Control Monoarticular aplicado en manipuladores móviles utilizando aprendizaje por refuerzo

Universidad Internacional de Valencia

Titulación:

Máster Inteligencia Artificial
Curso académico

2025-2026

Alumno/a:

Sarabia Palacio
Ricardo Enrique

D.N.I: LFTG8GWZ6

Director/a de TFM:
García Caicedo
Jesús Marcey

Convocatoria:

Regular

De:
Planeta Formación y Universidades

Universidad Internacional de Valencia

Índice

1 Resultados en Fase 2 4
1.1.1 Entrenamiento del agente RL 5
1.1.2 Evaluación del controlador RL en Plataforma Plana 9
1.1.3 Evaluación del controlador RL en Plataforma inclinada 13
1.1.4 Comparación PID vs Controlador RL Fase2 17
1.1.5 Conclusión Fase 2 18
Referencias Bibliográficas 20
2 Anexos 22
2.1 Modo en el Entrenamiento 22
2.2 Evaluación en las fases 22
2.3 Proceso de Decision de Markov (MDP) 22
2.4 Vector de observaciones 22
2.5 Anexo Bufferlength 22
2.6 Warm-Start Steps 22
2.7 Anexo policy Exploration Gaussian 23
2.8 Anexo Learning Rate Actor Critic 23
2.9 Anexo Mini Batchsize 23
2.10 TD3 Redes Neuronales 23
2.11 Función de Recompensa 23
2.12 Anexo Resultados 24

Índice de ilustraciones

Fig. 1. Entorno de la primera articulación con Agente RL. Fuente: Elaboración propia. Enlace. 4
Fig. 2. Función de recompensa en fase 2. Fuente: Elaboración propia. Enlace. 4
Fig. 3. Vector de Observación de Estado. Fuente: Elaboración propia. Enlace 5
Fig. 4. Curva de aprendizaje recompensa vs episodio del agente RL, fase 2. Fuente: Elaboración propia. Enlace. 6
Fig. 5. Evolución del RMSE global a lo largo de los checkpoints de entrenamiento. Fuente: Elaboración propia. Enlace. 7
Fig. 6. Comparación del RMSE angular de los mejores 3 checkpoints del agente RL. Fuente: Elaboración propia. Enlace. 8
Fig. 7. Evaluación del RMSE en el dominio angular bajo variación del ángulo inicial o1ini, plataforma plana. Fuente: Elaboración propia. Enlace. 9
Fig. 8. Respuesta temporal del sistema ante variaciones del ángulo inicial de operación en plataforma plana. Fuente: Elaboración propia. Enlace. 10
Fig. 9. Evaluación del RMSE en el dominio angular bajo variación retardo de señal. Fuente: Elaboración propia. Enlace. 11
Fig. 10. Respuesta temporal del sistema ante variaciones de retardo en el lazo de control. Fuente: Elaboración pro-pía. Enlace. 11
Fig. 11. Evaluación del RMSE en el dominio angular bajo variación de la velocidad angular inicial do1ini, plata-forma plana. Fuente: Elaboración propia. Enlace. 12
Fig. 12.. Respuesta temporal del sistema ante variaciones de la velocidad angular inicialen plataforma plana. Fuente: Elaboración propia. Enlace. 12
Fig. 13. Evaluación del RMSE en el dominio angular bajo variación del ángulo inicial o1ini, plataforma inclinada Pitch=Roll=-10°. Fuente: Elaboración propia. Enlace. 13
Fig. 14. Respuesta temporal del sistema ante variaciones del ángulo inicial de operación en plataforma inclinada pitch=roll= -10. Fuente: Elaboración propia. Enlace. 14
Fig. 15. Evaluación del RMSE en el dominio angular bajo variación retardo de señal en plataforma inclinada, pitch=roll= -10°. Fuente: Elaboración propia. Enlace. 14
Fig. 16. Respuesta temporal del sistema ante retardo en el lazo de control en plataforma inclinada pitch=roll= -10. Fuente: Elaboración propia. Enlace. 15
Fig. 17. Evaluación del RMSE en el dominio angular bajo variación de la velocidad angular inicial do1ini, plataforma inclinada pitch=roll=-10°. Fuente: Elaboración propia. Enlace. 16
Fig. 18. Respuesta temporal del sistema ante variaciones de la velocidad angular inicialen plataforma inclinada pitch=roll=-10°. Fuente: Elaboración propia. Enlace. ... 17
Fig. 19. Evaluación del RMSE en el dominio angular del PID vs Controlador RL Fase2, plataforma plana. Fuente: Elaboración propia. Enlace. 18
Fig. 20. Evaluación del RMSE en el dominio angular del PID vs Controlador RL Fase2, plataforma inclinada, pitch= roll= -10°. Fuente: Elaboración propia. Enlace 18

1 Resultados en Fase 2

Tras identificar en la Fase 1 las limitaciones del controlador PID en términos de robustez, sensibilidad al estado inicial y degradación del desempeño bajo perturbaciones, en esta segunda fase se aborda el problema mediante un enfoque basado en aprendizaje por refuerzo.

El objetivo de la Fase 2 es desarrollar y evaluar un agente RL de control capaz de aprender una política que permita el seguimiento angular de la primera articulación del robot Lázaro de forma más robusta y generalizable, incluso en presencia de no linealidades, perturbaciones y variaciones en las condiciones iniciales.

Para ello, se implementa un entorno de aprendizaje en MATLAB/Simulink donde el agente interactúa directamente con el modelo dinámico (véase Fig. 1), optimizando su comportamiento a través de una función de recompensa diseñada para penalizar el error (véase Fig. 2) el seguimiento del error.

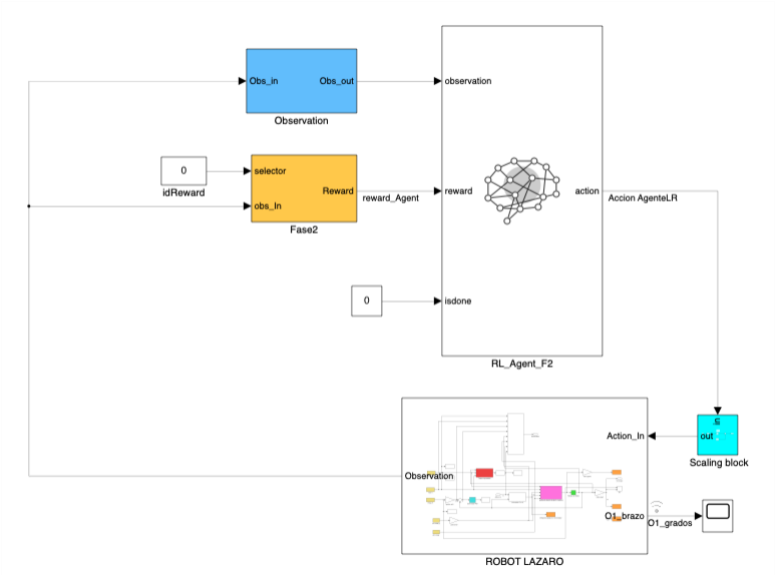

Fig. 1. Entorno de la primera articulación con Agente RL. Fuente: Elaboración propia. Enlace.

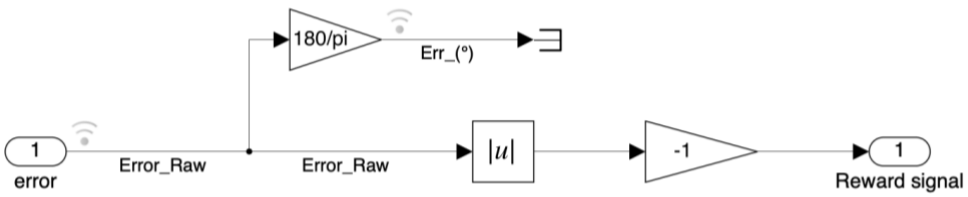

Fig. 2. Función de recompensa en fase 2. Fuente: Elaboración propia. Enlace.

En este contexto, el agente recibe como entrada un vector de observación diseñado para capturar tanto el estado instantáneo del sistema como su comportamiento dinámico. (véase Fig. 3). Dicho vector incorpora variables angulares y sus representaciones trigonométricas (seno y coseno), incluyendo la referencia, la posición actual y el error angular, así como las condiciones iniciales y la velocidad angular de la articulación. Esta formulación permite eliminar discontinuidades en el dominio angular y proporcionar al agente una representación continua y rica del estado, facilitando el aprendizaje de políticas de control más robustas y generalizables frente a las distintas condiciones evaluadas.

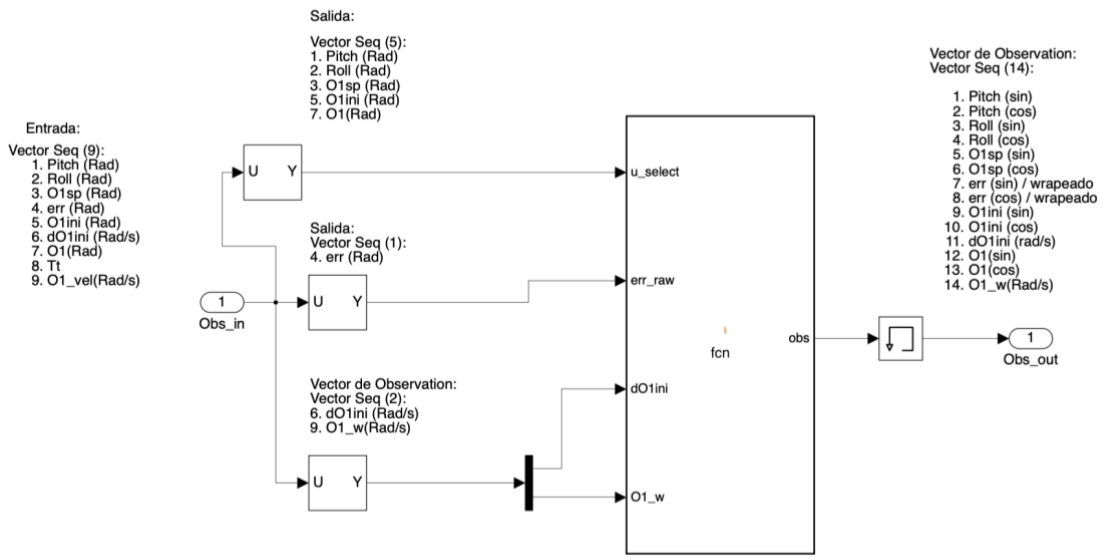

Fig. 3. Vector de Observación de Estado. Fuente: Elaboración propia. Enlace

La evaluación del agente se realiza bajo los mismos escenarios definidos en la Fase 1, incluyendo plataforma plana e inclinada, así como variaciones en el ángulo inicial, el retardo de señal y la velocidad angular inicial, con el fin de garantizar una comparación directa y objetiva entre ambos enfoques de control.

1.1.1 Entrenamiento del agente RL

En esta fase se aborda el entrenamiento del agente de aprendizaje por refuerzo utilizando una función de recompensa basada principalmente en el error de seguimiento. El objetivo es evaluar la capacidad del agente para aprender una política de control que minimice la desviación angular respecto a la referencia.

Durante el proceso de entrenamiento (véase Fig. 4), se observa una mejora progresiva del retorno acumulado, pasando de valores iniciales cercanos a −2000 hasta aproximadamente −500, lo que indica un aprendizaje efectivo del

comportamiento básico del sistema. Asimismo, la curva de recompensa promedio presenta una tendencia creciente y más estable, reflejando una reducción gradual del error de seguimiento. La Tabla 1 Muestra las Metricas e hiperparámetros utilizados para el entrenamiento.

No obstante, se identifican fluctuaciones puntuales en el retorno, asociadas a episodios con respuestas inestables, lo que sugiere que el agente aún no ha alcanzado una política completamente robusta.

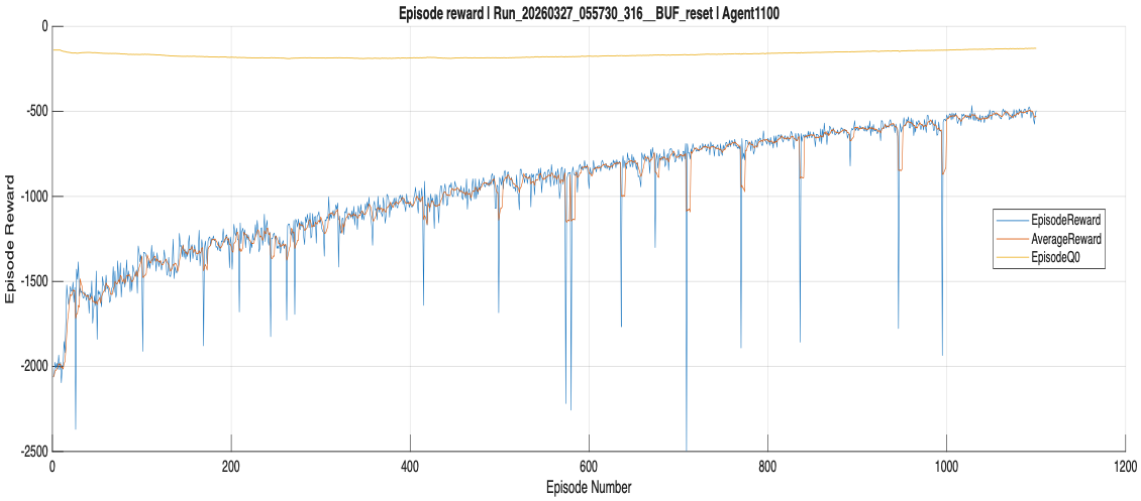

Fig. 4. Curva de aprendizaje recompensa vs episodio del agente RL, fase 2. Fuente: Elaboración propia. Enlace.

Tabla 1. Métricas e hiperparámetros del agente RL, fase2 durante el entrenamiento. Fuente: propia

Training Stats		
Métrica	Símbolo	Valor
Total de episodios	N_{ep}	1100
Recompensa total último episodio	R_{ep}	-495.652
Recompensa Media	$\bar{R}$	-528.005
Pasos último episodio	-	600
Número total de pasos	N_{steps}	660000
Promedio pasos/eps	-	600
Valor Q estimado	Q_0	-129.333

Advanced Agent Options		
Métrica	Símbolo	Valor
Tiempo muestreo	T_s	0.01
Factor descuento	γ	0.99
Tamaño del Batchize	B	64
Tamaño del Exp. Buffer		10000
Modo del Buffer	-	Reset
Taza aprendizaje actor	α_a	1.0000e-04
Optimizador del actor	-	adam
Taza aprendizaje critico	α_c	7.0000e-04
Optimizador del critico	-	adam
Coeficiente actualización suave	τ	0.005

Exploration Gaussian Model		
Métrica	Símbolo	Valor
Std.Dev	σ	0.3162
Mean	μ	0
Lower Lim	-	-0.5
Upper Lim	-	0.5
Std.Dev decay	λ_σ	1.7442e-06
Std.Dev min	σ_{min}	0.1

Target Policy Smoothing		
Métrica	Símbolo	Valor
Std.Dev	σ	0.2
Mean	μ	0
Lower Lim	-	-0.5
Upper Lim	-	0.5
Std.Dev decay	λ_σ	4.9929e-06
Std.Dev min	σ_{min}	0.01

Tras completar el proceso de entrenamiento, se realiza una evaluación sistemática de todos los checkpoints generados a lo largo del aprendizaje (vease Fig. 5). Para cada uno de ellos, se analiza el desempeño del agente mediante la métrica RMSE en el dominio angular, permitiendo observar la evolución de la capacidad de control a lo largo de los episodios. Esta evaluación proporciona una visión clara de la progresión del aprendizaje y permite identificar posibles mejoras, estancamientos o degradaciones en el desempeño del agente.

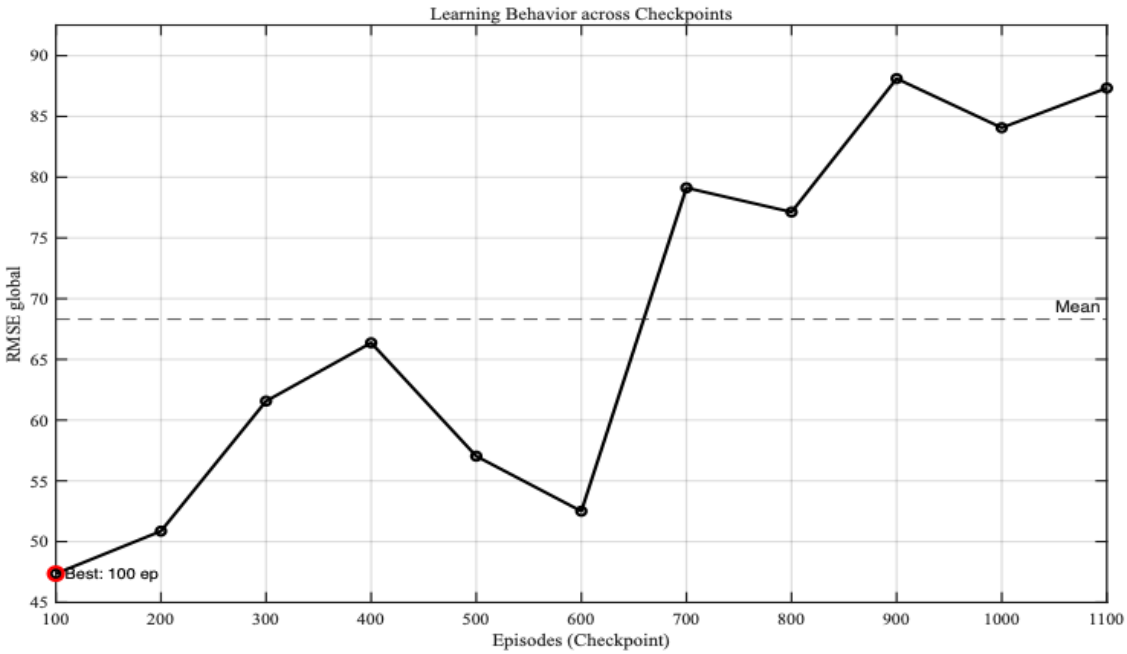

Fig. 5. Evolución del RMSE global a lo largo de los checkpoints de entrenamiento. Fuente: Elaboración propia. Enlace.

Tras el análisis de la evolución del desempeño durante el entrenamiento, se realiza una evaluación determinista de los diferentes checkpoints del agente. Para ello, se construye una tabla comparativa (véase Tabla 2) en la que se sintetizan las principales métricas de desempeño, como el RMSE global, el error máximo y la dispersión angular.

Esta comparación permite identificar de manera objetiva el mejor punto de entrenamiento, seleccionando el checkpoint que presenta el mejor equilibrio entre precisión, estabilidad y comportamiento global del sistema.

Tabla 2. Tabla de evaluación y selección del agente basada en métricas de desempeño. Fuente: Elaboración propia

Position	Agente	$RMSE_{global}$	$RMSE_{max}$	$\sigma_{angular}$	$Ratio_{ext}$	AUC
1	Agent100.mat	47.3593	91.9526	21.9152	1.9416	45.9488
2	Agent200.mat	50.8623	84.1346	16.6631	1.6542	49.9653
3	Agent600.mat	52.5019	104.5536	26.1521	1.9914	50.9272
4	Agent500.mat	57.0328	104.2105	22.3312	1.8272	56.4216
5	Agent300.mat	61.5651	139.2792	32.2617	2.2623	60.6632
6	Agent400.mat	66.3630	137.8620	33.3298	2.0774	65.1121
7	Agent800.mat	77.1289	137.6104	46.5498	1.7842	74.0597
8	Agent700.mat	79.1222	150.7403	48.0584	1.9052	75.3528
9	Agent1000.mat	84.0683	142.5539	45.6387	1.6957	81.6264
10	Agent1100.mat	87.3358	165.9936	49.7643	1.9006	84.6944

Posteriormente, se realiza una comparación detallada de los tres mejores checkpoints identificados (véase Fig. 6), analizando su desempeño en el dominio angular a lo largo de todo el rango de referencia. Esta evaluación permite observar diferencias en la precisión y la capacidad de generalización de cada agente, especialmente en zonas críticas del dominio.

Adicionalmente, esta comparación se lleva a cabo con el objetivo de seleccionar el agente más adecuado para las siguientes fases del estudio, garantizando que la elección se base en un criterio técnico y en el mejor desempeño global.

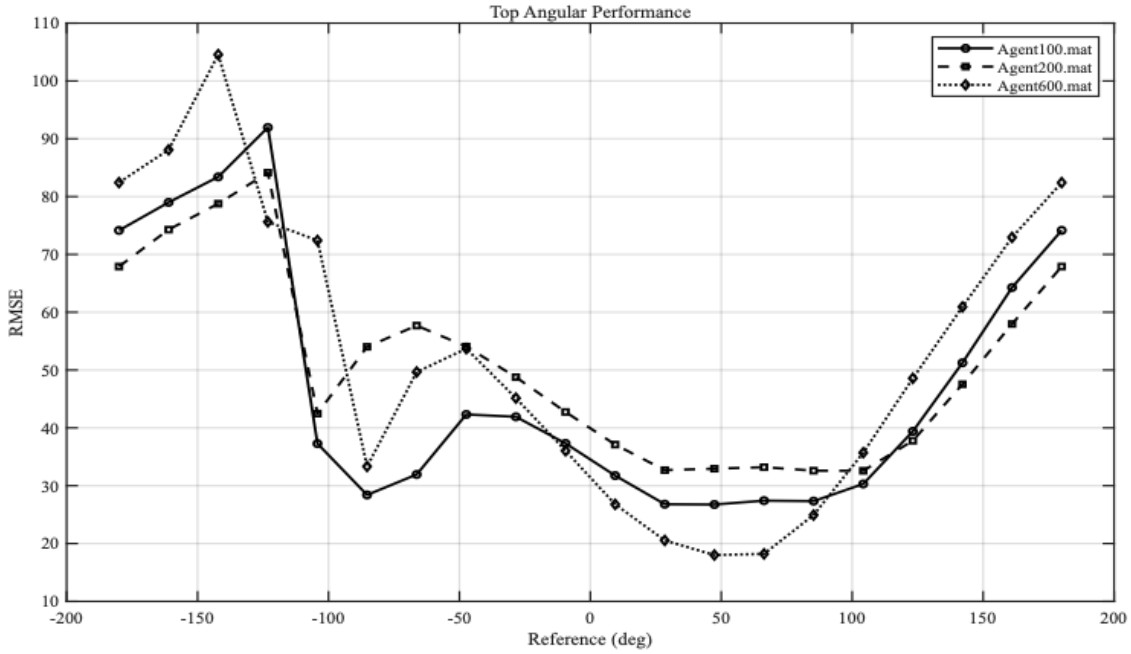

Fig. 6. Comparación del RMSE angular de los mejores 3 checkpoints del agente RL. Fuente: Elaboración propia. [Enlace.]

A partir del análisis comparativo de los checkpoints, se selecciona el Agent100 como el candidato óptimo, al presentar el mejor desempeño global en términos de RMSE y un comportamiento más consistente a lo largo del dominio angular.

En consecuencia, este agente es inyectado en el modelo de simulación, estableciendo su política como referencia para las siguientes etapas del estudio. A partir de este punto, se continúa con evaluaciones en modo determinista, con el objetivo de analizar de forma controlada su desempeño bajo diferentes condiciones operativas.

1.1.2 Evaluación del controlador RL en Plataforma Plana

En el dominio angular (Fig. 7), la variación del ángulo inicial $o1ini = (-90°, 0°, 90°)$ produce diferencias significativas en la distribución del RMSE, observándose tanto desplazamientos como distorsiones en la forma de la curva. A diferencia del comportamiento observado en el PID, el agente RL no mantiene una estructura uniforme en todo el dominio, evidenciando una dependencia más compleja del estado inicial. Los valores de RMSE alcanzan niveles elevados, superando los 100° en determinados sectores, lo que indica una pérdida de precisión y una menor capacidad de generalización bajo esta perturbación

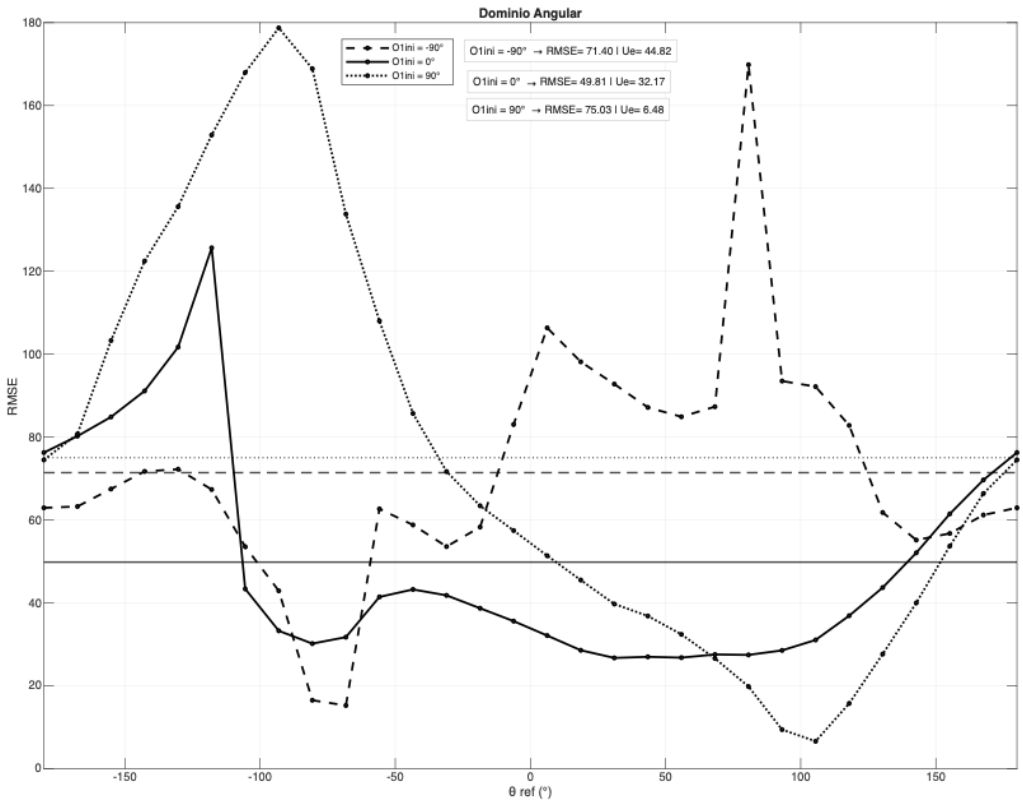

Fig. 7. Evaluación del RMSE en el dominio angular bajo variación del ángulo inicial o1ini, plataforma plana. Fuente: Elaboración propia. Enlace.

La respuesta temporal (Fig. 8) muestra que la variación en la posición inicial impacta de forma significativa el comportamiento dinámico del sistema. Aunque en algunos casos el agente logra aproximarse a la referencia, se observan desviaciones importantes, incluyendo sobreimpulsos elevados y, en ciertos escenarios, divergencias claras respecto a la consigna (por ejemplo, para $o1ini = -90°$). Este comportamiento evidencia que el agente no ha aprendido una política robusta frente a variaciones en el estado inicial, afectando tanto la estabilidad transitoria como la precisión en régimen permanente.

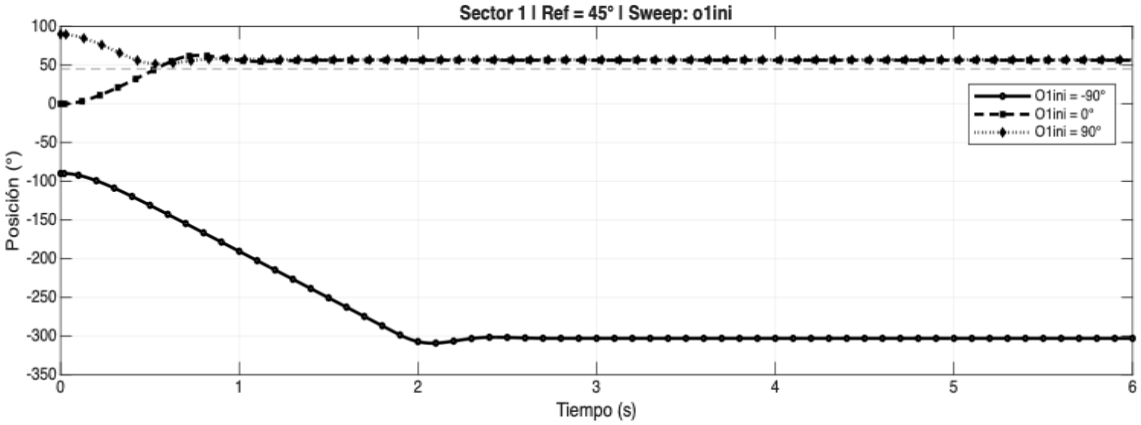

Fig. 8. Respuesta temporal del sistema ante variaciones del ángulo inicial de operación en plataforma plana. Fuente: Elaboración propia. Enlace.

En el dominio angular (Fig. 9), la variación del retardo de señal (0, 0.01, 0.02)[ms] no altera de forma significativa la estructura de la curva de RMSE, manteniéndose prácticamente invariante en todo el rango angular. Los valores de RMSE se sitúan alrededor de $86.9°$ a $87.0°$, lo que indica que el retardo introduce únicamente una ligera penalización global del desempeño, sin modificar la dependencia angular ni generar distorsiones relevantes en la respuesta del agente.

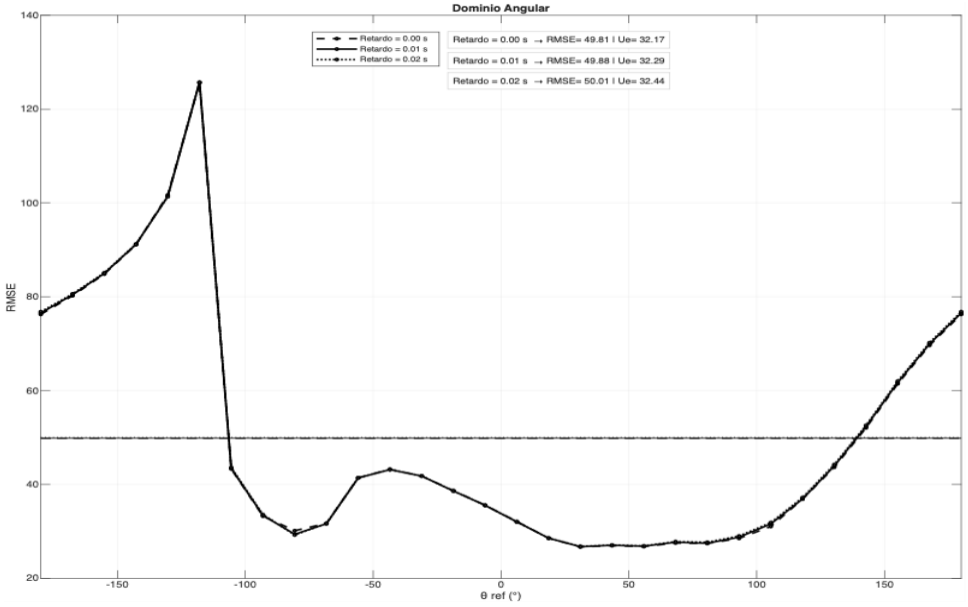

Fig. 9. Evaluación del RMSE en el dominio angular bajo variación retardo de señal. Fuente: Elaboración propia. Enlace

La respuesta temporal (véase Fig. 10) confirma este comportamiento, mostrando variaciones leves en el régimen transitorio a medida que aumenta el retardo, principalmente en forma de un incremento moderado del sobreimpulso. No obstante, el sistema mantiene una respuesta estable y convergente hacia la referencia, con diferencias poco significativas en el error estacionario y el tiempo de establecimiento. Esto sugiere que el agente presenta una baja sensibilidad al retardo de señal dentro del rango evaluado.

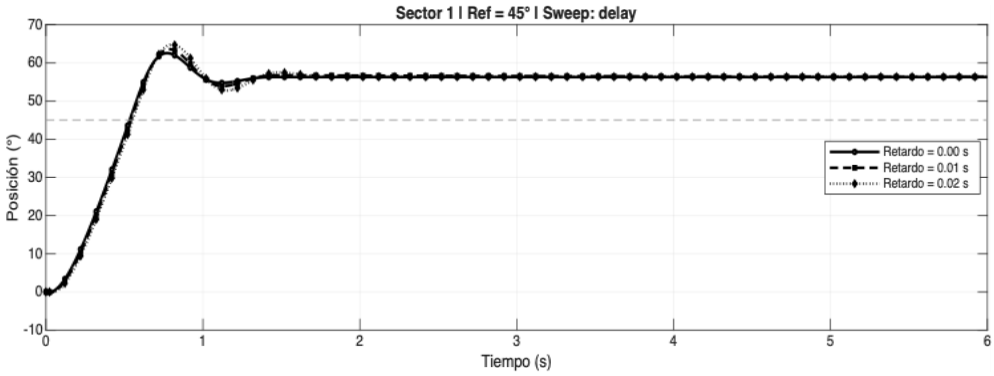

Fig. 10. Respuesta temporal del sistema ante variaciones de retardo en el lazo de control. Fuente: Elaboración propia. Enlace.

La variación de la velocidad angular inicial $\left(o1^{\cdot}_{\iota n\iota} = -3.14{,}0{,}3.14\right)\,\mathrm{rad}/s$ no solo produce un desplazamiento de la curva de RMSE, sino que introduce distorsiones claras en su forma, especialmente en los extremos del dominio. A diferencia del caso de retardo, las curvas no permanecen superpuestas, evidenciando una dependencia directa del desempeño respecto a la condición dinámica inicial (véase Fig. 11). Se observan incrementos de RMSE de hasta aproximadamente un 30 % entre escenarios, lo que confirma que la velocidad inicial actúa como un factor crítico en la degradación del rendimiento del agente.

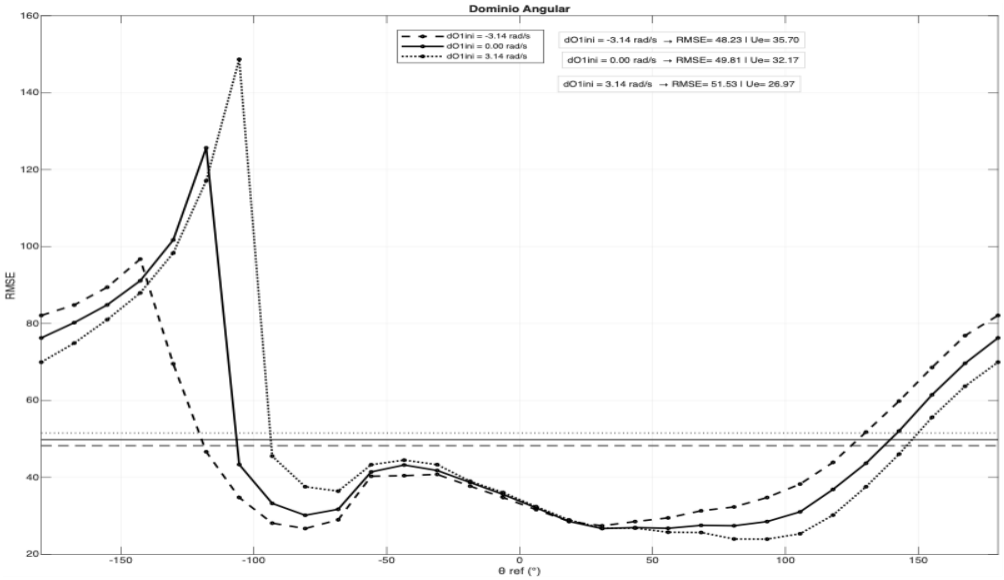

Fig. 11. Evaluación del RMSE en el dominio angular bajo variación de la velocidad angular inicial do1ini, plataforma plana. Fuente: Elaboración propia. Enlace.

La respuesta temporal refuerza esta observación, mostrando diferencias significativas en la fase transitoria dependiendo del signo y magnitud de la velocidad inicial. Se evidencian variaciones en el sobreimpulso, en la rapidez de convergencia y en el esfuerzo de control, siendo especialmente notable el caso de velocidad negativa, donde el sistema presenta mayor exigencia de actuación y peor desempeño global (RMSE ≈ 19.8° frente a ≈ 13.5°). Este comportamiento indica que el agente no ha logrado internalizar completamente la dinámica asociada a estados con energía inicial elevada, revelando una limitación en su capacidad de generalización frente a condiciones dinámicas adversas (véase Fig. 12).

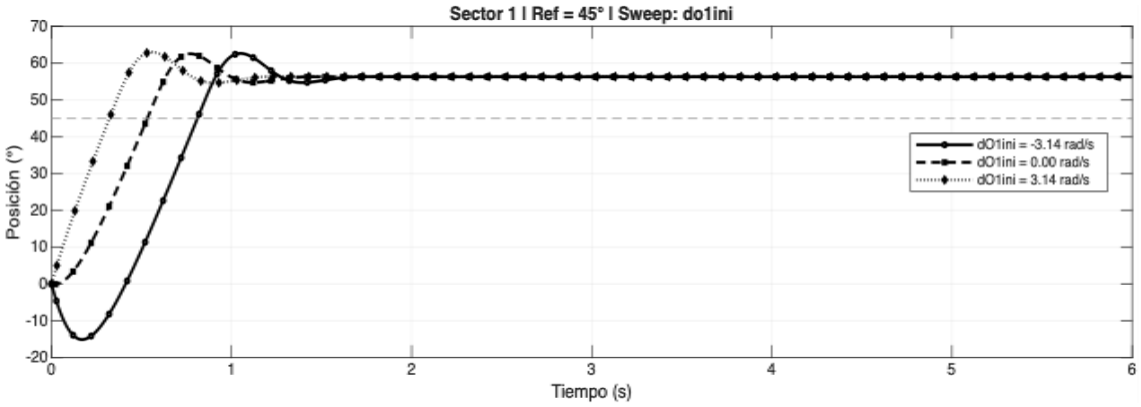

Fig. 12.. Respuesta temporal del sistema ante variaciones de la velocidad angular inicialen plataforma plana. Fuente: Elaboración propia. Enlace.

En condiciones de plataforma plana, el agente basado en aprendizaje por refuerzo demuestra un comportamiento estable y consistente frente a perturbaciones moderadas como el retardo de señal, manteniendo una respuesta prácticamente invariante en el dominio angular y una dinámica

temporal controlada. Sin embargo, su desempeño presenta una dependencia significativa respecto a las condiciones iniciales del sistema, especialmente ante variaciones en la velocidad angular inicial, donde se evidencian degradaciones notables en términos de RMSE, sobreimpulso y esfuerzo de control. Asimismo, la presencia de un error estacionario persistente indica que, si bien el agente ha aprendido una política funcional de control, aún no alcanza un nivel óptimo de precisión. En conjunto, estos resultados muestran que el controlador RL es robusto frente a perturbaciones estructurales del entorno, pero todavía limitado en su capacidad de generalización frente a estados dinámicos exigentes, lo que sugiere la necesidad de estrategias de entrenamiento más completas para mejorar su desempeño global.

1.1.3 Evaluación del controlador RL en Plataforma inclinada

En el dominio angular, el agente RL presenta una degradación significativa del desempeño respecto al caso en plataforma plana (véase Fig. 13). El RMSE medio se incrementa desde valores del orden de ≈ 49-75° (plataforma plana) hasta aproximadamente ≈ 52-76° en condición inclinada, lo que representa un aumento cercano al 2-6%. Además, la curva muestra una mayor dispersión y distorsión en los extremos del dominio (|θ| > 120°), donde el RMSE supera los 100°, evidenciando una pérdida de consistencia en la política aprendida. Este comportamiento confirma que la inclinación introduce una variación estructural en la dinámica (torque gravitatorio) que el agente no logra compensar adecuadamente.

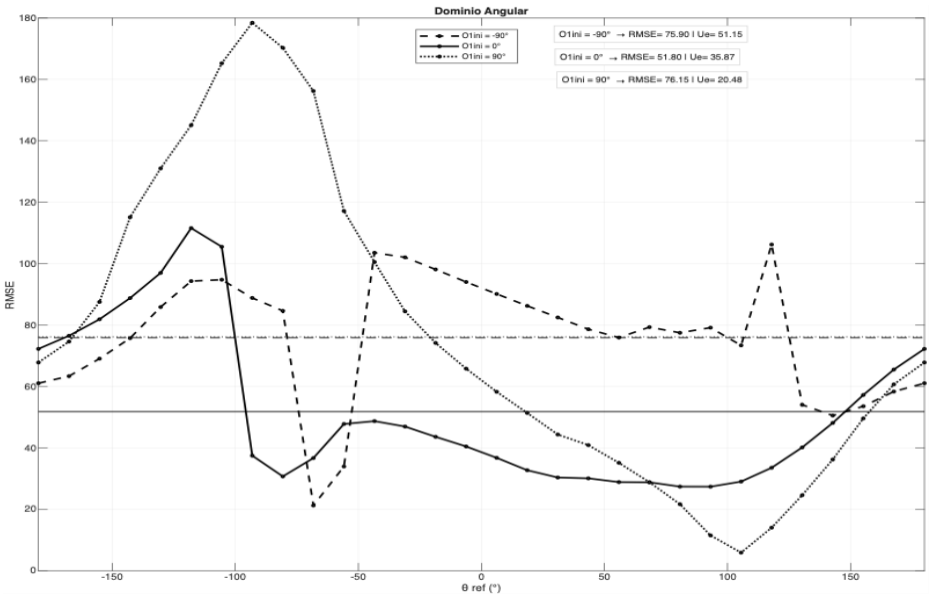

Fig. 13. Evaluación del RMSE en el dominio angular bajo variación del ángulo inicial o1ini, plataforma inclinada Pitch=Roll=-10°. Fuente: Elaboración propia. Enlace.

En la respuesta temporal (véase Fig. 14), el sistema mantiene estabilidad en condiciones nominales (o1ini = 0°), con un RMSE de ≈ 29.93°. No obstante, el error aumenta hasta ≈ 40.40° (o1ini = 90°) y ≈ 78.20° (o1ini = −90°), evidenciando

una degradación significativa del desempeño y pérdida de seguimiento en condiciones iniciales extremas.

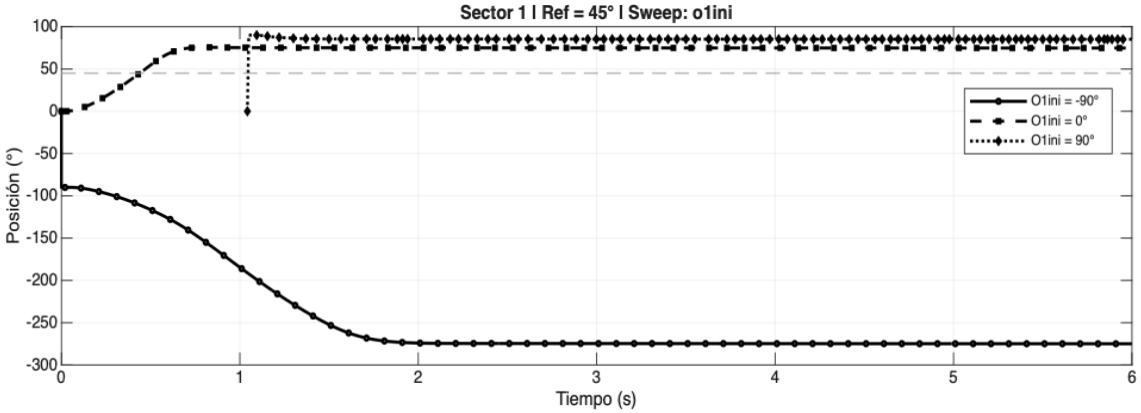

Fig. 14. Respuesta temporal del sistema ante variaciones del ángulo inicial de operación en plataforma inclinada pitch=roll= -10. Fuente: Elaboración propia. Enlace.

Como se observa en la Fig. 15, el retardo de señal no altera la forma global del RMSE, sino que introduce una variación prácticamente uniforme y de baja magnitud en todo el rango angular. El RMSE en plataforma inclinada pasa de 51.80° (0 ms) a 52.13° (20 ms), lo que representa una variación inferior al 0.64%, indicando una alta robustez estructural del agente frente a retardos pequeños. La distribución del error presenta un pico elevado en el sector angular negativo, seguido de una caída abrupta y una zona de menor error en ángulos intermedios, para posteriormente incrementarse de forma progresiva hacia el extremo positivo del dominio. Esta estructura se mantiene para todos los retardos analizados.

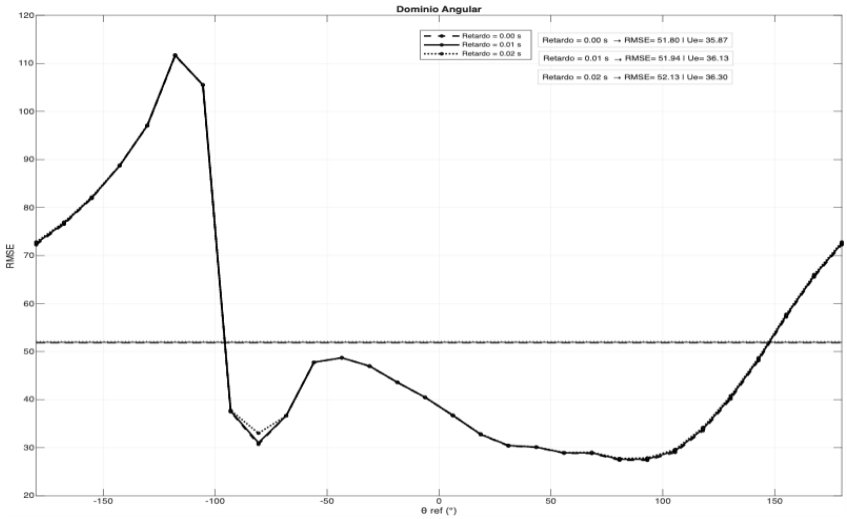

Fig. 15. Evaluación del RMSE en el dominio angular bajo variación retardo de señal en plataforma inclinada, pitch=roll= -10°. Fuente: Elaboración propia. Enlace.

En la respuesta temporal (véase Fig. 16), el sistema mantiene estabilidad y convergencia en todos los casos evaluados. El retardo introduce únicamente degradaciones leves en el comportamiento dinámico, reflejadas en un incremento moderado del sobreimpulso (≈ 57.6% a ≈ 65.7%). El error estacionario permanece prácticamente constante en torno a ≈ 14.9°, mientras que el RMSE aumenta ligeramente de ≈ 17.78° a ≈ 18.22° (≈ +2.5%), evidenciando una baja sensibilidad del agente frente a retardos pequeños.

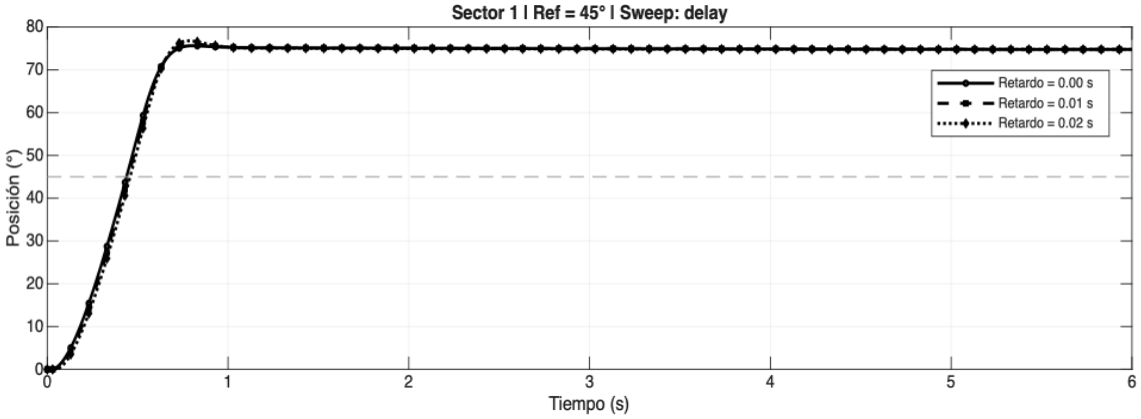

Fig. 16. Respuesta temporal del sistema ante retardo en el lazo de control en plataforma inclinada pitch=roll= -10. Fuente: Elaboración propia. Enlace.

En el dominio angular (véase Fig. 17) la variación de la velocidad angular inicial introduce modificaciones moderadas en el desempeño del agente. El RMSE medio varía entre ≈ 50.00° y ≈ 55.68°, lo que representa cambios relativamente acotados.

A diferencia del caso del retardo, no se observa un desplazamiento uniforme de la curva, sino distorsiones locales en determinadas regiones del dominio angular, especialmente en los extremos. No obstante, la forma global del RMSE se mantiene, evidenciando una dependencia moderada del agente respecto al estado dinámico inicial.

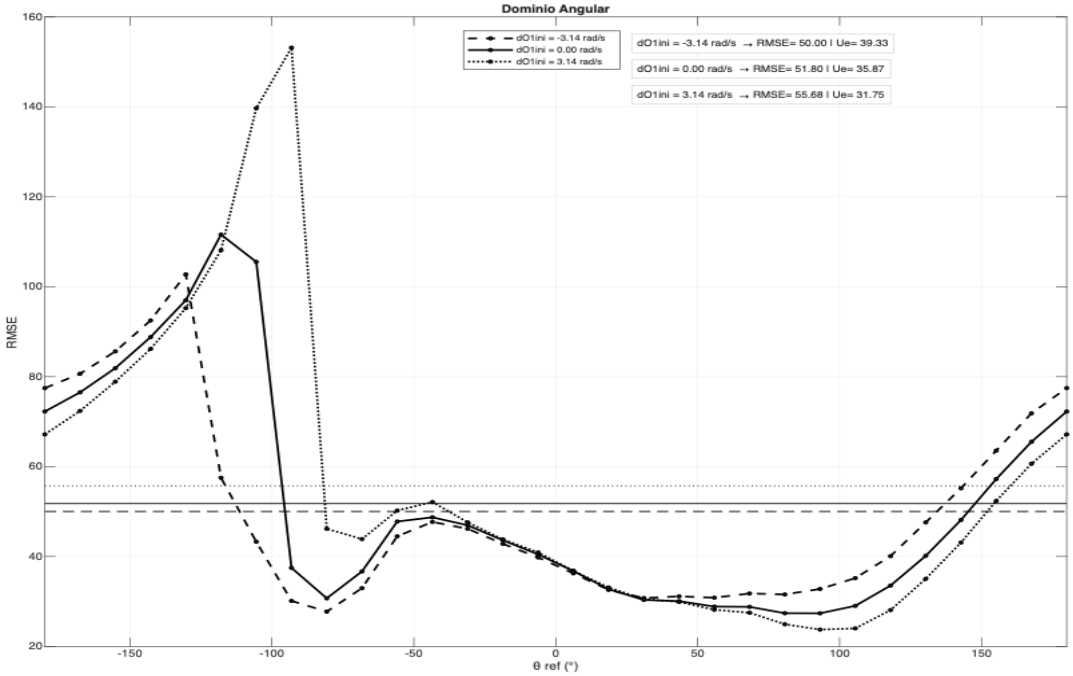

Fig. 17. Evaluación del RMSE en el dominio angular bajo variación de la velocidad angular inicial do1ini, plataforma inclinada pitch=roll=-10°. Fuente: Elaboración propia. Enlace.

En la respuesta temporal (véase Fig. 52), la velocidad angular inicial impacta principalmente el régimen transitorio del sistema. El agente mantiene estabilidad y convergencia en todos los casos, con un error estacionario prácticamente constante en torno a ≈ 15°. El RMSE varía entre ≈ 16.88° y ≈ 20.98°, lo que representa un incremento de aproximadamente +24% en condiciones adversas. Por su parte, el sobreimpulso se mantiene en un rango similar (≈ 58–59%), evidenciando una variación limitada frete a esta perturbación.

Estos resultados indican que la velocidad angular inicial introduce una degradación moderada del desempeño, afectando principalmente la fase transitoria sin comprometer la estabilidad del sistema.

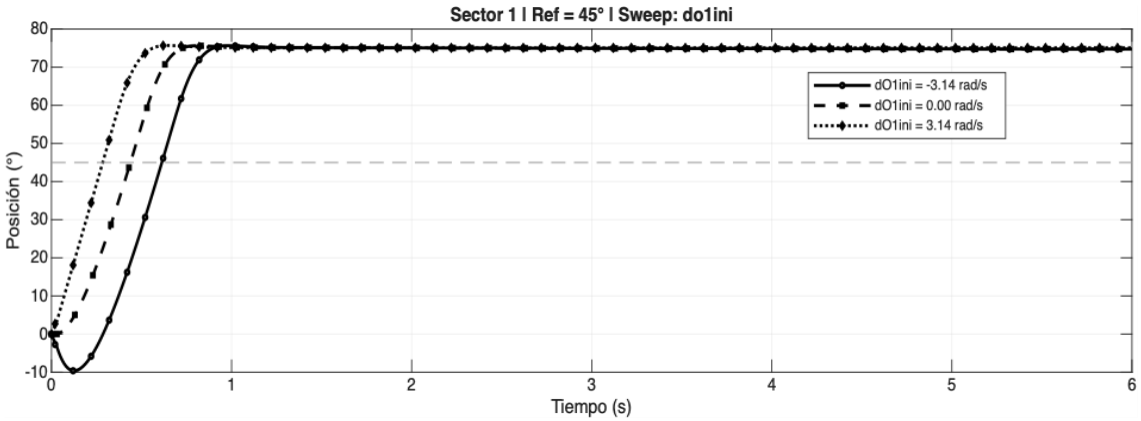

Fig. 18. Respuesta temporal del sistema ante variaciones de la velocidad angular inicialen plataforma inclinada pitch=roll=-10°. Fuente: Elaboración propia. Enlace.

La inclinación de la plataforma introduce una degradación cuantificable en el desempeño del agente RL. En el dominio angular, el RMSE medio se sitúa en torno a ≈ 51.80°, con incrementos de hasta ≈ 55.68° (+7.5%) bajo variaciones de velocidad inicial y valores de ≈ 75–76° en condiciones extremas de ángulo inicial.

En la respuesta temporal, el error estacionario se mantiene alrededor de ≈ 14–16°, mientras que el RMSE varía entre ≈ 16.88° y ≈ 20.98° (+24%) dependiendo de la condición inicial. El sobreimpulso se sitúa en el rango de ≈ 57–66%, con incrementos moderados ante retardo, mientras que este último introduce variaciones mínimas en el RMSE (≈ 17.78° a ≈ 18.22°, +2.5%).

El análisis evidencia una jerarquía clara en el impacto de las perturbaciones: el ángulo inicial genera las mayores degradaciones (RMSE hasta ≈ 78.20° y pérdida de seguimiento), la velocidad angular inicial introduce variaciones moderadas, y el retardo presenta un efecto prácticamente despreciable.

En conjunto, aunque el agente mantiene estabilidad, presenta una limitada capacidad de generalización frente a condiciones iniciales adversas y cambios en la dinámica inducidos por la inclinación.

1.1.4 Comparación PID vs Controlador RL Fase2

El controlador PID presenta un desempeño claramente superior al agente RL en el dominio angular, con un RMSE medio significativamente menor tanto en plataforma plana (véase la Fig. 19)(≈ 31° vs ≈ 87°), como en plataforma inclinada (veas e la Fig. 20) (≈ 40° vs ≈ 88°).

El PID mantiene una curva más suave y consistente en todo el rango angular, mientras que el RL muestra errores elevados y mayor degradación en los extremos del dominio.

Además, el PID evidencia mayor robustez ante cambios en la dinámica (inclinación), incrementando su RMSE de forma moderada, mientras que el RL mantiene un error alto prácticamente constante, sin mejora estructural.

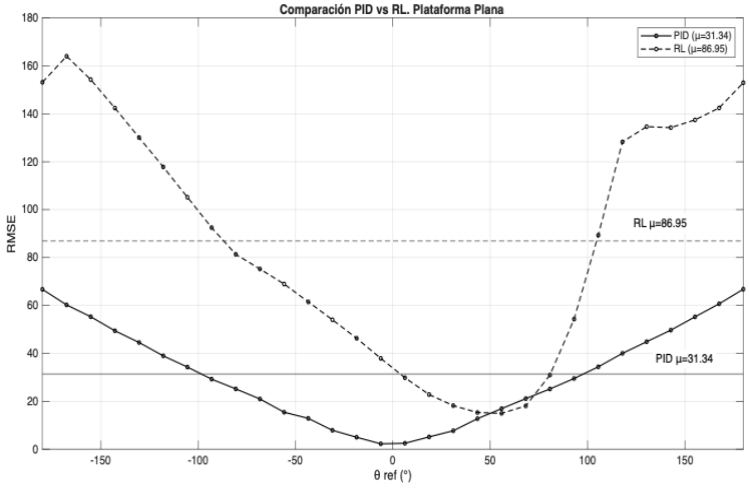

Fig. 19. Evaluación del RMSE en el dominio angular del PID vs Controlador RL Fase2, plataforma plana. Fuente: Elaboración propia. Enlace.

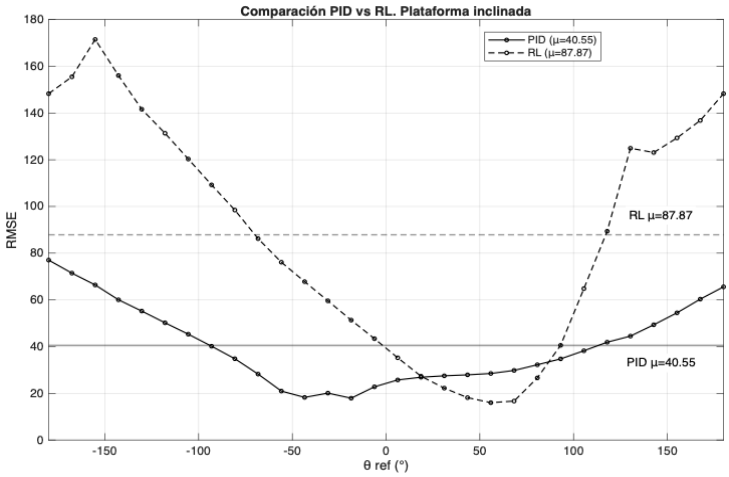

Fig. 20. Evaluación del RMSE en el dominio angular del PID vs Controlador RL Fase2, plataforma inclinada, pitch= roll= -10°. Fuente: Elaboración propia. Enlace.

Véase tabla de resultados en el Anexo 2.12, Enlace.

1.1.5 Conclusión Fase 2

La Fase 2 demuestra que el agente RL, basado en una recompensa simple centrada únicamente en el error de seguimiento, no alcanza un desempeño comparable al controlador PID, tal como se observa en la Tabla 3.

En el dominio angular, el agente presenta un RMSE elevado, situándose en torno a 49–50° en plataforma plana y 51–52° en plataforma inclinada, valores significativamente superiores a los obtenidos por el PID (≈31° y ≈40°, respectivamente). Además, ante variaciones en las condiciones iniciales, especialmente en el ángulo, el error se incrementa de forma considerable,

alcanzando valores superiores a 100°, lo que evidencia una fuerte sensibilidad del modelo.

En el dominio temporal, este comportamiento se traduce en respuestas menos estables y con mayor dificultad para alcanzar la consigna de forma precisa, reflejando un control aún no refinado.

Asimismo, bajo condiciones más exigentes como la plataforma inclinada, el agente no muestra una mejora estructural, manteniendo niveles de error similares o incluso superiores, a diferencia del PID, cuyo deterioro es más moderado.

Los resultados recogidos en la Tabla 3 indican que una función de recompensa basada únicamente en el error de seguimiento resulta insuficiente, siendo necesario incorporar términos adicionales que permitan mejorar la estabilidad, la robustez y el comportamiento dinámico del agente.

Tabla 3. Métricas de seguimiento (RMSE) y esfuerzo de control (U_ernergy) del agente RL en Fase 2. Fuente: Elaboración propi. Enlace.

	Seguimiento		**Esfuerzo**	
	Plataforma plana [RMSE]	**Plataforma Inclinada [RMSE]**	**Plataforma plana [U_energy]**	**Plataforma Inclinada [U_energy]**
Retardo=0ms	49.81	51.80	32.17	35.87
Retardo=0.01ms	49.88	51.94	32.29	36.13
Reatardo=0.02ms	50.01	52.13	32.14	36.30
o1ini=-90°	99.26	75.90	44.82	51.15
o1ini= 0°	86.94	51.80	32.17	35.57
o1ini=90°	101.50	76.15	6.46	20.48
do1ini = -0.5rad/s	48.23	50.00	35.70	39.33
do1ini = 0rad/s	49.81	51.80	32.17	35.87
do1ini = 0.5rad/s	51.53	55.68	26.97	31.75

Referencias Bibliográficas

Achiam, J. (Jan de 2026). *https://spinningup.openai.com/en/latest/algorithms/td3.html*. Obtenido de SpinningUp OpenAI: https://spinningup.openai.com/en/latest/algorithms/td3.html

Dankwa, S., & Wenfeng, Z. (2019). Twin-Delayed DDPG: A Deep Reinforcement Learning Technique to Model a Continuous Movement of an Intelligent Robot Agent. *ICVISP 2019, Proceedings of the 3rd International Conference on Vision, Image and Signal Processing*.

Fujimoto, S., Van Hoof, H., & Meger, D. (2018). *Addressing Function Approximation Error in Actor-Critic Methods.* Stockholm, Sweden: PMLR (Proceedings of Machine Learning Research).

Gamal, Z., Mahran, Y., & El-Badawy, A. (2024). *Control of a Twin Rotor using Twin Delayed Deep Deterministic Policy Gradient (TD3).* Egypt: 28th International Conference on System Theory, Control and Computing (ICSTCC).

García, J. M., Medina, I. J., Martinez, J. L., García-Cerezo, A., Linares, A., & Porras, C. (2017). *Lázaro: Robot Móvil dotado de Brazo para Contacto con el Suelo.*

García, J. M., Medina, I., Cerezo, A. G., & Linares, A. (2015). Improving The Static Stability Of A Mobile Manipulator Using Its End Effector In Contact With The Ground. 3228-3234.

García, J., Bohórquez, A., & Valero, A. (2020). Suspension Effect in Tip-Over Stability and Steerability of Robots Moving on Sloping Terrains. *IEEE LATIN AMERICA TRANSACTIONS*, 1381-1389.

Hazem, Z. B., Saidi, F., Guler, N., & Altaif, A. H. (2025). A Hybrid Reinforcement Learning Framework Combining TD3 and PID Control for Robust Trajectory Tracking of a 5-DOF Robotic Arm. *automation*.

Khoi, P. B., Giang, N. T., & Tan, H. V. (2021). Control and Simulation of a 6-DOF Biped Robot based on Twin Delayed Deep Deterministic Policy Gradient Algorithm. *Indian journal of Science and Technology*.

Kim, M., Han, D.-K., Park, J.-H., & Kim, J.-S. (2020). Motion Planning of Robot Manipulators for a Smoother Path Using a Twin Delayed Deep Deterministic Policy Gradient with Hindsight Experience Replay. *Applied Science*, 10,575.

Li, H. (2024). *Machine Learning Methods.* Quanzhou, China: Springer.

Lunze, J. (2014). *Regelungstechnik 1 . Systemtheoretische Grundlangen, Analyse und Entwurfe einschleifiger Regelung.* Berlin: Springer Vieweg.

M., G. J., L., M. J., A., M., & A., G.-C. (2017). Caster-legaidedmaneuverfornegotiatingsurfacediscontinuities withawheeledskid-steermobilerobot. *RoboticsandAutonomousSystems*, 25-37.

M., H. (2019). *Grundlagen der Robotik.* Berlin: VDE Verlag.

Mahran, Y., Gamal, Z., & El-Badawy, A. (2024). *Reinforcement Learning Position Control of a Quadrotor Using Soft Actor-Critic (SAC).* Egypt: publication in the IEEE 6th Novel Intelligent and Leading Emerging Sciences Conference (NILES).

Martínez, J. L., Mandow, A., & García-Cerezo, A. (2017). Slide-Down Prevention for Wheeled Mobile Robots on Slopes. *ACM*.

MatlabWorks. (Januar de 2026). *Reinforcement Learning Toolbox*. Obtenido de MATLAB Hilfe-Center: https://de.mathworks.com/help/reinforcement-learning/index.html?utm_source=chatgpt.com

Mosali, N. A., Shamsudin, S. S., & Omar Alfandi, R. O.-F. (2022). Twin Delayed Deep Deterministic Policy Gradient-Based Target Tracking for Unmanned Aerial Vehicle With Achievement Rewarding and Multistage Training. *IEEE Access*.

OpenAI. (26 de 01 de 2026). *Spinning Up in Deep Reinforcement Learning: DDPG*. Obtenido de OpenAI: https://spinningup.openai.com/en/latest/algorithms/ddpg.html#the-q-learning-side-of-ddpg

Plaat, A. (2022). *Deep Reinforcement Learnig.* Netherlands: Springer.

Sutton, R. S., & Barto, A. G. (2018). *Reinforcement Learning.* London, England: The MIT Press.

Wittpahl, V. (2019). *Künstliche Intelligenz, technologie, Anwendung, Gesellschaft.* Berlin: Springer Verlag.

2 Anexos

https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia

2.1 Modo en el Entrenamiento

Modos en el Entrenamiento: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/InformacionGeneral/MetodosEntrenamiento.pdf*

2.2 Evaluación en las fases

Evaluación en las fases: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/InformacionGeneral/MetodologiaEvaluacion.pdf*

2.3 Proceso de Decision de Markov (MDP)

Proceso de Decision de Markov (MDP): [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/InformacionGeneral/El%20Proceso%20de%20Decisión%20de%20Markov%20(MDP).pdf*

2.4 Vector de observaciones

Bus Vector de Observaciones: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/ArquitecturaAgente/Observacion/BusVectorObservacion.pdf*

Observables: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/ArquitecturaAgente/Observacion/Observation.pdf*

2.5 Anexo Bufferlength

Bufferlength: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/InformacionGeneral/EvaluacionImpactoBufferlength.pdf*

2.6 Warm-Start Steps

Warm-start Steps:[Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/InformacionGeneral/EvaluacionImpactoWarmStartSteps.pdf*

2.7 Anexo policy Exploration Gaussian

Exploracion Gaussiana: [Enlace],
https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/InformacionGeneral/EvaluacionImpactoPolicyExplorationGaussian.pdf

2.8 Anexo Learning Rate Actor Critic

Taza de Aprendizaje: [Enlace],
https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/InformacionGeneral/EvaluacionImpactoLearningRate.pdf

2.9 Anexo Mini Batchsize

Minie Batchsize: [Enlace],
https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/InformacionGeneral/EvaluacionImpactoBatchsize.pdf

2.10 TD3 Redes Neuronales

Redes Neuronales TD3: [Enlace],
https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/ArquitecturaAgente/05_Redes/RedesActorCritico.pdf

2.11 Función de Recompensa

Función de Recompensa: [Enlace],
https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/tree/main/ArquitecturaAgente/03_FuncionRecompensas

Función de Recompensa Sistema A: [Enlace],
https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/ArquitecturaAgente/03_FuncionRecompensas/Reward_System_A.pdf

Función de Recompensa Sistema D: [Enlace],
https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/ArquitecturaAgente/03_FuncionRecompensas/Reward_System_D.pdf

Función de Recompensa Sistema F: [Enlace],
https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/ArquitecturaAgente/03_FuncionRecompensas/Reward_System_F.pdf

2.12 Anexo Resultados

Fase 1:

Fase 1 plataforma plana: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase1/03_results/Evaluación%20PID–%20Plataforma%20plana%20%20.pdf*

Fase 1 plataforma inclinada: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase1/03_results/Evaluación%20PID–%20Plataforma%20Inclinada.pdf*

Fase1 tabla de resultados: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase1/03_results/TablaResultadosFase1.pdf*

Fase 2:

Fase 2 Entrenamiento: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase2/03_results/EvaluacionEntrenamiento.pdf*

Fase 2 plataforma plana: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase2/03_results/EvaluacionAgenteRL_F2–%20Plataforma%20plana%20%20.pdf*

Fase 2 plataforma inclinada: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase2/03_results/EvaluacionAgenteRL_F2–%20Plataforma%20Inclinada.pdf*

Fase 2 Tabla de resultados: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase2/03_results/TablaResultadosFase2.pdf*

Fase 2 Comparación PID vs RL: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase2/03_results/ComparacionPID_vs_RL_F2.pdf*

Fase 3:

Fase 3 Entrenamiento: [Enlace],
https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase3/03_results/EvaluacionEntrenamiento.pdf

Fase 3 plataforma plana: [Enlace],
https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase3/03_results/Evaluación%20AgenteRL_F3–%20Plataforma%20plana%20%20.pdf

Fase 3 plataforma inclinada: [Enlace],
https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase3/03_results/Evaluación%20AgenteRL_F3–%20Plataforma%20Inclinada.pdf

Fase 3 Tabla de resultados: [Enlace],
https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase2/03_results/TablaResultadosFase2.pdf

Fase 3 Comparación PID vs RL: [Enlace],
https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase3/03_results/ComparacionPID_vs_RL_F3.pdf

Fase 4A:

Fase 4A Entrenamiento: [Enlace],
https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase4/03_results/FaseA/EvaluacionEntrenamientoFaseA_Agente600.pdf

Fase 4A plataforma plana: [Enlace],
https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase4/03_results/Evaluación%20AgenteRL_F4A_Agente600–%20Plataformaplana.pdf

Fase 4A plataforma inclinada: [Enlace],
https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase4/03_results/FaseA/Evaluación%20AgenteRL_F4A_Agente600–Plataformainclinada.pdf

Fase 4A Tabla de resultados: [Enlace],
https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase4/03_results/TablaResultadosFase4A.pdf

Fase 4A Comparación PID vs RL: [Enlace],
https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase4/03_results/FaseA/ComparacionPID_vs_RL_F4A_Agente600.pdf

Fase 4B:

Fase 4B Entrenamiento: [Enlace],
https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase4/03_results/FaseB/EvaluacionEntrenamientoFaseB_Agente1900.pdf

Fase 4B plataforma plana: [Enlace],
https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase4/03_results/FaseB/Evaluación%20AgenteRL_F4B_Agente1900–Plataformaplana.pdf

Fase 4B plataforma inclinada: [Enlace],
https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase4/03_results/FaseB/Evaluación%20AgenteRL_F4B_Agente1900–Plataformainclinada.pdf

Fase 4B Tabla de resultados: [Enlace],
https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase4/03_results/FaseB/TablaResultadosFase4B.pdf

Fase 4B Comparación PID vs RL: [Enlace]
https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase4/03_results/FaseB/ComparacionPID_vs_RL_F4B_Agente1900.pdf

Fase 4C:

Fase 4C Entrenamiento: [Enlace],
https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase4/03_results/FaseC/EvaluacionEntrenamientoFaseC_Agente300.pdf

Fase 4C plataforma plana: [Enlace],
https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase4/03_results/FaseC/Evaluación%20AgenteRL_F4C_Agente300–Plataformaplana.pdf

Fase 4C plataforma inclinada: [Enlace],
https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase4/03_results/FaseC/Evaluación%20AgenteRL_F4C_Agente300–Plataformainclinada.pdf

Fase 4C Tabla de resultados: [Enlace],
https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase4/03_results/FaseC/TablaResultadosFase4C.pdf

Fase 4C Comparación PID vs RL: [Enlace],
https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase4/03_results/FaseC/ComparacionPID_vs_RL_F4C_Agente300.pdf

Fase 5:

Fase 5 plataforma plana: [Enlace],
https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase5/03_results/Evaluación%20AgenteRL_F5_Politica_Plataformaplana.pdf

Fase 5 plataforma inclinada: [Enlace],
https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase5/03_results/Evaluación%20AgenteRL_F5_Politica_Plataformainclinada.pdf

Fase 5 Tabla de Resultados: [Enlace],
https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase5/03_results/TablaResultadosFase5.pdf

Fase 5 Comparación PID vs política neuronal: [Enlace],
https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase5/03_results/ComparacionPID_vs_Politica_F5.pdf