Control Monoarticular aplicado en manipuladores móviles utilizando aprendizaje por refuerzo

Universidad Internacional de Valencia

Titulación:

Máster Inteligencia Artificial
Curso académico

2025-2026

Alumno/a:

Sarabia Palacio
Ricardo Enrique

D.N.I: LFTG8GWZ6

Director/a de TFM:
García Caicedo
Jesús Marcey

Convocatoria:

Regular

De:
Planeta Formación y Universidades

Universidad Internacional de Valencia

Índice

1 Resultados en Fase 3 4
1.1.1 Entrenamiento del agente RL 5
1.1.2 Evaluación del controlador RL en plataforma plana 8
1.1.3 Evaluación del controlador RL en plataforma inclinada 12
1.1.4 Comparación PID vs controlador RL fase3 16
1.1.5 Conclusión Fase 3 17
Referencias Bibliográficas 19
2 Anexos 21
2.1 Modo en el Entrenamiento 21
2.2 Evaluación en las fases 21
2.3 Proceso de Decision de Markov (MDP) 21
2.4 Vector de observaciones 21
2.5 Anexo Bufferlength 21
2.6 Warm-Start Steps 21
2.7 Anexo policy Exploration Gaussian 22
2.8 Anexo Learning Rate Actor Critic 22
2.9 Anexo Mini Batchsize 22
2.10 TD3 Redes Neuronales 22
2.11 Función de Recompensa 22
2.12 Anexo Resultados 23

Índice de ilustraciones

Fig. 1. Función de recompensa (Reward_systemA) en fase 3. Fuente: Elaboración propia. Enlace. 4
Fig. 2. Curva de aprendizaje recompensa vs episodio del agente RL, fase 3. Fuente: Elaboración propia. Enlace 5
Fig. 3. Evolución del RMSE global a lo largo de los checkpoints de entrenamiento. Fuente: Elaboración propia. Enlace. 7
Fig. 4. Comparación del RMSE angular de los mejores 3 checkpoints del agente RL. Fuente: Elaboración propia. Enlace. 8
Fig. 5. Evaluación del RMSE en el dominio angular bajo variación del ángulo inicial o1ini, plataforma plana. Fuente: Elaboración propia. Enlace. 9
Fig. 6. Respuesta temporal del sistema ante variaciones del ángulo inicial de operación en plataforma plana. Fuente: Elaboración propia. Enlace 9
Fig. 7. Evaluación del RMSE en el dominio angular bajo variación retardo de señal. Fuente: Elaboración propia. Enlace. 10
Fig. 8. Respuesta temporal del sistema ante variaciones de retardo en el lazo de control. Fuente: Elaboración pro-pía. Enlace. 11
Fig. 9. Evaluación del RMSE en el dominio angular bajo variación de la velocidad angular inicial do1ini, plataforma plana. Fuente: Elaboración propia. Enlace. 11
Fig. 10. Respuesta temporal del sistema ante variaciones de la velocidad angular inicialen plataforma plana. Fuente: Elaboración propia. Enlace. 12
Fig. 11. Evaluación del RMSE en el dominio angular bajo variación del ángulo inicial o1ini, plataforma inclinada Pitch=Roll=-10°. Fuente: Elaboración propia. Enlace. 13
Fig. 12. Respuesta temporal del sistema ante variaciones del ángulo inicial de operación en plataforma inclinada pitch=roll= -10. Fuente: Elaboración propia. Enlace. 13
Fig. 13. Evaluación del RMSE en el dominio angular bajo variación retardo de señal en plataforma inclinada, pitch=roll= -10°. Fuente: Elaboración propia. Enlace. 14
Fig. 14. Respuesta temporal del sistema ante retardo en el lazo de control en plataforma inclinada pitch=roll= -10. Fuente: Elaboración propia. Enlace. 14
Fig. 15. Evaluación del RMSE en el dominio angular bajo variación de la velocidad angular inicial do1ini, plataforma inclinada pitch=roll=-10°. Fuente: Elaboración propia. Enlace. 15
Fig. 16. Respuesta temporal del sistema ante variaciones de la velocidad angular inicialen plataforma incliada pitch=roll=-10°. Fuente: Elaboración propia. Enlace. 15
Fig. 17. Evaluación del RMSE en el dominio angular del PID vs Controlador RL Fase2, plataforma plana. Fuente: Elaboración propia. Enlace. 16
Fig. 18. Evaluación del RMSE en el dominio angular del PID vs Controlador RL Fase2, plataforma inclinada, pitch= roll= -10°. Fuente: Elaboración propia. Enlace. 17

1 Resultados en Fase 3

En esta fase se presentan los resultados obtenidos tras el desarrollo progresivo del agente de aprendizaje por refuerzo mediante un esquema de curriculum learning, en el cual múltiples agentes fueron entrenados y evaluados de forma iterativa. Este proceso se lleva a cabo manteniendo el mismo entorno de simulación definido en la Fase 2, garantizando así la coherencia en la evaluación y la comparabilidad de los resultados.

El objetivo principal de esta etapa es desarrollar y consolidar una política de control robusta, superando las limitaciones identificadas previamente, mediante la evolución de la función de recompensa hacia una formulación más completa.

Para ello, se introduce la función de recompensa A (Fig. 1), que incorpora no solo el error de seguimiento, sino también términos asociados a la velocidad angular y al esfuerzo de control, permitiendo guiar al agente hacia un comportamiento más estable y físicamente coherente. El Entorno del Agente RL es el mismo como en la fase 2 (**Error! Reference source not found.**), sin ningún otro cambio.

Como resultado de este proceso, se identifica el Agent500 como el candidato óptimo para el cierre de la Fase 3, al evidenciar un mejor equilibrio entre precisión, estabilidad y robustez en el seguimiento angular.

De este modo, el Agent500 representa la consolidación del aprendizaje alcanzado y se adopta como la política base para las siguientes etapas del estudio.

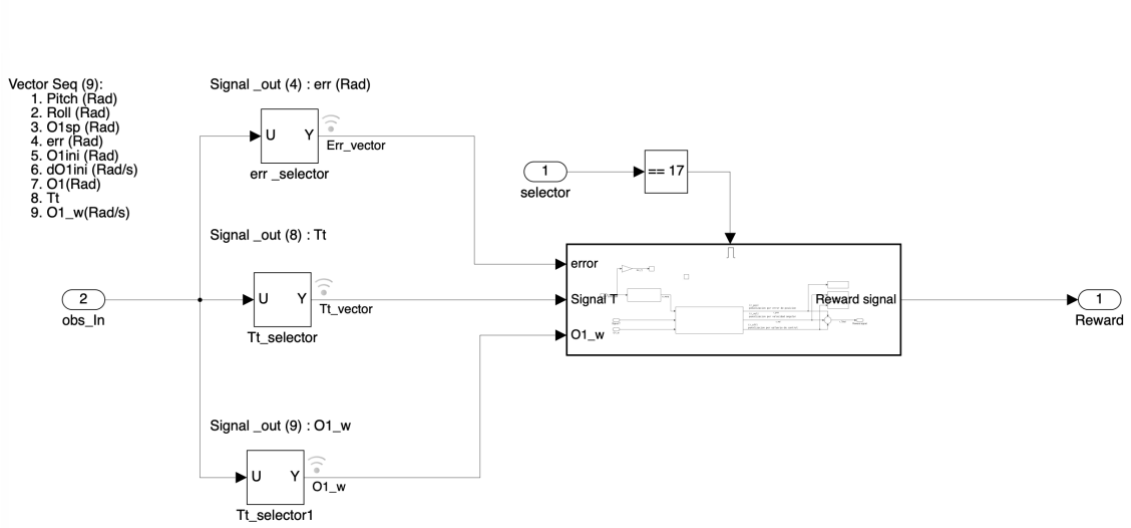

Fig. 1. Función de recompensa (Reward_systemA) en fase 3. Fuente: Elaboración propia. Enlace.

1.1.1 Entrenamiento del agente RL

En esta etapa se lleva a cabo el proceso de entrenamiento del agente de aprendizaje por refuerzo. El propósito es analizar la capacidad del agente para adquirir una política de control que reduzca la desviación angular y permita un seguimiento estable de la referencia a lo largo del dominio operativo.

La evolución del retorno por episodio (Fig. 2) refleja una transición desde un comportamiento inicial altamente variable hacia una zona de operación más consistente, en la que los valores se estabilizan aproximadamente en el intervalo −400 a −350. Esta tendencia se ve acompañada por una mayor coherencia en la recompensa media, lo que indica que el agente va consolidando una política de control más regular a lo largo del entrenamiento. La Tabla 1 recoge las métricas obtenidas y los hiperparámetros asociados a este proceso.

A pesar de esta estabilización, se identifican descensos abruptos en episodios aislados, evidenciando la persistencia de comportamientos no deseados bajo determinadas condiciones del entorno, propios de sistemas continuos con exploración.

En términos globales, la dinámica de la curva sugiere que el aprendizaje converge hacia un régimen estable; sin embargo, la ausencia de mejoras sostenidas en las últimas etapas apunta a una limitación en la capacidad de refinamiento adicional del agente.

Fig. 2. Curva de aprendizaje recompensa vs episodio del agente RL, fase 3. Fuente: Elaboración propia. Enlace

Tabla 1. Métricas e hiperparámetros del agente RL, fase3 durante el entrenamiento. Fuente: propia

Training Stats			**Advanced Agent Options**		
Métrica	Símbolo	Valor	Métrica	Símbolo	Valor
Total de episodios	N_{ep}	1000	Tiempo muestreo	T_s	0.01
Recompensa total último episodio	R_{ep}	-406.147	Factor descuento	γ	0.99
Recompensa Media	$\bar{R}$	-352.339	Tamaño del Batchize	B	64
Pasos último episodio	-	600	Tamaño del Exp. Buffer		10000
Número total de pasos	N_{steps}	600000	Modo del Buffer	-	Reset
Promedio pasos/eps	-	600	Taza aprendizaje actor	α_a	1.0000e-04
Valor Q estimado	Q_0	-263.797	Optimizador del actor	-	adam
			Taza aprendizaje critico	α_c	0.001
			Optimizador del critico	-	adam
			Coeficiente actualización suave	τ	0.005

Exploration Gaussian Model			**Target Policy Smoothing**		
Métrica	Símbolo	Valor	Métrica	Símbolo	Valor
Std.Dev	σ	0.3162	Std.Dev	σ	0.2
Mean	μ	0	Mean	μ	0
Lower Lim	-	-0.5	Lower Lim	-	-0.5
Upper Lim	-	0.5	Upper Lim	-	0.5
Std.Dev decay	λ_σ	1.9187e-06	Std.Dev decay	λ_σ	0
Std.Dev min	σ_{min}	0.1	Std.Dev min	σ_{min}	0.2

La Fig. 3 presenta la evolución del RMSE global a lo largo de los checkpoints de entrenamiento. Se observa una mejora progresiva hasta alcanzar su valor mínimo en el episodio 500, lo que indica el punto óptimo de desempeño del agente en esta fase.

A partir de este punto, el error aumenta de forma notable en los siguientes checkpoints, evidenciando una degradación de la política posiblemente asociada a sobreajuste o pérdida de generalización. En los últimos episodios, el comportamiento tiende nuevamente hacia valores cercanos a la media, sin recuperar el nivel óptimo alcanzado previamente.

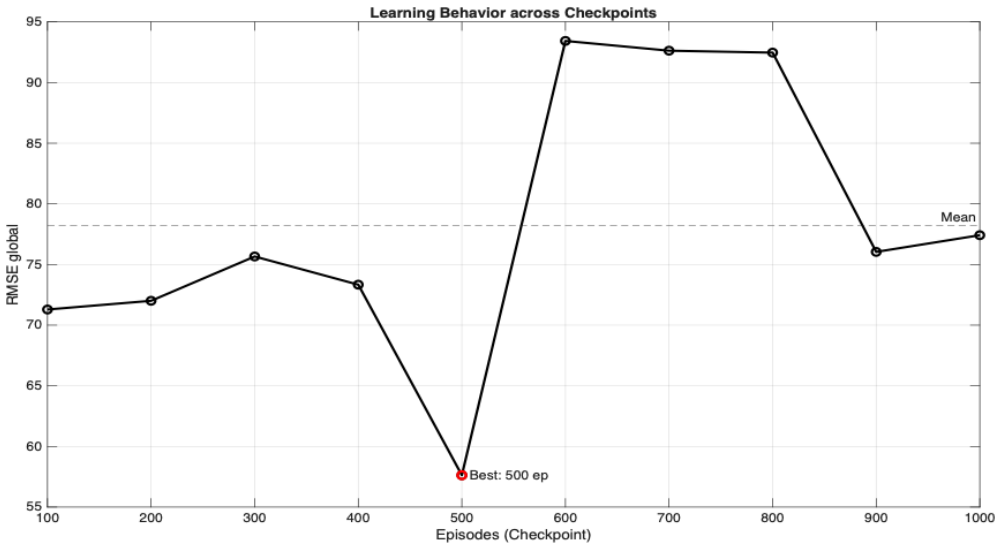

Fig. 3. Evolución del RMSE global a lo largo de los checkpoints de entrenamiento. Fuente: Elaboración propia. Enlace.

La Tabla 2 confirma que Agent500 es el mejor agente global, mientras que los agentes más entrenados presentan mayor error y menor estabilidad, evidenciando degradación del aprendizaje.

Tabla 2. Tabla de evaluación y selección del agente basada en métricas de desempeño. Fuente: Elaboración propia

Position	Agente	$RMSE_{global}$	$RMSE_{max}$	$\sigma_{angular}$	$Ratio_{ext}$	AUC
1	Agent500.mat	31.8768	67.5612	19.5546	2.1194	30.2252
2	Agent100.mat	32.1803	69.5560	21.8054	2.1614	30.5703
3	Agent200.mat	33.2539	69.7003	20.5150	2.0960	31.6975
4	Agent400.mat	34.4669	69.6161	19.0805	2.0198	32.9844
5	Agent900.mat	35.8842	69.5453	17.6581	1.9380	34.5013
6	Agent300.mat	36.8039	69.6267	17.0374	1.8918	35.4449
7	Agent1000.mat	38.5345	69.7105	16.2425	1.8090	37.2744
8	Agent700.mat	40.4853	75.5817	17.5543	1.8669	39.3504
9	Agent600.mat	40.6800	71.7127	17.5065	1.7629	39.5563
10	Agent800.mat	41.4784	71.6549	17.5960	1.7275	40.3722

La Fig. 4 muestra la evolución del RMSE a lo largo del dominio angular para los tres mejores checkpoints del agente RL. Se observa un comportamiento continuo con una forma característica en “U”, donde el error alcanza valores mínimos en la región central (≈ 10–13° en torno a 0°) y aumenta progresivamente hacia los extremos.

En las zonas de ±150° a ±180°, el RMSE se incrementa hasta valores de ≈ 63–70°, evidenciando una degradación significativa respecto a la región central. Este incremento se produce de forma gradual, sin saltos abruptos, lo que indica una transición suave en el desempeño del agente a lo largo del dominio angular.

Las diferencias entre los checkpoints son reducidas en la zona central (≈ 2–4°), pero se amplifican en los extremos (hasta ≈ 5–10°), donde algunos agentes presentan un mejor comportamiento relativo. En conjunto, los resultados evidencian una capacidad de generalización consistente, aunque con limitaciones en los extremos del dominio.

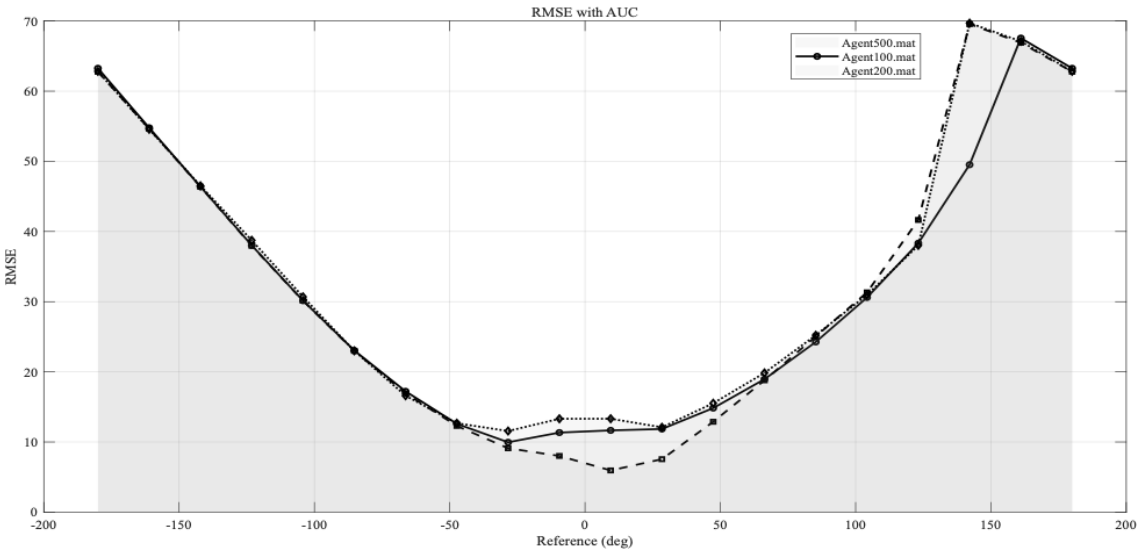

Fig. 4. Comparación del RMSE angular de los mejores 3 checkpoints del agente RL. Fuente: Elaboración propia. Enlace.

En consecuencia, se adopta el Agent500 como la política de control seleccionada para continuar con las siguientes evaluaciones en modo determinista, integrándolo en el modelo para su validación final.

1.1.2 Evaluación del controlador RL en plataforma plana

En este escenario se evalúa el comportamiento del agente frente a variaciones en la condición inicial $o1_{ini} \in \{-90°, 0°, 90°\}$, manteniendo el resto de las perturbaciones desactivadas. El objetivo es analizar la sensibilidad del controlador ante diferentes estados iniciales dentro del dominio angular.

La Fig. 5 muestra que el RMSE presenta una dependencia clara con la condición inicial, modificando la forma de la curva a lo largo del dominio. No obstante, a diferencia de fases anteriores, la respuesta se mantiene continua y acotada, sin evidencias de inestabilidad severa.

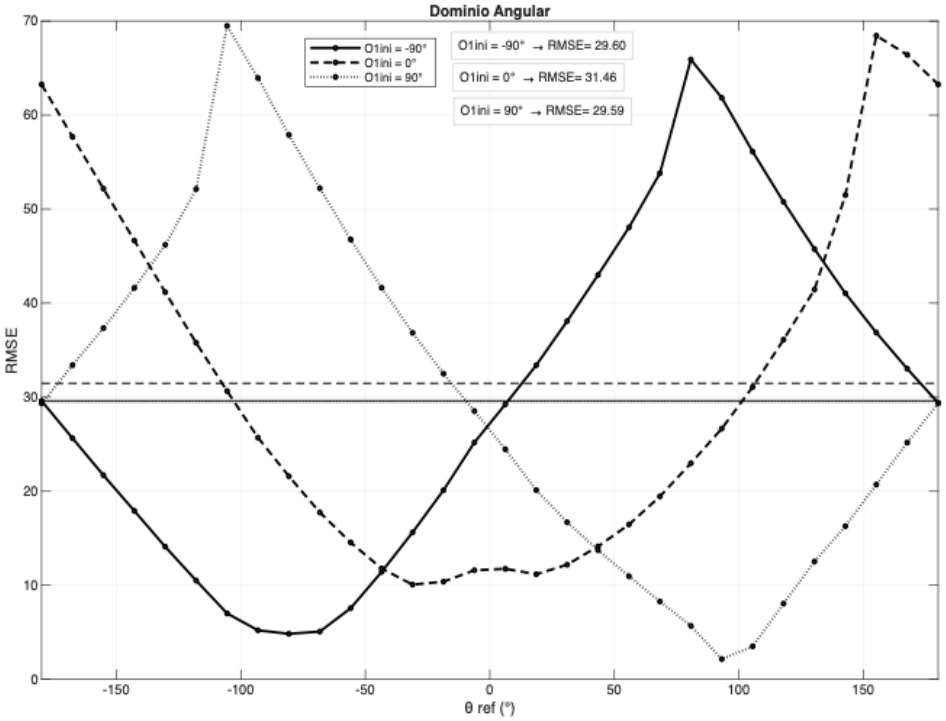

Fig. 5. Evaluación del RMSE en el dominio angular bajo variación del ángulo inicial o1ini, plataforma plana. Fuente: Elaboración propia. Enlace.

En la evaluación temporal para $o1_{sp} = 45°$, el sistema logra converger hacia los casos analizados, pero sin alcanzar la referencia (persiste un error en estado estable). Se observan diferencias en la dinámica de convergencia: las condiciones iniciales más alejadas requieren mayores esfuerzos de control y presentan transitorios más prolongados.

La Fig. 6 confirma este comportamiento, donde el caso $o1_{ini} = -90°$ presenta el mayor error global (RMSE = 43.63°) y mayor demanda energética, mientras que condiciones iniciales más cercanas a la referencia mantienen un desempeño más eficiente.

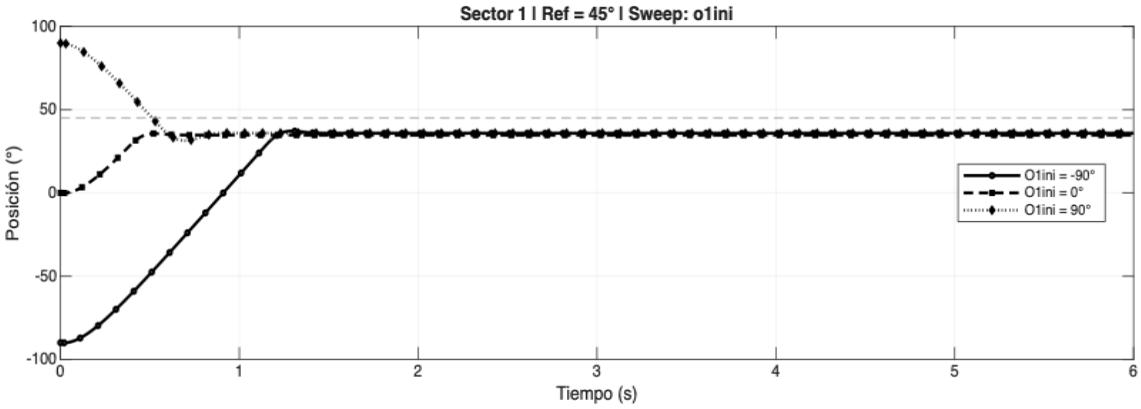

Fig. 6. Respuesta temporal del sistema ante variaciones del ángulo inicial de operación en plataforma plana. Fuente: Elaboración propia. Enlace

En conjunto, el agente demuestra robustez frente a variaciones en la condición inicial, aunque con una penalización en rendimiento para estados iniciales extremos, lo cual es consistente con la naturaleza no lineal del sistema.

La Fig. 7 muestra que la forma del RMSE se mantiene prácticamente inalterada en todo el dominio angular, evidenciando que el retardo no afecta la estructura del comportamiento. No obstante, se observa una penalización ligera y uniforme del error a medida que aumenta el retardo.

En la respuesta temporal ($o1_{sp} = 45°$) (véase Fig. 8), el sistema conserva la estabilidad y convergencia, presentando únicamente pequeños incrementos en el sobreimpulso y el esfuerzo de control.

En conjunto, el agente demuestra robustez frente a retardos moderados, sin pérdida de estabilidad.

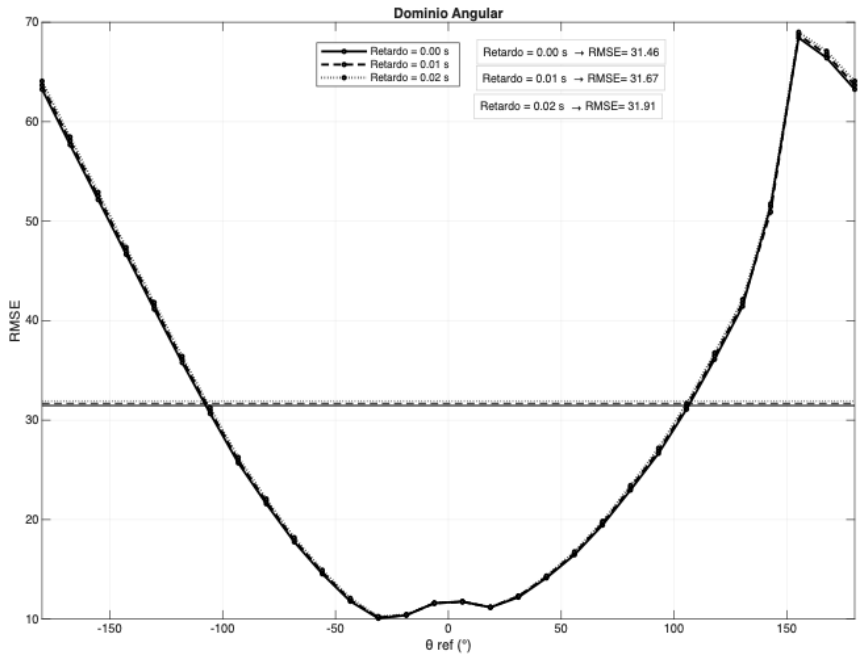

Fig. 7. Evaluación del RMSE en el dominio angular bajo variación retardo de señal. Fuente: Elaboración propia. *Enlace.*

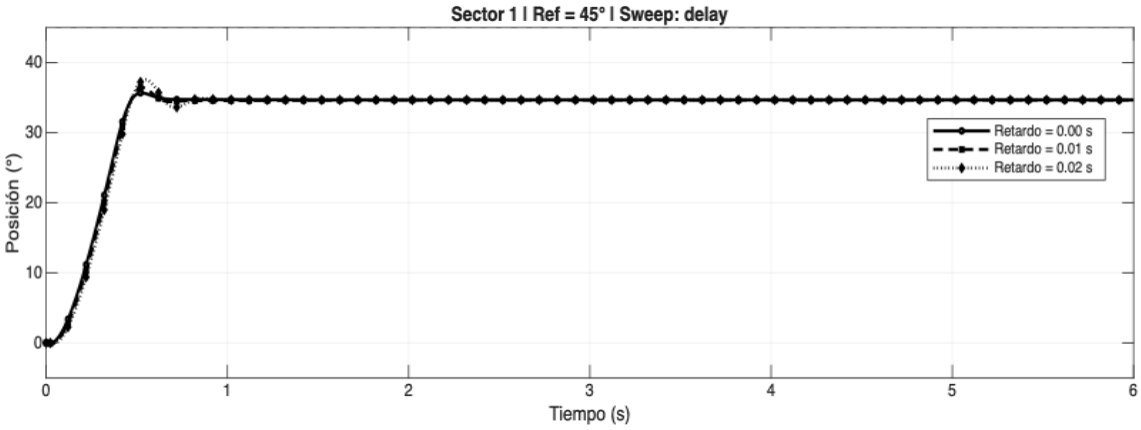

Fig. 8. Respuesta temporal del sistema ante variaciones de retardo en el lazo de control. Fuente: Elaboración propía. Enlace.

La velocidad angular inicial $do1_{ini}$ introduce una distorsión moderada en el RMSE (Fig. 9), manteniendo la forma global del perfil pero con pérdida parcial de simetría, especialmente en los extremos del dominio angular.

Se observa que la curva conserva continuidad, aunque con desplazamientos dependientes del signo y magnitud de la velocidad inicial, lo que evidencia una dependencia dinámica del agente respecto al estado inicial.

En el respuesta temporal ($o1_{sp} = 45°$) (Fig. 10), el sistema mantiene la convergencia en todos los casos, pero presenta variaciones en el transitorio, principalmente en el sobreimpulso y el esfuerzo de control.

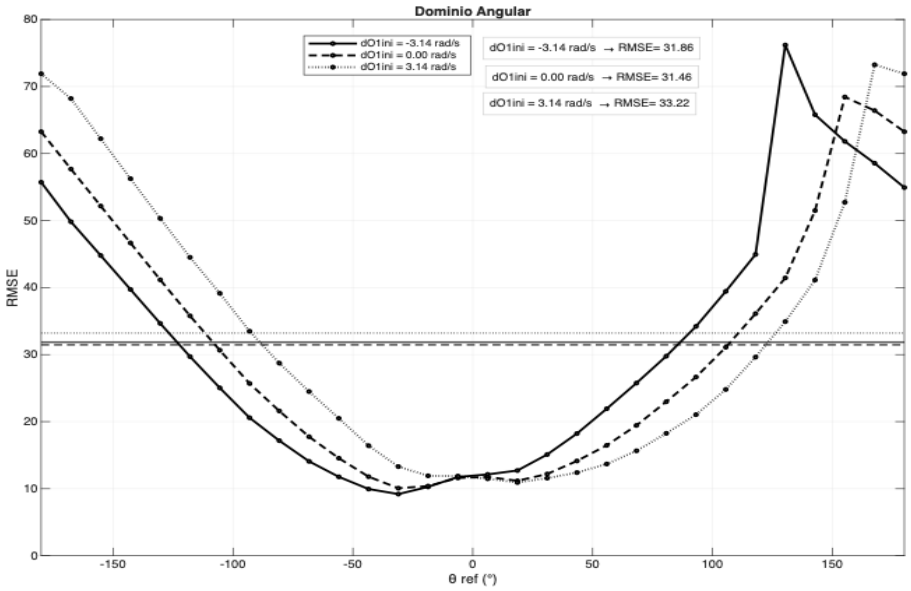

Fig. 9. Evaluación del RMSE en el dominio angular bajo variación de la velocidad angular inicial do1ini, plataforma plana. Fuente: Elaboración propia. Enlace.

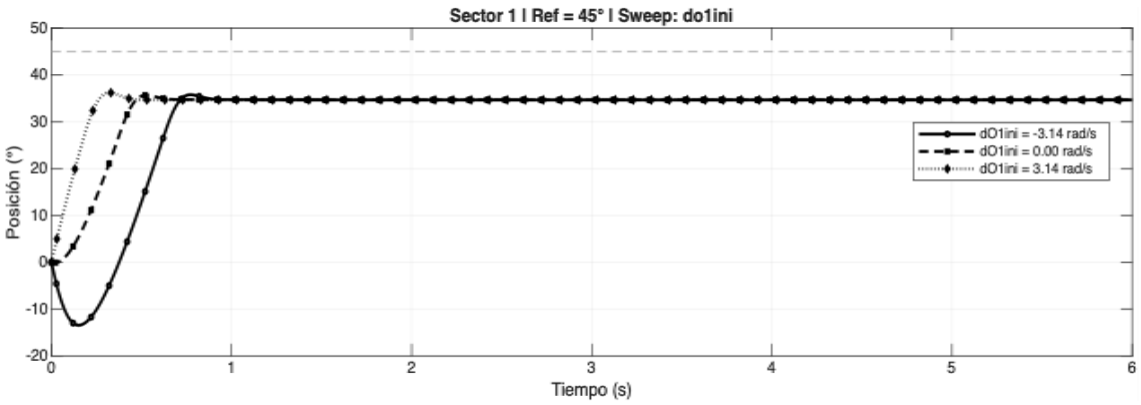

Fig. 10. Respuesta temporal del sistema ante variaciones de la velocidad angular inicialen plataforma plana. Fuente: Elaboración propia. Enlace.

En plataforma plana, el agente presenta un desempeño global estable, manteniendo continuidad en el dominio angular. Sin embargo, se evidencia sensibilidad a las condiciones iniciales, principalmente en el régimen transitorio, lo que introduce variaciones en el error sin comprometer la convergencia.

1.1.3 Evaluación del controlador RL en plataforma inclinada

La introducción de una inclinación (Pitch, Roll = −10°) incorpora un efecto gravitacional constante que modifica la dinámica del sistema, incrementando la exigencia de control y poniendo a prueba la capacidad de generalización del agente.

En el dominio angular (Fig. 11), el agente mantiene continuidad, pero presenta pérdida de simetría y distorsiones no uniformes, con valores de RMSE ≈ 28.55° (−90°), 31.50° (0°) y 31.50° (90°), evidenciando una penalización respecto al caso plano.

En el dominio temporal ($o1_{sp} = 45°$) (véase Fig. 12), el sistema converge en condiciones nominales (RMSE ≈ 13.03° – 13.27°), pero muestra degradación significativa en estados extremos, alcanzando RMSE ≈ 46.09° y un incremento notable del esfuerzo de control (U_rms ≈ 156.81).

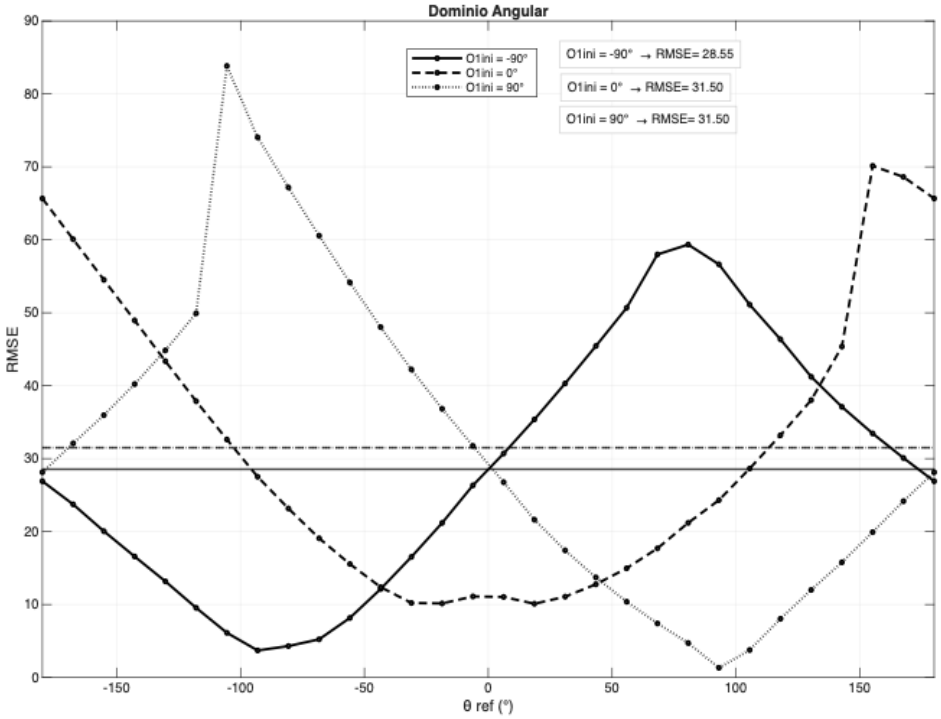

Fig. 11. Evaluación del RMSE en el dominio angular bajo variación del ángulo inicial o1ini, plataforma inclinada Pitch=Roll=-10°. Fuente: Elaboración propia. Enlace.

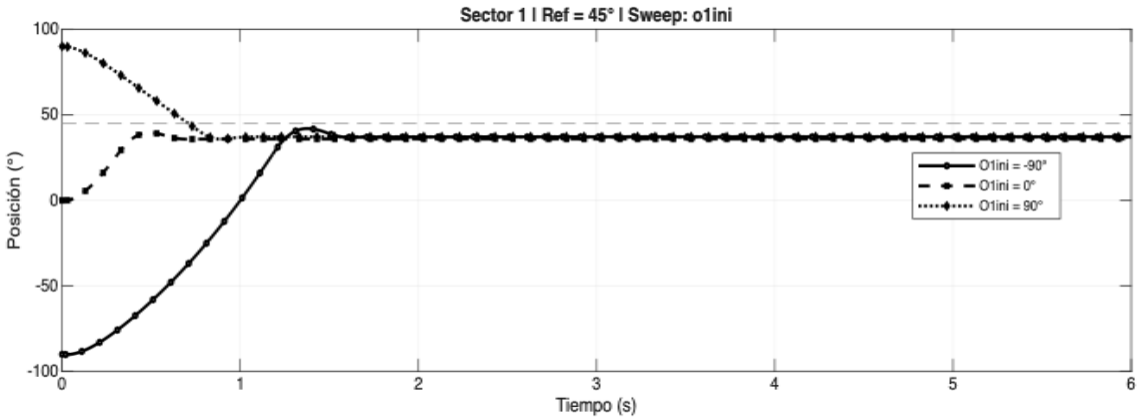

Fig. 12. Respuesta temporal del sistema ante variaciones del ángulo inicial de operación en plataforma inclinada pitch=roll= -10. Fuente: Elaboración propia. Enlace.

Bajo plataforma inclinada, la variación del retardo (0, 10, 20)ms no modifica la estructura del RMSE en el dominio angular, manteniéndose la misma forma global de la curva (Fig. 14). No obstante, se observa una penalización ligera y homogénea del error, con un RMSE medio que aumenta de 31.50° a 31.98°. En la respuesta temporal (Fig. 15), el agente conserva la estabilidad y la convergencia hacia la referencia, presentando únicamente una degradación moderada del régimen transitorio, con incrementos leves en el RMSE y en el esfuerzo de control.

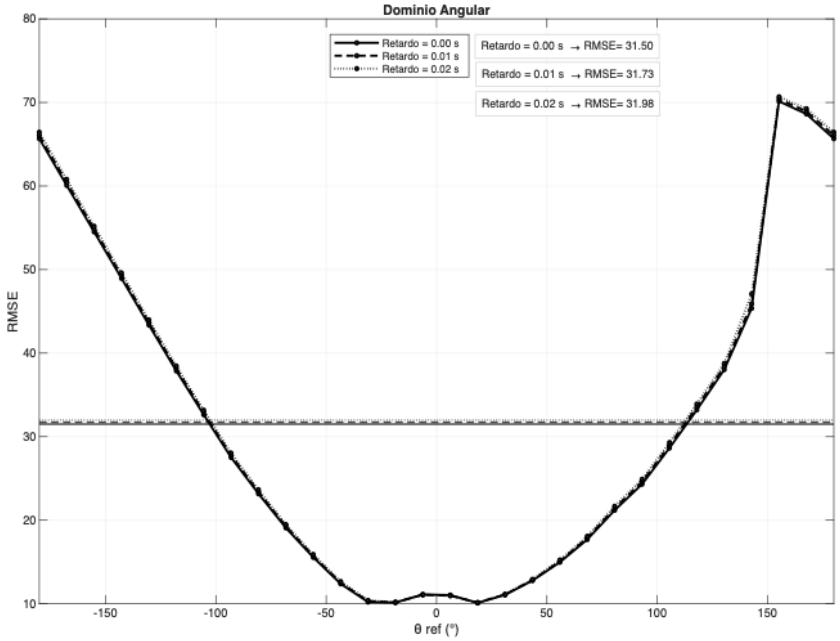

Fig. 13. Evaluación del RMSE en el dominio angular bajo variación retardo de señal en plataforma inclinada, pitch=roll= -10°. Fuente: Elaboración propia. Enlace.

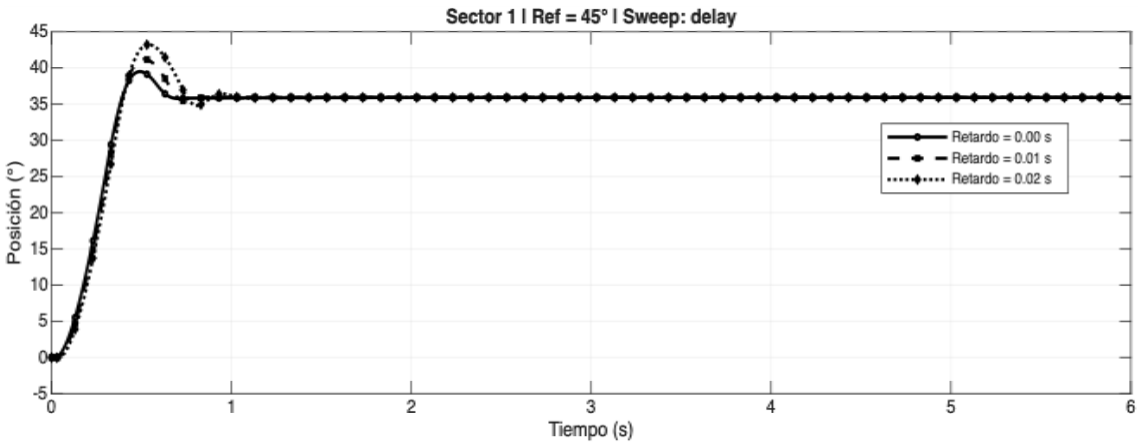

Fig. 14. Respuesta temporal del sistema ante retardo en el lazo de control en plataforma inclinada pitch=roll= -10. Fuente: Elaboración propia. Enlace.

La velocidad angular inicial, en plataforma inclinada, mantiene la continuidad del RMSE pero introduce pérdida de simetría y dependencia del signo, alcanzando valores de hasta 34.97° frente a 30.31°–31.50° en condiciones nominales (Fig. 15). Esto evidencia sensibilidad del agente al estado dinámico inicial bajo carga gravitacional.

En la respuesta temporal (véase Fig. 16), el sistema conserva la convergencia, pero el transitorio se degrada, con variaciones en el RMSE (11.43°–16.82°) y en el esfuerzo de control. El error estacionario permanece estable, indicando robustez en régimen permanente pero limitaciones en adaptación dinámica.

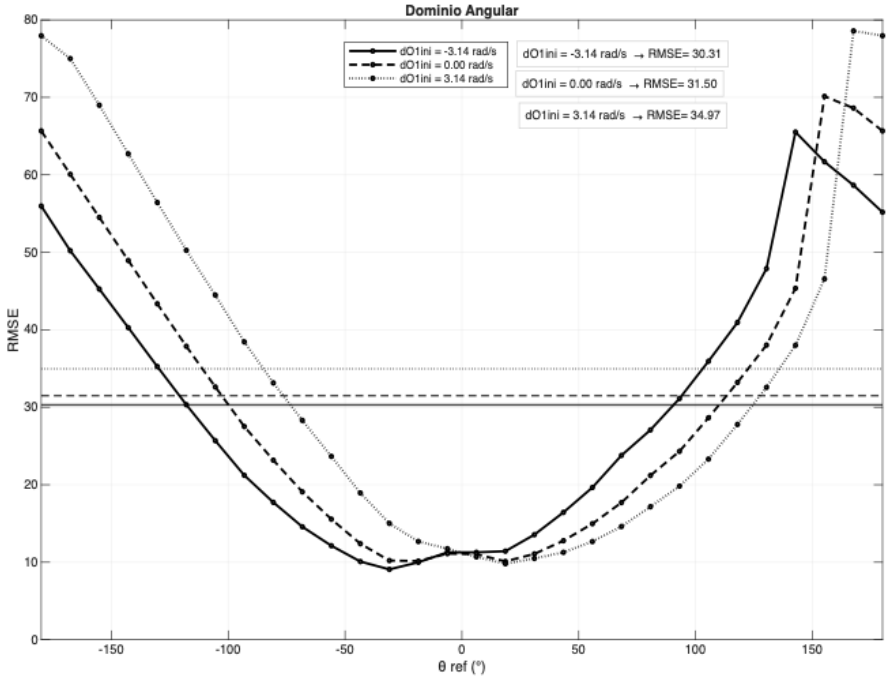

Fig. 15. Evaluación del RMSE en el dominio angular bajo variación de la velocidad angular inicial do1ini, plataforma inclinada pitch=roll=-10°. Fuente: Elaboración propia. Enlace.

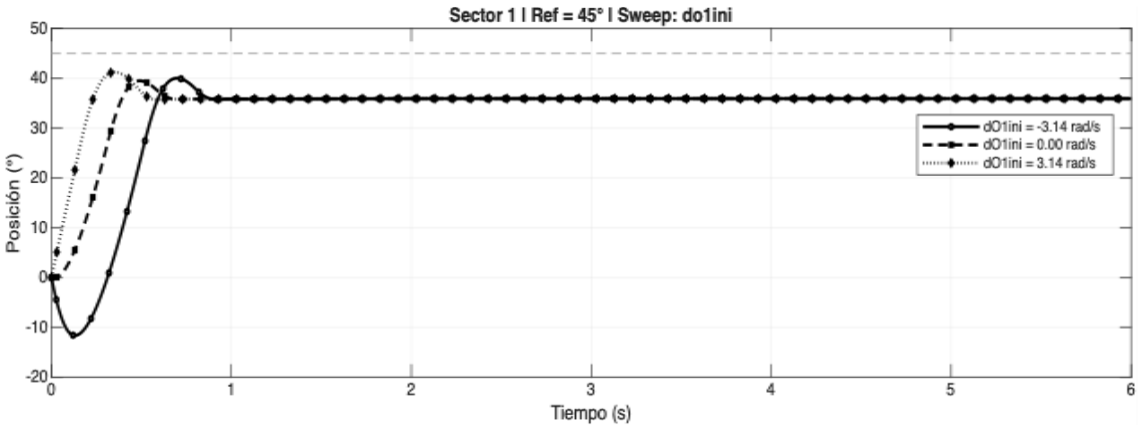

Fig. 16. Respuesta temporal del sistema ante variaciones de la velocidad angular inicialen plataforma incliada pitch=roll=-10°. Fuente: Elaboración propia. Enlace.

En resumen, bajo condiciones de plataforma inclinada, el agente conserva la continuidad del comportamiento en el dominio angular, aunque con una clara pérdida de simetría y un incremento del error global respecto al caso plano. El retardo de señal mantiene un efecto marginal, introduciendo únicamente una penalización leve y uniforme, sin alterar la estructura del RMSE.

En contraste, las condiciones iniciales —particularmente la velocidad angular— afectan de forma significativa el desempeño del agente. Se observan distorsiones en el dominio angular y degradaciones en el régimen transitorio,

reflejadas en incrementos del RMSE y del esfuerzo de control. Estos resultados evidencian que, si bien el agente es estable, presenta limitaciones en su capacidad de generalización ante variaciones dinámicas bajo la influencia de la gravedad.

1.1.4 Comparación PID vs controlador RL fase3

En Fase 3, el agente basado en aprendizaje por refuerzo muestra una mejora sustancial respecto a etapas anteriores, reduciendo la diferencia de desempeño frente al controlador PID. En plataforma plana (Fig. 17), ambos controladores presentan un comportamiento prácticamente equivalente, con valores de RMSE cercanos a 31°, lo que indica que el agente ha logrado capturar adecuadamente la dinámica nominal del sistema.

Bajo condiciones de plataforma inclinada (Fig. 18), el comportamiento del agente RL resulta especialmente relevante, ya que mantiene un RMSE de aproximadamente 31.5°, mientras que el PID incrementa su error hasta 40.5°. Este resultado evidencia una mayor capacidad de adaptación del controlador RL ante perturbaciones estructurales como la influencia gravitacional. No obstante, el PID sigue mostrando una respuesta más suave y predecible, mientras que el RL, aunque más adaptable, aún presenta variaciones locales asociadas a las condiciones iniciales.

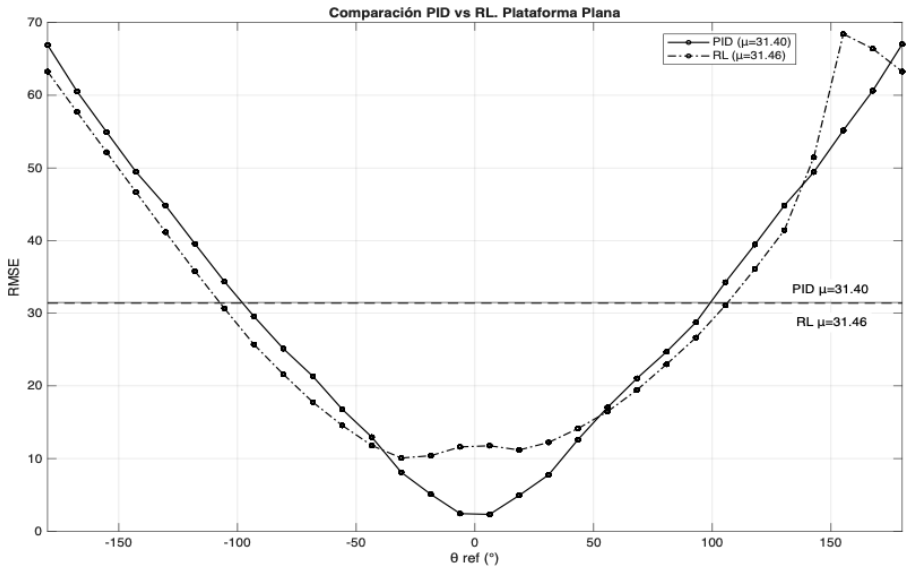

Fig. 17. Evaluación del RMSE en el dominio angular del PID vs Controlador RL Fase2, plataforma plana. Fuente: Elaboración propia. Enlace.

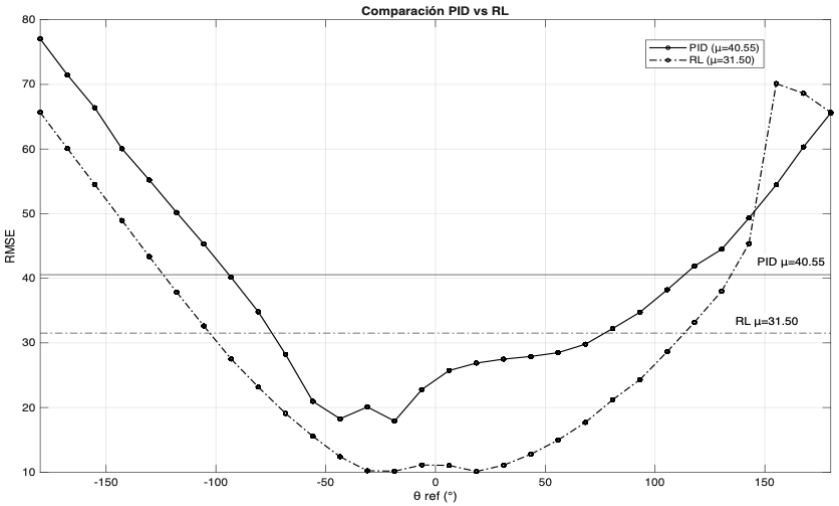

Fig. 18. Evaluación del RMSE en el dominio angular del PID vs Controlador RL Fase2, plataforma inclinada, pitch= roll= -10°. Fuente: Elaboración propia. Enlace.

1.1.5 Conclusión Fase 3

La Fase 3 demuestra que el controlador basado en aprendizaje por refuerzo ha alcanzado un desempeño competitivo frente al PID, tal como se observa en la Tabla 3.

En plataforma plana, ambos controladores presentan un comportamiento equivalente, con un RMSE medio cercano a 31–32°, mostrando una respuesta continua y estable en la mayor parte del dominio angular.

Bajo condiciones perturbadas, como la plataforma inclinada y variaciones en el estado inicial, el agente RL mantiene un RMSE en torno a 31–32°, mientras que el PID incrementa su error hasta aproximadamente 40–41°, lo que evidencia una mayor robustez del controlador RL frente a cambios en la dinámica del sistema. Asimismo, el agente presenta una respuesta consistente ante variaciones en el ángulo y la velocidad angular inicial, con valores de RMSE generalmente contenidos en el rango 30–34°, reflejando una mejora significativa en capacidad de generalización respecto a la fase anterior.

No obstante, persiste una limitación localizada en el rango angular alto (≈ +150° a +180°), donde se observa un incremento del error. A pesar de ello, el desempeño global es sólido, por lo que se selecciona el agente como la mejor política de la fase, al ofrecer un adecuado equilibrio entre precisión, estabilidad y robustez.

Tabla 3. Métricas de seguimiento (RMSE) y esfuerzo de control (U_ernergy) del agente RL en Fase 3. Fuente: Elaboración propi. Enlace.

	Seguimiento		Esfuerzo	
	Plataforma plana [RMSE]	**Plataforma Inclinada [RMSE]**	**Plataforma plana [U_energy]**	**Plataforma Inclinada [U_energy]**
Retardo=0ms	31.72	31.78	31.28	43.68
Retardo=0.01ms	32.02	32.03	37.07	46.90
Reatardo=0.02ms	32.18	32.25	63.07	65.63
o1ini=-90°	30.40	29.25	29.57	41.45
o1ini= 0°	31.72	31.78	31.28	43.88
o1ini=90°	30.16	31.91	34.22	53.75
do1ini = -0.5rad/s	31.07	30.36	29.48	40.94
do1ini = 0rad/s	31.72	31.78	31.28	43.88
do1ini = 0.5rad/s	33.72	34.37	33.07	47.58

Referencias Bibliográficas

Achiam, J. (Jan de 2026). *https://spinningup.openai.com/en/latest/algorithms/td3.html*. Obtenido de SpinningUp OpenAI: https://spinningup.openai.com/en/latest/algorithms/td3.html

Dankwa, S., & Wenfeng, Z. (2019). Twin-Delayed DDPG: A Deep Reinforcement Learning Technique to Model a Continuous Movement of an Intelligent Robot Agent. *ICVISP 2019, Proceedings of the 3rd International Conference on Vision, Image and Signal Processing*.

Fujimoto, S., Van Hoof, H., & Meger, D. (2018). *Addressing Function Approximation Error in Actor-Critic Methods.* Stockholm, Sweden: PMLR (Proceedings of Machine Learning Research).

Gamal, Z., Mahran, Y., & El-Badawy, A. (2024). *Control of a Twin Rotor using Twin Delayed Deep Deterministic Policy Gradient (TD3).* Egypt: 28th International Conference on System Theory, Control and Computing (ICSTCC).

García, J. M., Medina, I. J., Martinez, J. L., García-Cerezo, A., Linares, A., & Porras, C. (2017). *Lázaro: Robot Móvil dotado de Brazo para Contacto con el Suelo.*

García, J. M., Medina, I., Cerezo, A. G., & Linares, A. (2015). Improving The Static Stability Of A Mobile Manipulator Using Its End Effector In Contact With The Ground. 3228-3234.

García, J., Bohórquez, A., & Valero, A. (2020). Suspension Effect in Tip-Over Stability and Steerability of Robots Moving on Sloping Terrains. *IEEE LATIN AMERICA TRANSACTIONS*, 1381-1389.

Hazem, Z. B., Saidi, F., Guler, N., & Altaif, A. H. (2025). A Hybrid Reinforcement Learning Framework Combining TD3 and PID Control for Robust Trajectory Tracking of a 5-DOF Robotic Arm. *automation*.

Khoi, P. B., Giang, N. T., & Tan, H. V. (2021). Control and Simulation of a 6-DOF Biped Robot based on Twin Delayed Deep Deterministic Policy Gradient Algorithm. *Indian journal of Science and Technology*.

Kim, M., Han, D.-K., Park, J.-H., & Kim, J.-S. (2020). Motion Planning of Robot Manipulators for a Smoother Path Using a Twin Delayed Deep Deterministic Policy Gradient with Hindsight Experience Replay. *Applied Science*, 10,575.

Li, H. (2024). *Machine Learning Methods.* Quanzhou, China: Springer.

Lunze, J. (2014). *Regelungstechnik 1 . Systemtheoretische Grundlangen, Analyse und Entwurfe einschleifiger Regelung.* Berlin: Springer Vieweg.

M., G. J., L., M. J., A., M., & A., G.-C. (2017). Caster-legaidedmaneuverfornegotiatingsurfacediscontinuities withawheeledskid-steermobilerobot. *RoboticsandAutonomousSystems*, 25-37.

M., H. (2019). *Grundlagen der Robotik.* Berlin: VDE Verlag.

Mahran, Y., Gamal, Z., & El-Badawy, A. (2024). *Reinforcement Learning Position Control of a Quadrotor Using Soft Actor-Critic (SAC).* Egypt: publication in the IEEE 6th Novel Intelligent and Leading Emerging Sciences Conference (NILES).

Martínez, J. L., Mandow, A., & García-Cerezo, A. (2017). Slide-Down Prevention for Wheeled Mobile Robots on Slopes. *ACM*.

MatlabWorks. (Januar de 2026). *Reinforcement Learning Toolbox*. Obtenido de MATLAB Hilfe-Center: https://de.mathworks.com/help/reinforcement-learning/index.html?utm_source=chatgpt.com

Mosali, N. A., Shamsudin, S. S., & Omar Alfandi, R. O.-F. (2022). Twin Delayed Deep Deterministic Policy Gradient-Based Target Tracking for Unmanned Aerial Vehicle With Achievement Rewarding and Multistage Training. *IEEE Access*.

OpenAI. (26 de 01 de 2026). *Spinning Up in Deep Reinforcement Learning: DDPG*. Obtenido de OpenAI: https://spinningup.openai.com/en/latest/algorithms/ddpg.html#the-q-learning-side-of-ddpg

Plaat, A. (2022). *Deep Reinforcement Learnig.* Netherlands: Springer.

Sutton, R. S., & Barto, A. G. (2018). *Reinforcement Learning.* London, England: The MIT Press.

Wittpahl, V. (2019). *Künstliche Intelligenz, technologie, Anwendung, Gesellschaft.* Berlin: Springer Verlag.

2 Anexos

https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia

2.1 Modo en el Entrenamiento

Modos en el Entrenamiento: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/InformacionGeneral/MetodosEntrenamiento.pdf*

2.2 Evaluación en las fases

Evaluación en las fases: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/InformacionGeneral/MetodologiaEvaluacion.pdf*

2.3 Proceso de Decision de Markov (MDP)

Proceso de Decision de Markov (MDP): [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/InformacionGeneral/El%20Proceso%20de%20Decisión%20de%20Markov%20(MDP).pdf*

2.4 Vector de observaciones

Bus Vector de Observaciones: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/ArquitecturaAgente/Observacion/BusVectorObservacion.pdf*

Observables: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/ArquitecturaAgente/Observacion/Observation.pdf*

2.5 Anexo Bufferlength

Bufferlength: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/InformacionGeneral/EvaluacionImpactoBufferlength.pdf*

2.6 Warm-Start Steps

Warm-start Steps: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/InformacionGeneral/EvaluacionImpactoWarmStartSteps.pdf*

2.7 Anexo policy Exploration Gaussian

Exploracion Gaussiana: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/InformacionGeneral/EvaluacionImpactoPolicyExplorationGaussian.pdf*

2.8 Anexo Learning Rate Actor Critic

Taza de Aprendizaje: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/InformacionGeneral/EvaluacionImpactoLearningRate.pdf*

2.9 Anexo Mini Batchsize

Minie Batchsize: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/InformacionGeneral/EvaluacionImpactoBatchsize.pdf*

2.10 TD3 Redes Neuronales

Redes Neuronales TD3: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/ArquitecturaAgente/05_Redes/RedesActorCritico.pdf*

2.11 Función de Recompensa

Función de Recompensa: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/tree/main/ArquitecturaAgente/03_FuncionRecompensas*

Función de Recompensa Sistema A: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/ArquitecturaAgente/03_FuncionRecompensas/Reward_System_A.pdf*

Función de Recompensa Sistema D: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/ArquitecturaAgente/03_FuncionRecompensas/Reward_System_D.pdf*

Función de Recompensa Sistema F: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/ArquitecturaAgente/03_FuncionRecompensas/Reward_System_F.pdf*

2.12 Anexo Resultados

Fase 1:

Fase 1 plataforma plana: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase1/03_results/Evaluación%20PID–%20Plataforma%20plana%20%20.pdf*

Fase 1 plataforma inclinada: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase1/03_results/Evaluación%20PID–%20Plataforma%20Inclinada.pdf*

Fase1 tabla de resultados: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase1/03_results/TablaResultadosFase1.pdf*

Fase 2:

Fase 2 Entrenamiento: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase2/03_results/EvaluacionEntrenamiento.pdf*

Fase 2 plataforma plana: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase2/03_results/EvaluacionAgenteRL_F2–%20Plataforma%20plana%20%20.pdf*

Fase 2 plataforma inclinada: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase2/03_results/EvaluacionAgenteRL_F2–%20Plataforma%20Inclinada.pdf*

Fase 2 Tabla de resultados: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase2/03_results/TablaResultadosFase2.pdf*

Fase 2 Comparación PID vs RL: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase2/03_results/ComparacionPID_vs_RL_F2.pdf*

Fase 3:

Fase 3 Entrenamiento: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase3/03_results/EvaluacionEntrenamiento.pdf*

Fase 3 plataforma plana: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase3/03_results/Evaluación%20AgenteRL_F3–%20Plataforma%20plana%20%20.pdf*

Fase 3 plataforma inclinada: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase3/03_results/Evaluación%20AgenteRL_F3–%20Plataforma%20Inclinada.pdf*

Fase 3 Tabla de resultados: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase2/03_results/TablaResultadosFase2.pdf*

Fase 3 Comparación PID vs RL: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase3/03_results/ComparacionPID_vs_RL_F3.pdf*

Fase 4A:

Fase 4A Entrenamiento: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase4/03_results/FaseA/EvaluacionEntrenamientoFaseA_Agente600.pdf*

Fase 4A plataforma plana: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase4/03_results/Evaluación%20AgenteRL_F4A_Agente600–%20Plataformaplana.pdf*

Fase 4A plataforma inclinada: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase4/03_results/FaseA/Evaluación%20AgenteRL_F4A_Agente600–Plataformainclinada.pdf*

Fase 4A Tabla de resultados: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase4/03_results/TablaResultadosFase4A.pdf*

Fase 4A Comparación PID vs RL: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase4/03_results/FaseA/ComparacionPID_vs_RL_F4A_Agente600.pdf*

Fase 4B:

Fase 4B Entrenamiento: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase4/03_results/FaseB/EvaluacionEntrenamientoFaseB_Agente1900.pdf*

Fase 4B plataforma plana: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase4/03_results/FaseB/Evaluación%20AgenteRL_F4B_Agente1900–Plataformaplana.pdf*

Fase 4B plataforma inclinada: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase4/03_results/FaseB/Evaluación%20AgenteRL_F4B_Agente1900–Plataformainclinada.pdf*

Fase 4B Tabla de resultados: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase4/03_results/FaseB/TablaResultadosFase4B.pdf*

Fase 4B Comparación PID vs RL: [Enlace] *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase4/03_results/FaseB/ComparacionPID_vs_RL_F4B_Agente1900.pdf*

Fase 4C:

Fase 4C Entrenamiento: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase4/03_results/FaseC/EvaluacionEntrenamientoFaseC_Agente300.pdf*

Fase 4C plataforma plana: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase4/03_results/FaseC/Evaluación%20AgenteRL_F4C_Agente300–Plataformaplana.pdf*

Fase 4C plataforma inclinada: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase4/03_results/FaseC/Evaluación%20AgenteRL_F4C_Agente300–Plataformainclinada.pdf*

Fase 4C Tabla de resultados: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase4/03_results/FaseC/TablaResultadosFase4C.pdf*

Fase 4C Comparación PID vs RL: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase4/03_results/FaseC/ComparacionPID_vs_RL_F4C_Agente300.pdf*

Fase 5:

Fase 5 plataforma plana: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase5/03_results/Evaluación%20AgenteRL_F5_Politica_Plataformaplana.pdf*

Fase 5 plataforma inclinada: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase5/03_results/Evaluación%20AgenteRL_F5_Politica_Plataformainclinada.pdf*

Fase 5 Tabla de Resultados: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase5/03_results/TablaResultadosFase5.pdf*

Fase 5 Comparación PID vs política neuronal: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase5/03_results/ComparacionPID_vs_Politica_F5.pdf*