Control Monoarticular aplicado en manipuladores móviles utilizando aprendizaje por refuerzo

Universidad Internacional de Valencia

Titulación:

Máster Inteligencia Artificial
Curso académico

2025-2026

Alumno/a:

Sarabia Palacio
Ricardo Enrique

D.N.I: LFTG8GWZ6

Director/a de TFM:
García Caicedo
Jesús Marcey

Convocatoria:

Regular

De:
Planeta Formación y Universidades

Universidad Internacional de Valencia

Índice

1 Resultados en Fase 4 6
1.1 Resultados Fase A Base Tracking 6
1.1.1 Entrenamiento del agente RL 6
1.1.2 Evaluación del controlador RL en plataforma plana 11
1.1.3 Evaluación del controlador RL en plataforma inclinada 15
1.1.4 Comparación PID vs Controlador RL Fase 4A 18
1.1.5 Conclusión Fase 4A 19
1.2 Resultados Fase 4B Horizont Break 20
1.2.1 Entrenamiento del agente RL 20
1.2.2 Evaluación del controlador RL en Plataforma Plana 24
1.2.3 Evaluación del controlador RL en plataforma inclinada 28
1.2.4 Comparación PID vs controlador RL Fase 4B 32
1.2.5 Conclusión Fase 4B 33
1.3 Resultados Fase 4C Lázaro Ascencion 34
1.3.1 Entrenamiento del agente RL 34
1.3.2 Evaluación del controlador RL en Plataforma Plana 38
1.3.3 Evaluación del controlador RL en plataforma inclinada 43
1.3.4 Comparación PID vs controlador RL Fase 4C 46
1.3.5 Conclusión Fase 4C 47
1.4 Conclusión Fase 4 48
Referencias Bibliográficas 50
2 Anexos 52
2.1 Modo en el Entrenamiento 52
2.2 Evaluación en las fases 52
2.3 Proceso de Decision de Markov (MDP) 52
2.4 Vector de observaciones 52
2.5 Anexo Bufferlength 52
2.6 Warm-Start Steps 52
2.7 Anexo policy Exploration Gaussian 53
2.8 Anexo Learning Rate Actor Critic 53
2.9 Anexo Mini Batchsize 53
2.10 TD3 Redes Neuronales 53
2.11 Función de Recompensa 53
2.12 Anexo Resultados 54

Universidad Internacional de Valencia

Índice de ilustraciones

Fig. 1. Estrategia de entrenamiento progresivo mediante Curriculum Learning y evolución de agentes, Fase 4A. Fuente: Elaboración propia. Enlace. 6
Fig. 2. Curva de aprendizaje recompensa vs episodio del agente RL, fase 4A. Fuente: Elaboración propia. Enlace 7
Fig. 3. Evolución del RMSE global a lo largo de los checkpoints de entrenamiento. Fuente: Elaboración propia. Enlace. 9
Fig. 4. Comparación del RMSE angular de los mejores 3 checkpoints del agente RL. Fuente: Elaboración propia. Enlace. 10
Fig. 5. Evaluación del RMSE en el dominio angular bajo variación del ángulo inicial o1ini, plataforma plana. Fuente: Elaboración propia. Enlace. 11
Fig. 6. Respuesta temporal del sistema ante variaciones del ángulo inicial de operación en plataforma plana, Sector 1. Fuente: Elaboración propia. Enlace. 11
Fig. 7. Respuesta temporal del sistema ante variaciones del ángulo inicial de operación en plataforma plana, Sector 2. Fuente: Elaboración propia. Enlace. 12
Fig. 8. Respuesta temporal del sistema ante variaciones del ángulo inicial de operación en plataforma plana, Sector 3. Fuente: Elaboración propia. Enlace. 12
Fig. 9. Respuesta temporal del sistema ante variaciones del ángulo inicial de operación en plataforma plana, Sector 4. Fuente: Elaboración propia. Enlace. 12
Fig. 10. Evaluación del RMSE en el dominio angular bajo variación retardo de señal. Fuente: Elaboración propia. Enlace. 13
Fig. 11. Respuesta temporal del sistema ante variaciones de retardo en el lazo de control. Fuente: Elaboración propia. Enlace. 13
Fig. 12. Evaluación del RMSE en el dominio angular bajo variación de la velocidad angular inicial do1ini, plataforma plana. Fuente: Elaboración propia. Enlace. 14
Fig. 13. Respuesta temporal del sistema ante variaciones de la velocidad angular inicialen plataforma plana. Fuen-te: Elaboración propia. Enlace. 14
Fig. 14. Evaluación del RMSE en el dominio angular bajo variación retardo de señal en plataforma inclinada, pitch=roll= -10°. Fuente: Elaboración propia. Enlace. 15
Fig. 15. Respuesta temporal del sistema ante variaciones del ángulo inicial de operación en plataforma inclinada pitch=roll= -10. Fuente: Elaboración propia. Enlace. 16
Fig. 16. Evaluación del RMSE en el dominio angular bajo variación retardo de señal en plataforma inclinada, pitch=roll= -10°. Fuente: Elaboración propia. Enlace. 16
Fig. 17. Respuesta temporal del sistema ante retardo en el lazo de control en plataforma inclinada pitch=roll= -10. Fuente: Elaboración propia. Enlace. 17
Fig. 18. Evaluación del RMSE en el dominio angular bajo variación de la velocidad angular inicial do1ini, plataforma inclinada pitch=roll=-10°. Fuente: Elaboración propia. Enlace. 17
Fig. 19. Respuesta temporal del sistema ante variaciones de la velocidad angular inicialen plataforma inclinada pitch=roll=-10°. Fuente: Elaboración propia. Enlace. ... 18
Fig. 20. Evaluación del RMSE en el dominio angular del PID vs Controlador RL Fase4A, plataforma plana. Fuente: Elaboración propia. Enlace. 19
Fig. 21. Evaluación del RMSE en el dominio angular del PID vs Controlador RL Fase4A, plataforma inclinada, pitch= roll= -10°. Fuente: Elaboración propia. Enlace.. 19

Fig. 22. Estrategia de entrenamiento progresivo mediante Curriculum Learning y evolución de agentes, Fase4B. Fuente: Elaboración propia. Enlace. 20
Fig. 23. Curva de aprendizaje recompensa vs episodio del agente RL, fase 4B. Fuente: Elaboración propia. Enlace. 21
Fig. 24. Evolución del RMSE global a lo largo de los checkpoints de entrenamiento. Fuente: Elaboración propia. Enlace. 22
Fig. 25. Comparación del RMSE angular de los mejores 3 checkpoints del agente RL. Fuente: Elaboración propia. Enlace. 23
Fig. 26. Evaluación del RMSE en el dominio angular bajo variación del ángulo inicial o1ini, plataforma plana. Fuente: Elaboración propia. Enlace. 24
Fig. 27. Respuesta temporal del sistema ante variaciones del ángulo inicial de operación en plataforma plana, Sector 1. Fuente: Elaboración propia. Enlace. 25
Fig. 28. Respuesta temporal del sistema ante variaciones del ángulo inicial de operación en plataforma plana, Sector 2. Fuente: Elaboración propia. Enlace. 25
Fig. 29. Respuesta temporal del sistema ante variaciones del ángulo inicial de operación en plataforma plana, Sector 3.. Fuente: Elaboración propia. Enlace. 25
Fig. 30. Respuesta temporal del sistema ante variaciones del ángulo inicial de operación en plataforma plana, Sector 4. Fuente: Elaboración propia. Enlace. 26
Fig. 31. Evaluación del RMSE en el dominio angular bajo variación retardo de señal. Fuente: Elaboración propia. Enlace. 26
Fig. 32. Respuesta temporal del sistema ante variaciones de retardo en el lazo de control. Fuente: Elaboración propia. Enlace. 27
Fig. 33. Evaluación del RMSE en el dominio angular bajo variación de la velocidad angular inicial do1ini, plataforma plana. Fuente: Elaboración propia. Enlace 27
Fig. 34. Respuesta temporal del sistema ante variaciones de la velocidad angular inicialen plataforma plana. Fuen-te: Elaboración propia. Enlace 28
Fig. 35. Evaluación del RMSE en el dominio angular bajo variación retardo de señal en plataforma inclinada, pitch=roll= -10°. Fuente: Elaboración propia. Enlace. 29
Fig. 36. Respuesta temporal del sistema ante variaciones del ángulo inicial de operación en plataforma inclinada pitch=roll= -10. Fuente: Elaboración propia. Enlace. 29
Fig. 37. Evaluación del RMSE en el dominio angular bajo variación retardo de señal en plataforma inclinada, pitch=roll= -10°. Fuente: Elaboración propia. Enlace. 30
Fig. 38. Respuesta temporal del sistema ante retardo en el lazo de control en plataforma inclinada pitch=roll= -10. Fuente: Elaboración propia. Enlace. 30
Fig. 39. Evaluación del RMSE en el dominio angular bajo variación de la velocidad angular inicial do1ini, plataforma inclinada pitch=roll=-10°. Fuente: Elaboración propia. Enlace. 31
Fig. 40. Respuesta temporal del sistema ante variaciones de la velocidad angular inicialen plataforma inclinada pitch=roll=-10°. Fuente: Elaboración propia. Enlace. ... 32
Fig. 41. Evaluación del RMSE en el dominio angular del PID vs Controlador RL Fase4B, plataforma plana. Fuente: Elaboración propia. Enlace. 32
Fig. 42. Evaluación del RMSE en el dominio angular del PID vs Controlador RL Fase4B, plataforma inclinada, pitch= roll= -10°. Fuente: Elaboración propia. Enlace.. 33
Fig. 43. Estrategia de entrenamiento progresivo mediante Curriculum Learning y evolución de agentes, Fase4B. Fuente: Elaboración propia. Enlace. 35
Fig. 44. Curva de aprendizaje recompensa vs episodio del agente RL, fase 4C. Fuente: Elaboración propia. Enlace. 35

Fig. 45. Evolución del RMSE global a lo largo de los checkpoints de entrenamiento. Fuente: Elaboración propia. Enlace. 37
Fig. 46. Comparación del RMSE angular de los mejores 3 checkpoints del agente RL. Fuente: Elaboración propia. Enlace. 38
Fig. 47. Evaluación del RMSE en el dominio angular bajo variación del ángulo inicial o1ini, plataforma plana. Fuente: Elaboración propia. Enlace. 39
Fig. 48. Respuesta temporal del sistema ante variaciones del ángulo inicial de operación en plataforma plana, Sector 1. Fuente: Elaboración propia. Enlace. 40
Fig. 49. Respuesta temporal del sistema ante variaciones del ángulo inicial de operación en plataforma plana, Sector 2. Fuente: Elaboración propia. Enlace. 40
Fig. 50. Respuesta temporal del sistema ante variaciones del ángulo inicial de operación en plataforma plana, Sector 3. Fuente: Elaboración propia. Enlace. 40
Fig. 51. Respuesta temporal del sistema ante variaciones del ángulo inicial de operación en plataforma plana, Sector 4. Fuente: Elaboración propia. Enlace. 41
Fig. 52. Evaluación del RMSE en el dominio angular bajo variación retardo de señal. Fuente: Elaboración propia. Enlace. 41
Fig. 53. Respuesta temporal del sistema ante variaciones de retardo en el lazo de control. Fuente: Elaboración propia. Enlace. 42
Fig. 54. Evaluación del RMSE en el dominio angular bajo variación de la velocidad angular inicial do1ini, plataforma plana. Fuente: Elaboración propia. Enlace. 42
Fig. 55. Respuesta temporal del sistema ante variaciones de la velocidad angular inicialen plataforma plana. Fuen-te: Elaboración propia. Enlace. 43
Fig. 56. Evaluación del RMSE en el dominio angular bajo variación retardo de señal en plataforma inclinada, pitch=roll= -10°. Fuente: Elaboración propia. Enlace. 43
Fig. 57. Respuesta temporal del sistema ante variaciones del ángulo inicial de operación en plataforma inclinada pitch=roll= -10. Fuente: Elaboración propia. Enlace. 44
Fig. 58. Evaluación del RMSE en el dominio angular bajo variación retardo de señal en plataforma inclinada, pitch=roll= -10°. Fuente: Elaboración propia. Enlace. 44
Fig. 59. Respuesta temporal del sistema ante retardo en el lazo de control en plataforma inclinada pitch=roll= -10. Fuente: Elaboración propia. Enlace. 45
Fig. 60. Evaluación del RMSE en el dominio angular bajo variación de la velocidad angular inicial do1ini, plataforma inclinada pitch=roll=-10°. Fuente: Elaboración propia. Enlace. 45
Fig. 61. Respuesta temporal del sistema ante variaciones de la velocidad angular inicialen plataforma inclinada pitch=roll=-10°. Fuente: Elaboración propia. Enlace. ... 46
Fig. 62. Evaluación del RMSE en el dominio angular del PID vs Controlador RL Fase4C, plataforma plana. Fuente: Elaboración propia. Enlace. 47
Fig. 63. Evaluación del RMSE en el dominio angular del PID vs Controlador RL Fase4C, plataforma inclinada, pitch= roll= -10°. Fuente: Elaboración propia. Enlace. . 47

1 Resultados en Fase 4

La Fase 4 introduce una estrategia de aprendizaje progresivo (Curriculum Learning) con el objetivo de mejorar la capacidad de generalización del agente en todo el dominio operativo. A diferencia de las fases anteriores, donde el entrenamiento se realizaba bajo condiciones más directas, en esta etapa el agente se expone de forma gradual a escenarios de creciente complejidad, permitiendo una adquisición más estructurada de la política de control.

Este enfoque busca consolidar el conocimiento previamente adquirido y, al mismo tiempo, evitar problemas de inestabilidad o sobreajuste local, favoreciendo una generalización más robusta frente a perturbaciones simultáneas (referencia, inclinación y condiciones iniciales).

1.1 Resultados Fase A Base Tracking

La Fase A constituye el punto de partida del curriculum y se centra en la estabilización del control en condiciones ideales. En esta etapa, el agente se entrena sobre una plataforma plana (pitch = 0°, roll = 0°) con variaciones controladas de la referencia angular, permitiendo aprender la dinámica base del sistema sin perturbaciones externas. El objetivo principal es que el agente desarrolle un seguimiento preciso y estable de la referencia, estableciendo así una base sólida sobre la cual se introducirán progresivamente condiciones más complejas en las siguientes fases.

1.1.1 Entrenamiento del agente RL

En la Fig. 1 se presenta seguimiento del entrenamiento donde se muestra la evolución progresiva de los agentes a través de los entrenamientos. En el enlace asociado a esta figura se encuentra disponible toda la información relevante del proceso, incluyendo parámetros, configuraciones y resultados intermedios de cada etapa.

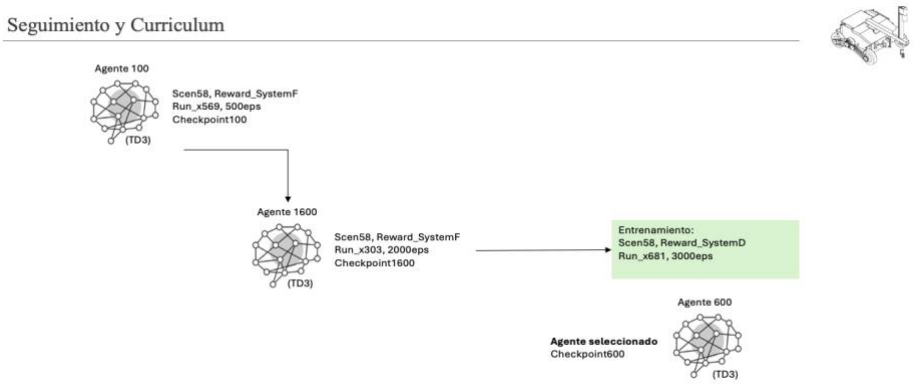

Fig. 1. Estrategia de entrenamiento progresivo mediante Curriculum Learning y evolución de agentes, Fase 4A. Fuente: Elaboración propia. Enlace.

La evolución del entrenamiento (véase Fig. 2) muestra una rápida estabilización del retorno acumulado en valores cercanos a −150, lo que indica que el agente adquiere de forma temprana un comportamiento de control consistente. La recompensa promedio presenta una tendencia estable, reflejando la convergencia del aprendizaje.

No obstante, se observan caídas puntuales del retorno asociadas a episodios con respuestas inestables o exploración, evidenciando que, aunque la política es funcional, aún presenta sensibilidad ante ciertas condiciones del entorno. La Tabla 1 resume las métricas e hiperparámetros empleados durante el entrenamiento.

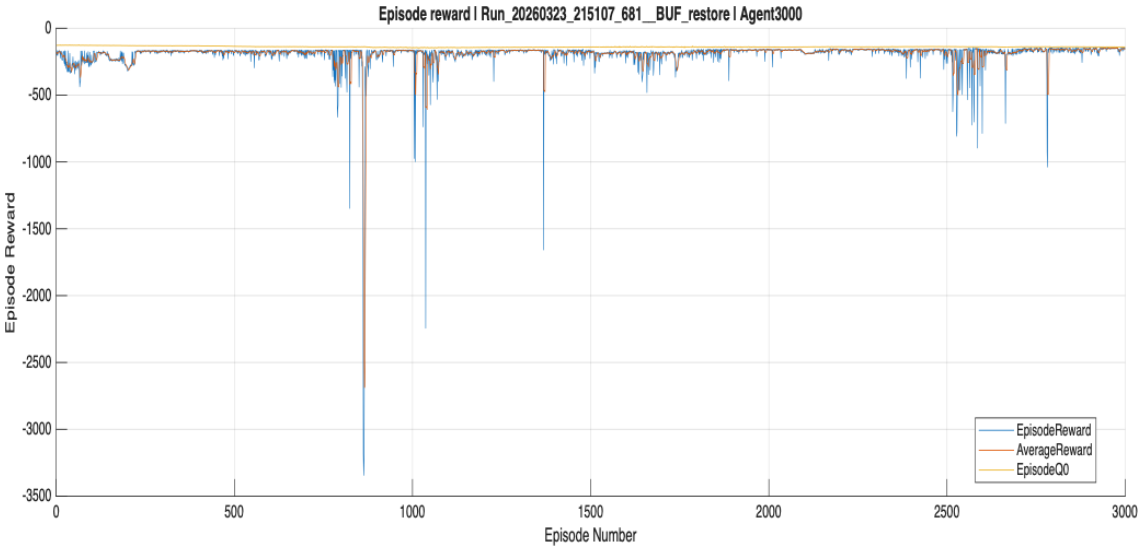

Fig. 2. Curva de aprendizaje recompensa vs episodio del agente RL, fase 4A. Fuente: Elaboración propia. Enlace

Tabla 1. Métricas e hiperparámetros del agente RL, fase4A durante el entrenamiento. Fuente: propia

Training Stats			**Advanced Agent Options**		
Métrica	Símbolo	Valor	Métrica	Símbolo	Valor
Total de episodios	N_{ep}	3000	Tiempo muestreo	T_s	0.01
Recompensa total último episodio	R_{ep}	-153.928	Factor descuento	γ	0.99
Recompensa Media	$\bar{R}$	-151.869	Tamaño del Batchize	B	256
Pasos último episodio	-	600	Tamaño del Exp. Buffer		400000
Número total de pasos	N_{steps}	1.8e+06	Modo del Buffer	-	Reset
Promedio pasos/eps	-	600	Taza aprendizaje actor	α_a	1.0000e-04
Valor Q estimado	Q_0	-140.123	Optimizador del actor	-	adam
			Taza aprendizaje critico	α_c	0.007
			Optimizador del critico	-	adam
			Coeficiente actualización suave	τ	0.005

Exploration Gaussian Model			**Target Policy Smoothing**		
Métrica	Símbolo	Valor	Métrica	Símbolo	Valor
Std.Dev	σ	0.2	Std.Dev	σ	0.2
Mean	μ	0	Mean	μ	0
Lower Lim	-	-0.5	Lower Lim	-	-0.5
Upper Lim	-	0.5	Upper Lim	-	0.5
Std.Dev decay	λ_σ	3.8508e-07	Std.Dev decay	λ_σ	0
Std.Dev min	σ_{min}	0.1	Std.Dev min	σ_{min}	0.2

La Fig. 3 muestra la evolución del RMSE global a lo largo de los checkpoints de entrenamiento. El error presenta variaciones significativas en fases tempranas, con valores entre ≈ 30° y ≈ 39°. A partir de ~1000 episodios, el comportamiento se estabiliza en torno a ≈ 30°–32°, con una media cercana a ≈ 33.5°.

El mejor desempeño se alcanza en el checkpoint de 600 episodios, con un RMSE mínimo de ≈ 29.4°, seleccionado como agente final. En etapas posteriores (>2000 episodios) se observa una degradación progresiva, con incrementos del RMSE hasta ≈ 41°.

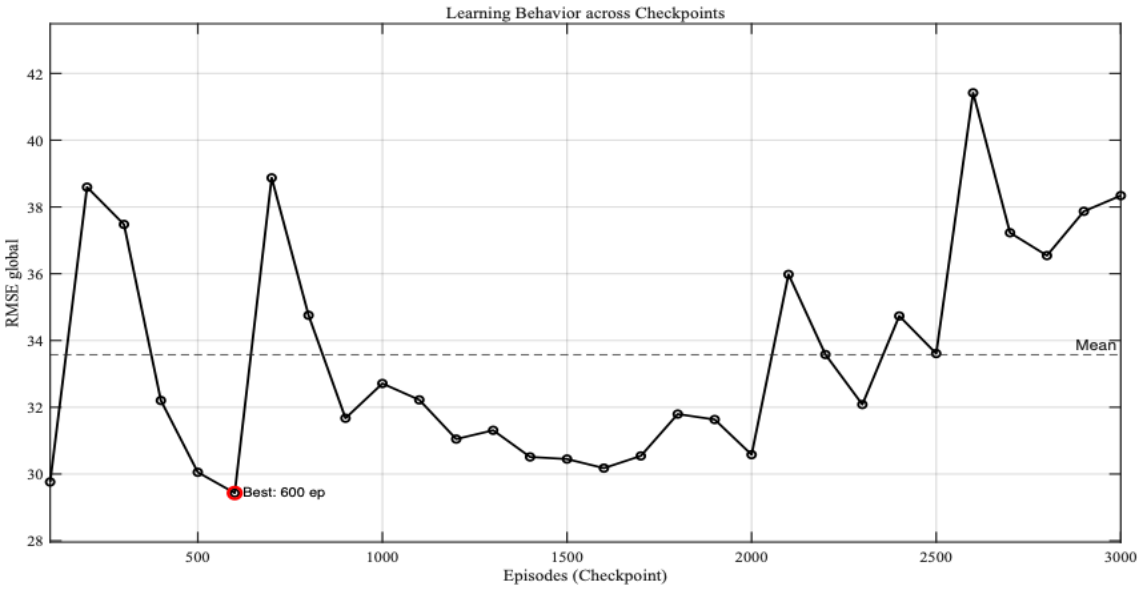

Fig. 3. Evolución del RMSE global a lo largo de los checkpoints de entrenamiento. Fuente: Elaboración propia. Enlace.

La Tabla 2 resume la evaluación comparativa de los principales checkpoints según métricas de desempeño. El agente Agent600 se posiciona como el mejor candidato, con el menor RMSE_global (29.43°) y el menor AUC (27.50), indicando un mejor comportamiento global en todo el dominio angular.

Aunque Agent500.mat presenta un RMSE_max inferior (63.71°) y menor dispersión (σ_angular ≈ 19.28°), su error medio y AUC son superiores. De forma similar, Agent100.mat muestra un rendimiento cercano (RMSE_global ≈ 29.76°), pero con peor AUC (27.85).

En conjunto, Agent600 ofrece el mejor compromiso entre precisión global, estabilidad y comportamiento en extremos, por lo que se selecciona como agente final para la evaluación en simulación.

Tabla 2. Tabla de evaluación y selección del agente basada en métricas de desempeño. Fuente: Elaboración propia

Position	Agente	$RMSE_{global}$	$RMSE_{max}$	$\sigma_{angular}$	$Ratio_{ext}$	AUC
1	Agent600.mat	29.4306	66.1160	20.7105	2.2465	27.5001
2	Agent100.mat	29.7619	66.4583	20.7880	2.2330	27.8482
3	Agent500.mat	30.0520	63.7054	19.2808	2.1198	28.2809
4	Agent1600.mat	30.1761	63.9606	19.7550	2.1196	28.4268
5	Agent1500.mat	30.4479	62.8607	19.4954	2.0645	28.7420
6	Agent1400.mat	30.5116	68.3393	21.5078	2.2398	28.5412
7	Agent1700.mat	30.5417	64.2228	19.4280	2.1028	28.7690
8	Agent2000.mat	30.5797	63.7484	19.5204	2.0847	28.8340
9	Agent1200.mat	31.0465	62.9055	18.2170	2.0262	29.3892
10	Agent1300.mat	31.3092	65.9519	21.0994	2.1065	29.4860

La Fig. 4 compara el RMSE angular de los tres mejores checkpoints seleccionados. Los tres agentes presentan un comportamiento similar, con una forma en “U” y valores mínimos en la región central (≈ 2°–5°), aumentando progresivamente hacia los extremos (≈ 65°–67° en ±180°).

El agente Agent600 muestra el menor error en la zona central y una ligera ventaja global respecto a Agent100 y Agent500, manteniendo una curva más uniforme en todo el dominio. Por su parte, Agent500 presenta menores valores en algunos extremos, pero con mayor error medio, mientras que Agent100 mantiene un comportamiento intermedio. En resumen las diferencias son reducidas, pero consistentes con la Tabla 6, confirmando la selección de Agent600 como el agente con mejor desempeño global.

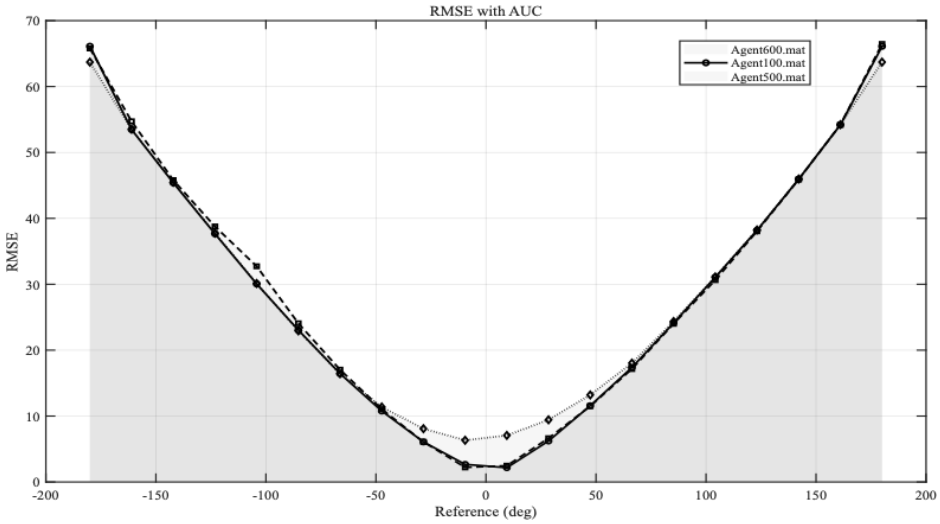

Fig. 4. Comparación del RMSE angular de los mejores 3 checkpoints del agente RL. Fuente: Elaboración propia.
Enlace.

1.1.2 Evaluación del controlador RL en plataforma plana

A continuación, se procede con el análisis del agente resultante en condiciones de plataforma plana, evaluando de forma intensiva su desempeño a partir de los resultados temporales obtenidos.

En la Fig. 5 (dominio angular), se observa que el entrenamiento intensivo sobre el estado inicial (o1ini) en plataforma plana reduce el RMSE global, pero introduce una degradación en la política global, evidenciada por desviaciones significativas en los sectores 2 y 3.

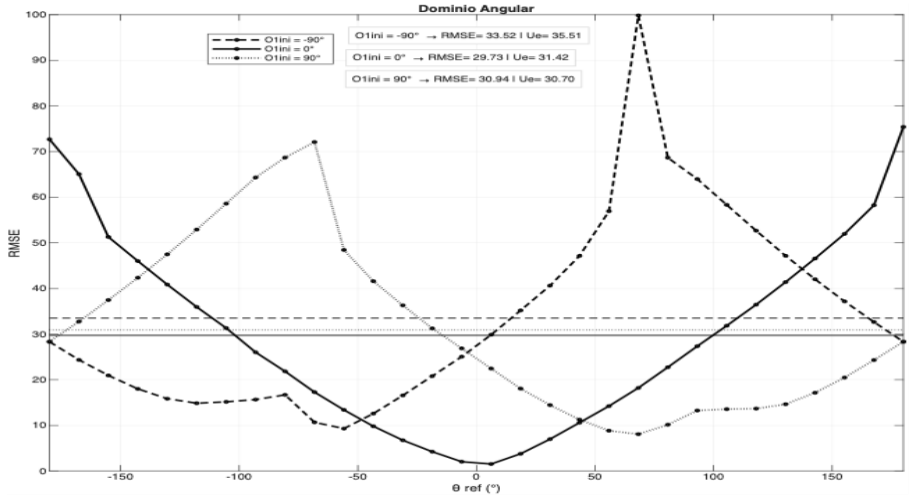

Fig. 5. Evaluación del RMSE en el dominio angular bajo variación del ángulo inicial o1ini, plataforma plana. Fuente: Elaboración propia. Enlace.

En el sector 1 (Fig. 6) el agente muestra un comportamiento estable con un RMSE bajo (≈ 10.29°) para condiciones nominales, mientras que en extremos se incrementa moderadamente (≈ 12.55° y 77.62°). Sin embargo, en el sector 2 (Fig. 7), el error aumenta (≈ 24.34° – 47.33°), reflejando pérdida de generalización.

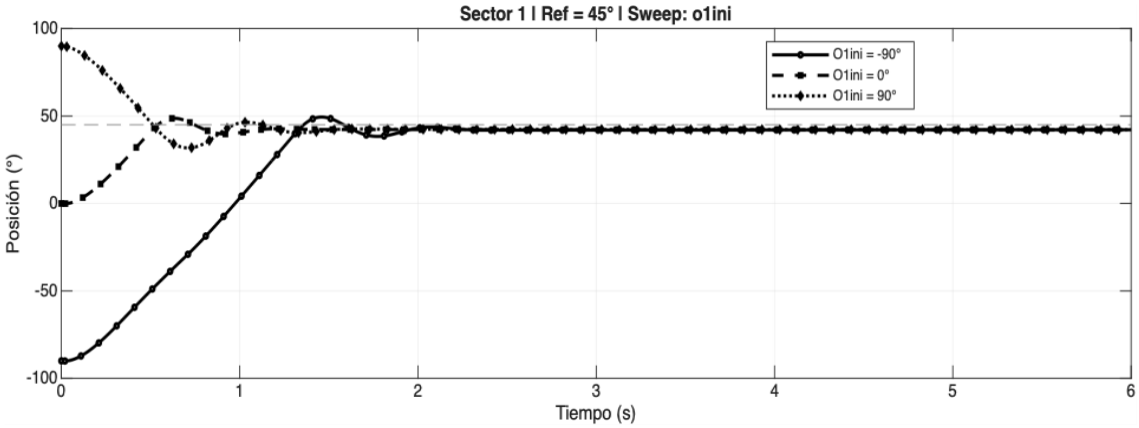

Fig. 6. Respuesta temporal del sistema ante variaciones del ángulo inicial de operación en plataforma plana, Sector 1. Fuente: Elaboración propia. Enlace.

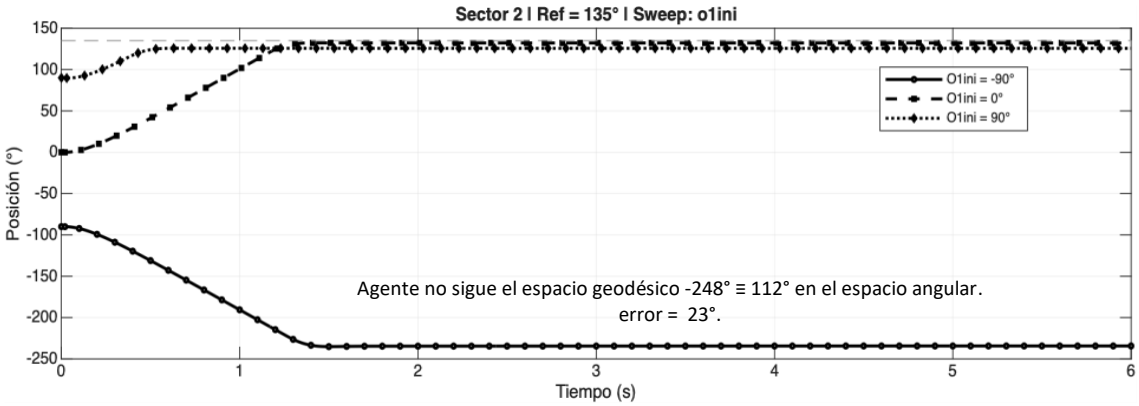

Fig. 7. Respuesta temporal del sistema ante variaciones del ángulo inicial de operación en plataforma plana, Sector 2. Fuente: Elaboración propia. Enlace.

Esta tendencia se acentúa en sector 3 (véase Fig. 8) donde se alcanzan los mayores errores (≈ 53.65° – 84.30°), confirmando una política altamente dependiente del estado inicial. Finalmente, en el sector 4 (véase Fig. 9), el agente recupera parcialmente el desempeño (≈ 10.84° en condiciones nominales), aunque persisten errores elevados en extremos (≈ 42.64°).

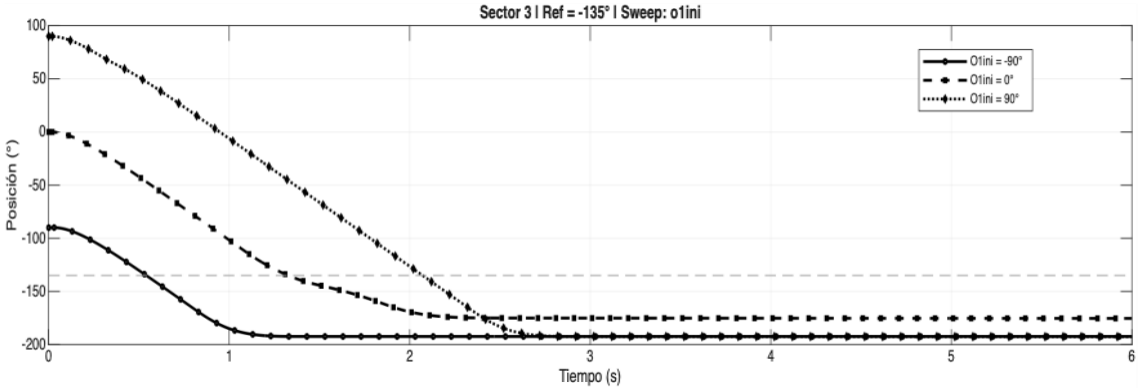

Fig. 8. Respuesta temporal del sistema ante variaciones del ángulo inicial de operación en plataforma plana, Sector 3. Fuente: Elaboración propia. Enlace.

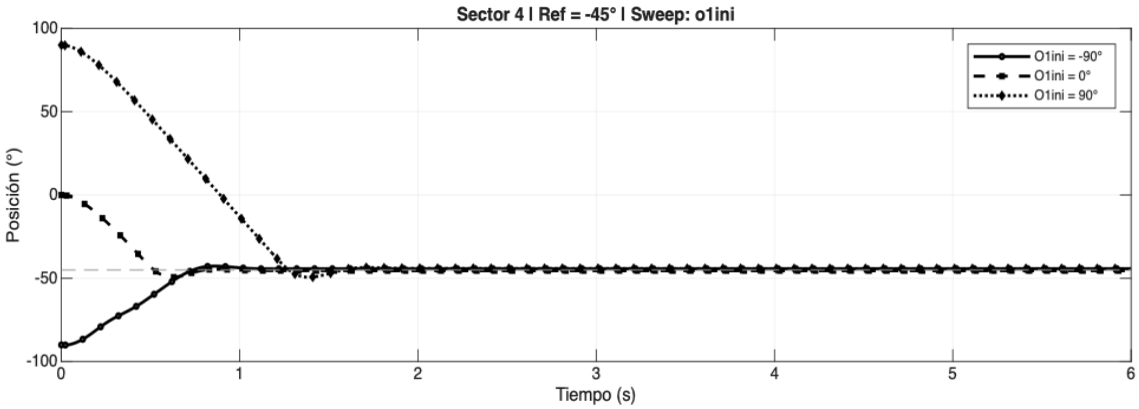

Fig. 9. Respuesta temporal del sistema ante variaciones del ángulo inicial de operación en plataforma plana, Sector 4. Fuente: Elaboración propia. Enlace.

En conjunto, el sobreentrenamiento en esta fase induce una transición hacia una política local, reduciendo el RMSE global pero comprometiendo la consistencia y capacidad de generalización en todo el dominio angular.

El retardo no compromete la estabilidad ni la convergencia, pero incrementa moderadamente el sobreimpulso y el esfuerzo de control (véase Fig. 10, Fig. 11)

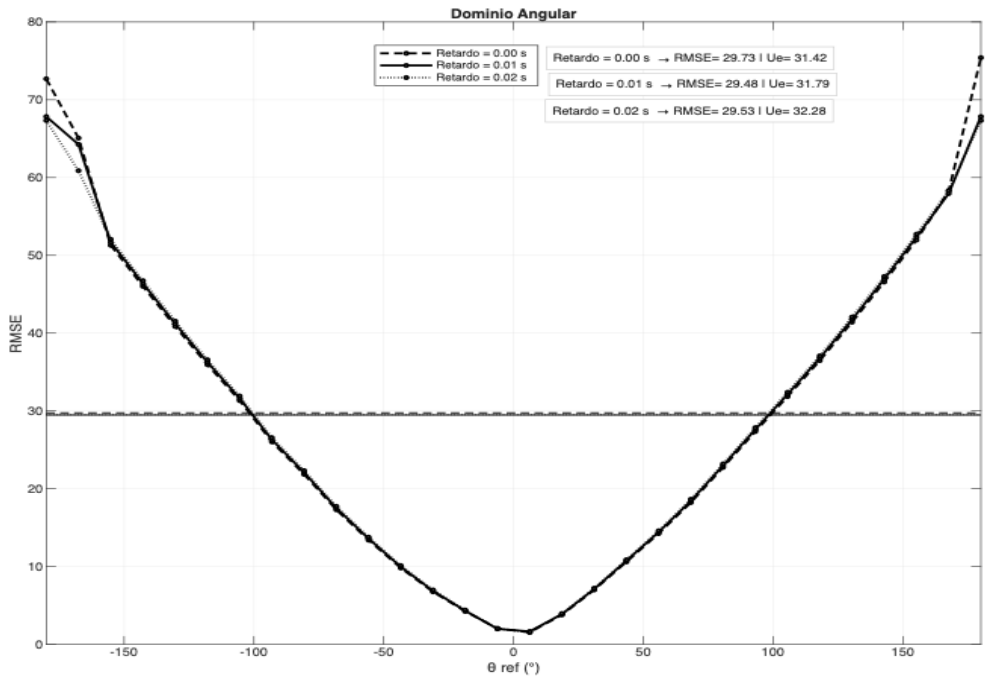

Fig. 10. Evaluación del RMSE en el dominio angular bajo variación retardo de señal. Fuente: Elaboración propia. Enlace.

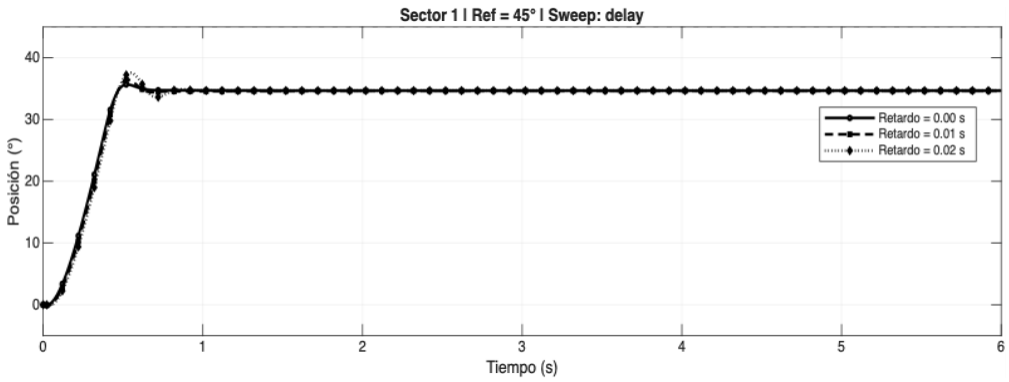

Fig. 11. Respuesta temporal del sistema ante variaciones de retardo en el lazo de control. Fuente: Elaboración propia. Enlace.

En la Fig. 12 se observa que la variación de la velocidad angular inicial no altera la forma del RMSE en el dominio angular, sino únicamente su magnitud. El error global se mantiene prácticamente constante entre 29.12 y 29.78, con una variación inferior al 2.3%, lo que evidencia una alta robustez del agente. Asimismo, el esfuerzo de control permanece estable en torno a $U_e \approx 31$.

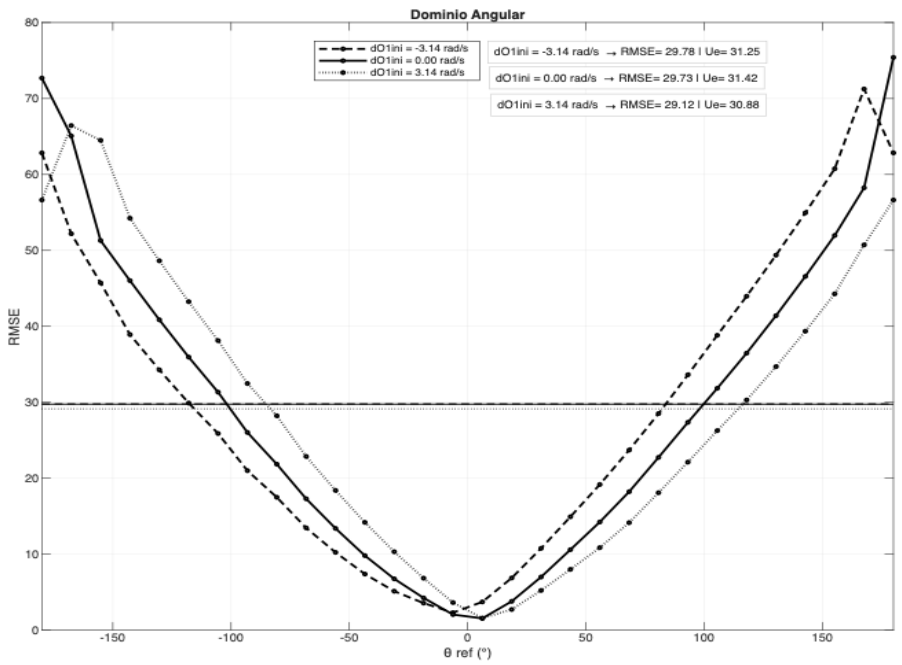

Fig. 12. Evaluación del RMSE en el dominio angular bajo variación de la velocidad angular inicial do1ini, plataforma plana. Fuente: Elaboración propia. Enlace.

En la Fig. 13 la respuesta temporal muestra que el sistema converge en todos los casos en menos de 1 s, con error estacionario prácticamente nulo. Las diferencias se limitan al régimen transitorio: aparece undershoot (~−15°) para -3.14 rad/s y ligero overshoot (~48–49°) para 3.14 rad/s, mientras que la condición nominal presenta la respuesta más equilibrada.

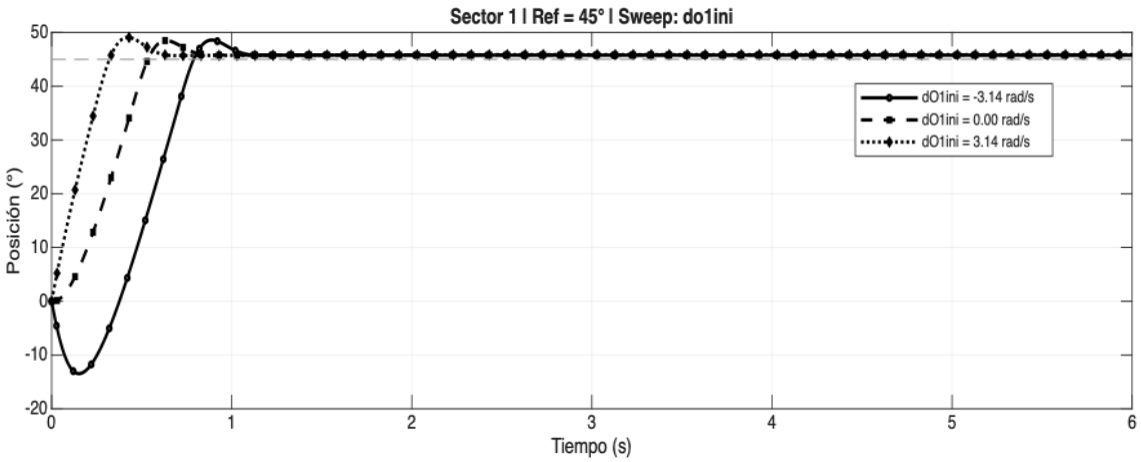

Fig. 13. Respuesta temporal del sistema ante variaciones de la velocidad angular inicialen plataforma plana. Fuente: Elaboración propia. Enlace.

1.1.3 Evaluación del controlador RL en plataforma inclinada

El análisis en plataforma inclinada tiene como objetivo evaluar la robustez y capacidad de generalización del agente RL frente a condiciones no presentes durante el entrenamiento. La inclinación (pitch=roll=−10°) introduce una perturbación gravitacional constante que modifica la dinámica del sistema, permitiendo analizar el impacto sobre el error, la simetría de la respuesta y el comportamiento en régimen transitorio.

La Fig. 14 muestra el RMSE en el dominio angular bajo distintas condiciones iniciales de orientación en plataforma inclinada (pitch=roll=−10°). A diferencia del caso en plataforma plana, se observa una pérdida clara de simetría en la curva, con desplazamientos del mínimo error y degradaciones localizadas.

El caso o1ini = 0° presenta el mejor desempeño global (RMSE ≈ 28.67°), mientras que o1ini = −90° incrementa el error medio hasta ≈ 33.01° y o1ini = 90° hasta ≈ 31.46°. Además, se observan incrementos locales significativos, alcanzando valores de hasta ≈ 85° en determinadas regiones del dominio.

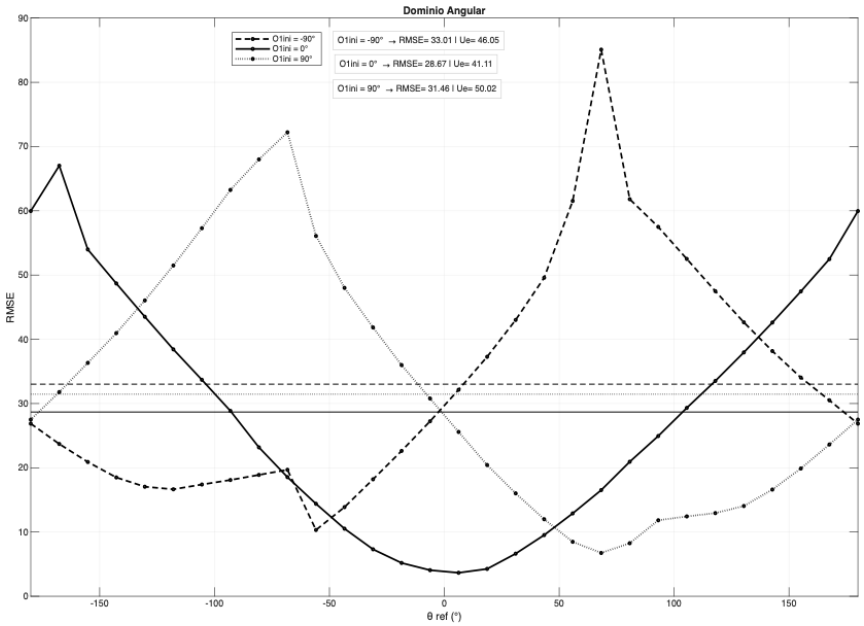

Fig. 14. Evaluación del RMSE en el dominio angular bajo variación retardo de señal en plataforma inclinada, pitch=roll= -10°. Fuente: Elaboración propia. Enlace.

La Fig. 15 muestra la respuesta temporal del sistema ante distintas condiciones iniciales de orientación en plataforma inclinada. En los tres casos, el sistema converge hacia la referencia de 45°, manteniendo la estabilidad del controlador bajo la perturbación gravitacional.

La condición inicial modifica significativamente el transitorio. Para o1ini = 0° y o1ini = 90°, la referencia se alcanza en torno a 0.7–1 s, con oscilaciones moderadas. En cambio, para o1ini = −90° la convergencia es más lenta (≈ 2 s) y el recorrido angular es considerablemente mayor, partiendo desde valores

cercanos a −90°. Esta diferencia se refleja en el error global, con RMSE de ≈ 28.67° para o1ini = 0°, ≈ 31.46° para o1ini = 90° y ≈ 33.01° para o1ini = −90°, evidenciando una mayor sensibilidad del agente a condiciones iniciales desfavorables.

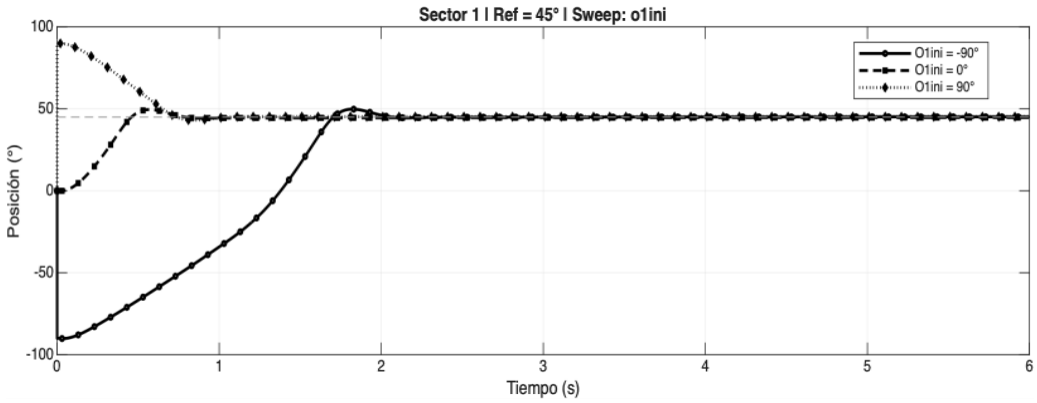

Fig. 15. Respuesta temporal del sistema ante variaciones del ángulo inicial de operación en plataforma inclinada pitch=roll= -10. Fuente: Elaboración propia. Enlace.

En el caso de variación del retardo de señal en plataforma inclinada, el RMSE mantiene prácticamente la misma forma en todo el dominio angular (véase Fig. 16), con una curva en "U" y un mínimo en la región central (≈ 4°–5°). El efecto del retardo se limita a un incremento leve del error global, pasando de ≈ 28.67° (0 ms) a ≈ 29.02° (10 ms) y ≈ 29.08° (20 ms), lo que representa una variación inferior al 2%. En los extremos (±180°), el error se mantiene en torno a ≈ 60°–66°, sin cambios relevantes en la tendencia.

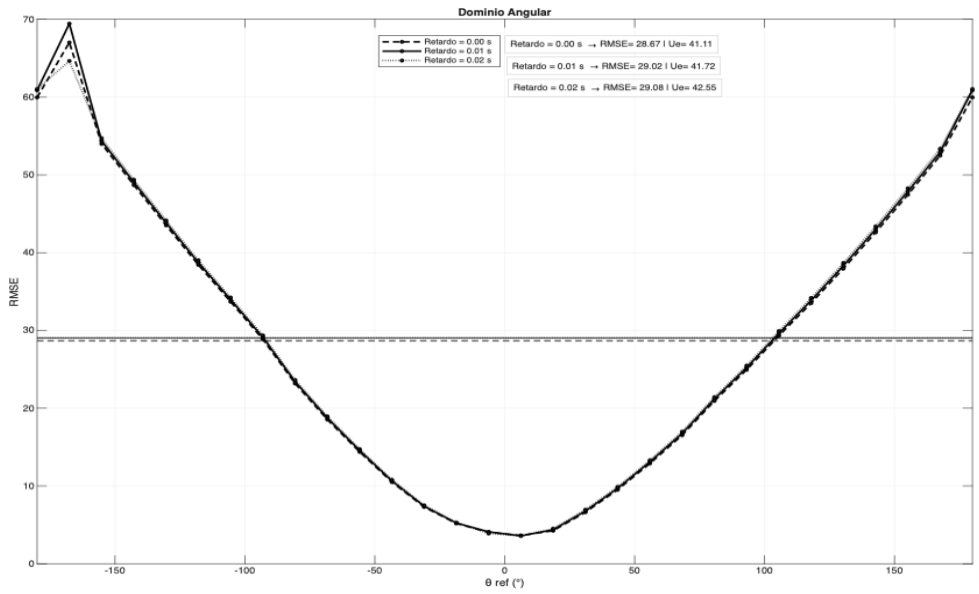

Fig. 16. Evaluación del RMSE en el dominio angular bajo variación retardo de señal en plataforma inclinada, pitch=roll= -10°. Fuente: Elaboración propia. Enlace.

En el caso de retardo en plataforma inclinada, la respuesta temporal mantiene la convergencia hacia la referencia de 45° en todos los casos (véase Fig. 89), con tiempos de establecimiento similares (≈ 0.8–1 s). El retardo incrementa ligeramente el sobreimpulso, pasando de ≈ 45° a ≈ 50°–52°, sin afectar de forma apreciable el error en régimen estacionario. Las diferencias entre 0 ms, 10 ms y 20 ms son reducidas, confirmando un impacto limitado del retardo en la dinámica del sistema.

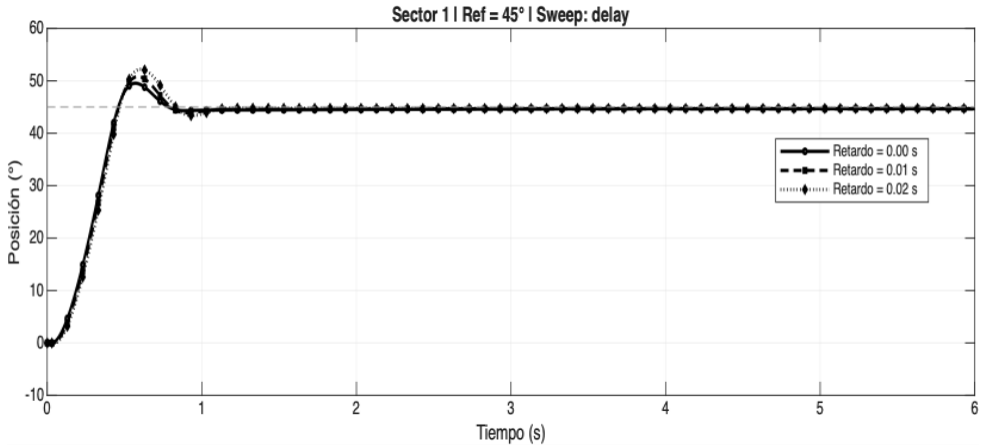

Fig. 17. Respuesta temporal del sistema ante retardo en el lazo de control en plataforma inclinada pitch=roll= -10. Fuente: Elaboración propia. Enlace.

En el caso de variación de la velocidad angular inicial en plataforma inclinada, el RMSE mantiene la forma global en "U" (véase Fig. 18) pero presenta una clara asimetría dependiendo del signo de do1ini. El caso do1ini = 0 rad/s muestra el mejor desempeño (RMSE ≈ 28.67°), mientras que do1ini = −3.14 rad/s y do1ini = 3.14 rad/s incrementan el error hasta ≈ 28.99° y ≈ 29.67°, respectivamente. Las diferencias se acentúan en los extremos del dominio, donde el error alcanza valores de ≈ 60°–65°, con mayor degradación para velocidades iniciales positivas.

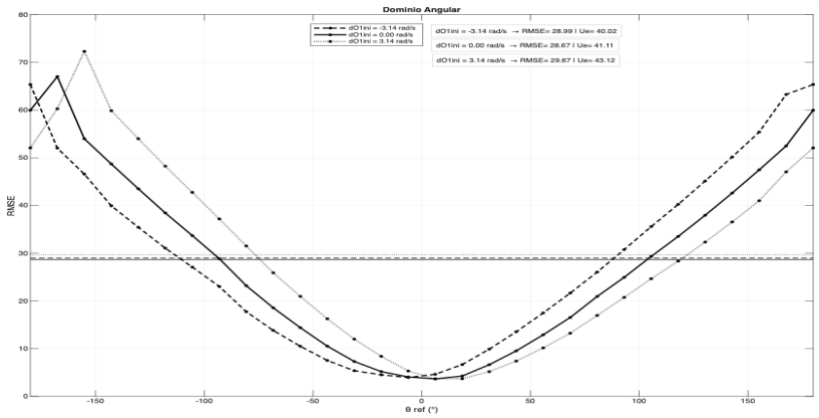

Fig. 18. Evaluación del RMSE en el dominio angular bajo variación de la velocidad angular inicial do1ini, plataforma inclinada pitch=roll=-10°. Fuente: Elaboración propia. Enlace.

En el caso de variación de la velocidad angular inicial en plataforma inclinada, el sistema converge hacia la referencia de 45° en todos los casos (véase Fig. 91), manteniendo el error estacionario prácticamente nulo. La condición inicial afecta principalmente al transitorio. Para do1ini = 0 rad/s, la respuesta alcanza la referencia en ≈ 0.7 s, mientras que para do1ini = ±3.14 rad/s se observan mayores sobreimpulsos (≈ 50°–52°) y ligeras diferencias en la rapidez de convergencia.

Las variaciones en la dinámica se traducen en un incremento del error global, con RMSE de ≈ 28.67° (0 rad/s), ≈ 28.99° (−3.14 rad/s) y ≈ 29.67° (3.14 rad/s), evidenciando la influencia del estado inicial en el comportamiento transitorio.

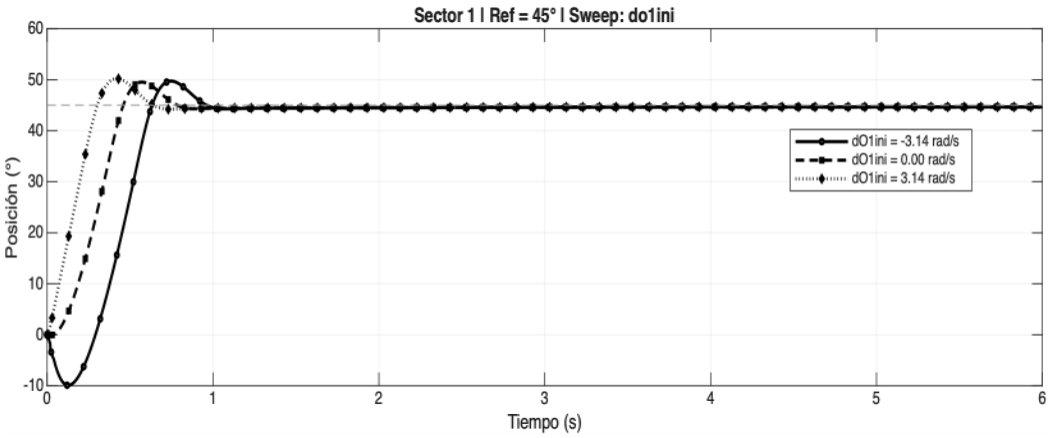

Fig. 19. Respuesta temporal del sistema ante variaciones de la velocidad angular inicialen plataforma inclinada pitch=roll=-10°. Fuente: Elaboración propia. Enlace.

1.1.4 Comparación PID vs Controlador RL Fase 4A

En plataforma plana (Fig. 20), el controlador RL (Agente 600) alcanza un desempeño comparable al PID, con un RMSE medio de ≈28.6° frente a ≈31.4°. En condiciones inclinadas (Fig. 21) el RL mejora significativamente el rendimiento, reduciendo el RMSE a ≈28.2° frente a ≈40.6° del PID, evidenciando una mayor robustez y capacidad de adaptación ante perturbaciones gravitacionales.

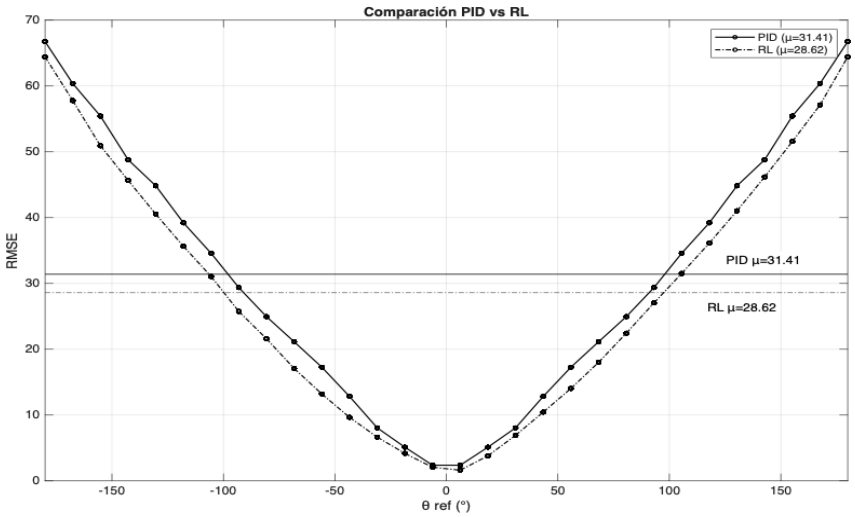

Fig. 20. Evaluación del RMSE en el dominio angular del PID vs Controlador RL Fase4A, plataforma plana. Fuente: Elaboración propia. Enlace.

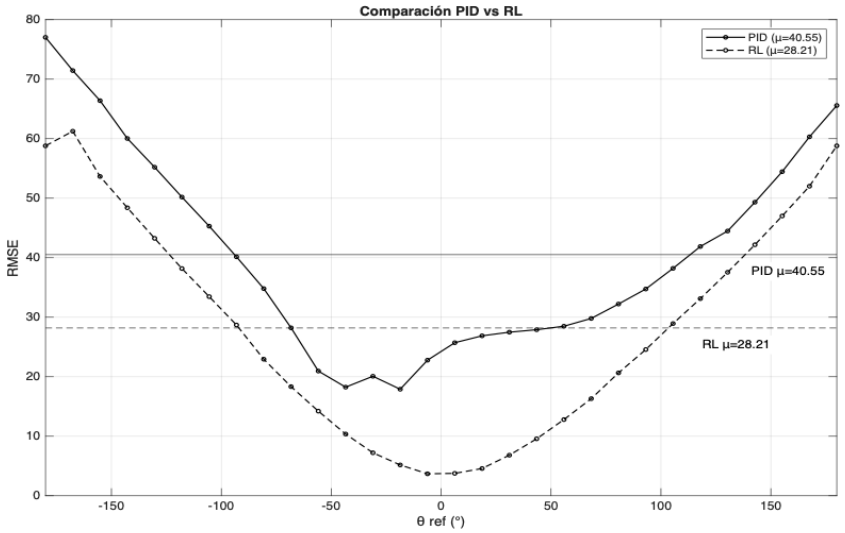

Fig. 21. Evaluación del RMSE en el dominio angular del PID vs Controlador RL Fase4A, plataforma inclinada, pitch= roll= -10°. Fuente: Elaboración propia. Enlace.

Véase tabla de resultados en el Anexo 2.12, Enlace.

1.1.5 Conclusión Fase 4A

La Fase 4A permite consolidar una política de control estable y efectiva en condiciones nominales, logrando un desempeño comparable al PID y superior bajo perturbaciones. No obstante, el entrenamiento intensivo en condiciones específicas induce una tendencia al sobreajuste, evidenciada por la pérdida de generalización en ciertos sectores del dominio angular. En conjunto, esta fase establece una base funcional robusta, pero revela la necesidad de estrategias adicionales para mejorar la consistencia global del agente.

1.2 Resultados Fase 4B Horizont Break

En esta fase se introducen perturbaciones estructurales en el sistema durante el entrenamiento, mediante inclinaciones en los ejes *pitch* y *roll*, modificando la dinámica del entorno a través de la acción gravitacional.

En este apartado se evalúa el desempeño del agente entrenado bajo estas condiciones, analizando el error en el dominio angular a lo largo del rango completo de referencias. Asimismo, se estudia la respuesta temporal del sistema ante variaciones en las condiciones iniciales (posición y velocidad angular) y la presencia de retardo en la señal. Los resultados permiten caracterizar el comportamiento del controlador frente a estas perturbaciones, evaluando su capacidad para mantener el seguimiento, así como la influencia de las condiciones iniciales y dinámicas sobre el error y el transitorio.

1.2.1 Entrenamiento del agente RL

El entrenamiento del agente en esta fase se realiza mediante una estrategia progresiva basada en Curriculum Learning, en la que se introducen de forma estructurada perturbaciones en los ejes pitch y roll, ampliando el dominio de operación del sistema. La evolución del agente a lo largo de este proceso se muestra en la Fig. 22, donde se observa la transición entre distintos checkpoints hasta la selección final del agente utilizado en la evaluación.

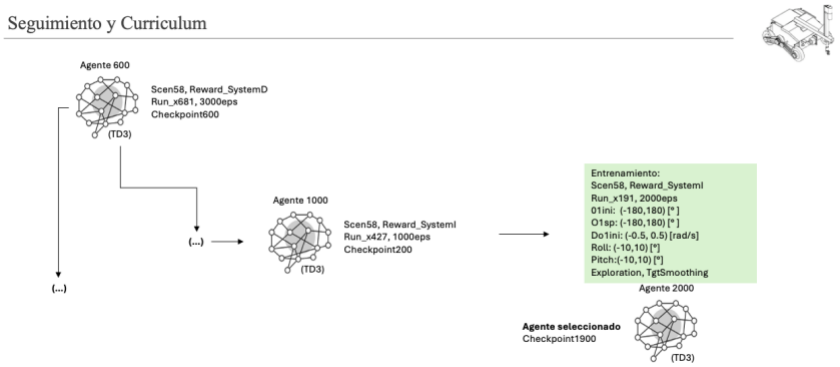

Fig. 22. Estrategia de entrenamiento progresivo mediante Curriculum Learning y evolución de agentes, Fase4B. Fuente: Elaboración propia. Enlace.

Durante el entrenamiento, el entorno incorpora variabilidad en las condiciones dinámicas mediante la inclusión de inclinaciones (pitch, roll), así como variaciones en las condiciones iniciales de posición y velocidad angular. Este enfoque permite exponer al agente a un rango más amplio de situaciones, forzando la adaptación de la política ante cambios en la dinámica del sistema.

a evolución de la recompensa por episodio se presenta en la Fig. 23. Se observa un comportamiento no monótono, con episodios puntuales de degradación significativa, asociados a exploración o a configuraciones dinámicas más exigentes. No obstante, la tendencia general muestra una estabilización de la

recompensa en etapas avanzadas del entrenamiento, indicando la convergencia del agente hacia una política consistente.

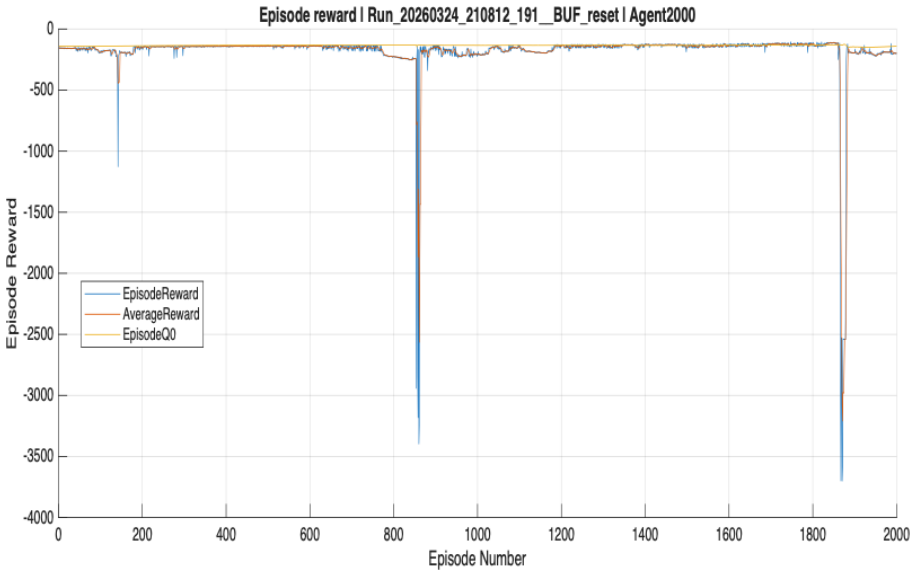

Fig. 23. Curva de aprendizaje recompensa vs episodio del agente RL, fase 4B. Fuente: Elaboración propia. Enlace.

Los parámetros de entrenamiento y configuración del agente se resumen en la Tabla 3. En particular, se emplea un modelo de exploración gaussiana con reducción progresiva de la varianza, junto con técnicas de suavizado de política (target policy smoothing) y actualización suave de redes (soft update), características del algoritmo TD3. Estos elementos contribuyen a mejorar la estabilidad del aprendizaje y a evitar sobreajustes a condiciones específicas del entorno.

La evolución del desempeño del agente durante el entrenamiento se analiza a partir del RMSE global evaluado en distintos *checkpoints*. Como se muestra en la Fig. 24, el comportamiento no presenta una tendencia monótona, sino oscilaciones a lo largo del proceso de aprendizaje, con fases de mejora y degradación intermedias. El mejor desempeño se alcanza en el entorno de los 1900 episodios, donde se obtiene el mínimo RMSE global.

Tabla 3. Métricas e hiperparámetros del agente RL, fase4A durante el entrenamiento. Fuente: propia

Training Stats		
Métrica	Símbolo	Valor
Total de episodios	N_{ep}	3000
Recompensa total último episodio	R_{ep}	-153.928
Recompensa Media	$\bar{R}$	-151.869
Pasos último episodio	-	600
Número total de pasos	N_{steps}	1.8e+06
Promedio pasos/eps	-	600
Valor Q estimado	Q_0	-140.123

Advanced Agent Options		
Métrica	Símbolo	Valor
Tiempo muestreo	T_s	0.01
Factor descuento	γ	0.99
Tamaño del Batchize	B	256
Tamaño del Exp. Buffer		400000
Modo del Buffer	-	Reset
Taza aprendizaje actor	α_a	1.0000e-04
Optimizador del actor	-	adam
Taza aprendizaje critico	α_c	0.007
Optimizador del critico	-	adam
Coeficiente actualización suave	τ	0.005

Exploration Gaussian Model		
Métrica	Símbolo	Valor
Std.Dev	σ	0.2
Mean	μ	0
Lower Lim	-	-0.5
Upper Lim	-	0.5
Std.Dev decay	λ_σ	3.8508e-07
Std.Dev min	σ_{min}	0.1

Target Policy Smoothing		
Métrica	Símbolo	Valor
Std.Dev	σ	0.2
Mean	μ	0
Lower Lim	-	-0.5
Upper Lim	-	0.5
Std.Dev decay	λ_σ	0
Std.Dev min	σ_{min}	0.2

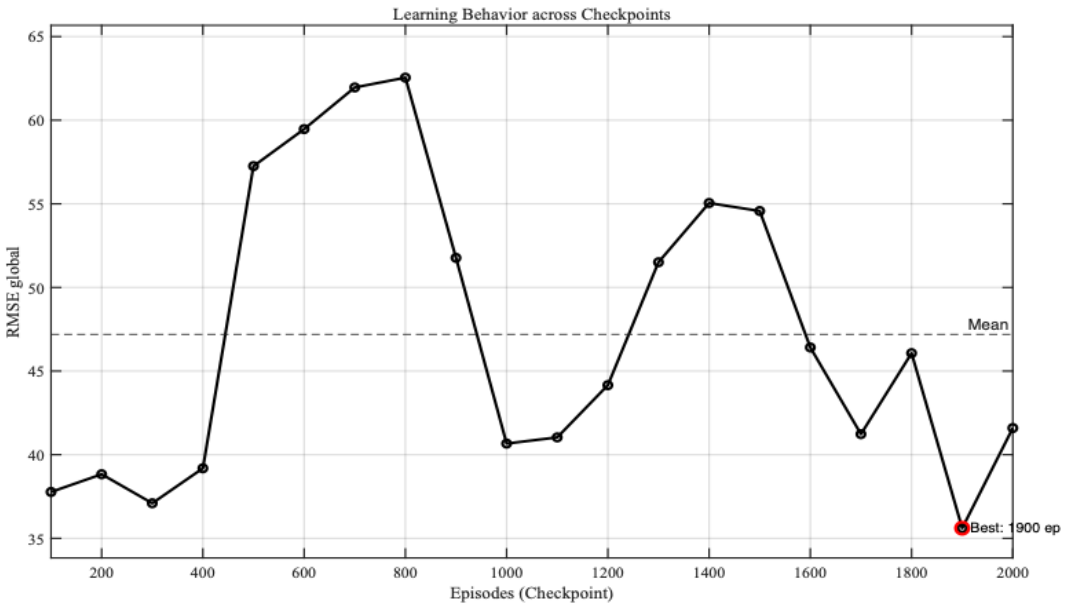

Fig. 24. Evolución del RMSE global a lo largo de los checkpoints de entrenamiento. Fuente: Elaboración propia. *Enlace.*

Con base en estas evaluaciones, se realiza la selección del agente considerando múltiples métricas de desempeño, tal como se resume en la Tabla 4. El agente correspondiente al *checkpoint* 1900 presenta el menor RMSE global (35.61°) y un valor competitivo en el resto de las métricas, posicionándose como la mejor solución global dentro del conjunto evaluado.

Tabla 4. Tabla de evaluación y selección del agente basada en métricas de desempeño. Fuente: Elaboración propia

Position	Agente	$RMSE_{global}$	$RMSE_{max}$	$\sigma_{angular}$	$Ratio_{ext}$	AUC
1	Agent1900.mat	35.6079	69.0122	16.5240	1.9381	33.8498
2	Agent300.mat	37.0973	64.8610	16.3866	1.7484	36.0126
3	Agent100.mat	37.7710	71.9503	16.3036	1.9049	36.7627
4	Agent200.mat	38.8326	65.7313	15.0605	1.6927	37.8612
5	Agent400.mat	39.1888	71.6536	18.0865	1.8284	38.2025
6	Agent1000.mat	40.6655	84.5003	16.6050	2.0779	39.6498
7	Agent1100.mat	41.0363	68.9146	14.8269	1.6794	39.5691
8	Agent1700.mat	41.2308	66.9294	12.7999	1.6233	40.3713
9	Agent2000.mat	41.5949	75.9852	23.5092	1.8268	40.2038
10	Agent1200.mat	44.1573	71.5813	15.9053	1.6211	42.7139

Para validar la consistencia del desempeño, la Fig. 25 muestra la comparación del RMSE en el dominio angular para los tres mejores agentes seleccionados. Se observa que los tres presentan un comportamiento similar, con un mínimo en la región central del dominio y un incremento progresivo del error hacia los extremos. No obstante, el agente 1900 mantiene un menor error global y una distribución más uniforme, lo que justifica su selección final.

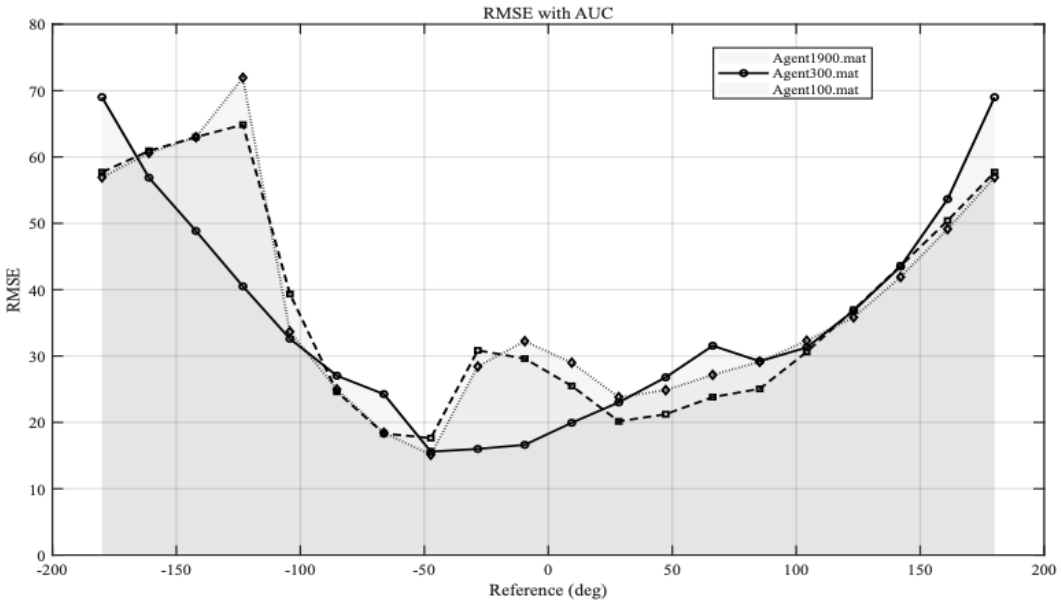

Fig. 25. Comparación del RMSE angular de los mejores 3 checkpoints del agente RL. Fuente: Elaboración propia.
Enlace.

1.2.2 Evaluación del controlador RL en Plataforma Plana

La Fig. 26 muestra la evaluación del RMSE en el dominio angular ante variaciones del ángulo inicial o1ini. El error presenta un mínimo en la región central (≈10°–15°) y aumenta hacia los extremos del dominio, alcanzando valores superiores a 140° en condiciones desfavorables. A nivel global, el RMSE varía entre 35.19° (o1ini = 90°) y 41.64° (o1ini = −90°), evidenciando una dependencia del desempeño respecto al estado inicial.

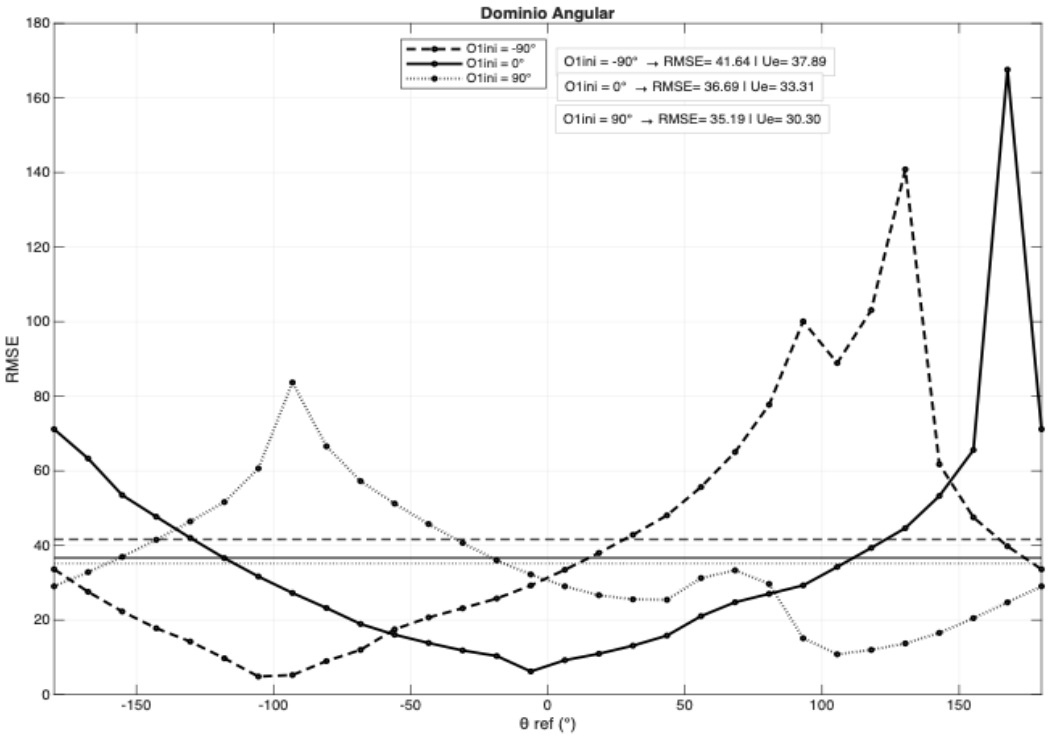

Fig. 26. Evaluación del RMSE en el dominio angular bajo variación del ángulo inicial o1ini, plataforma plana. Fuente: Elaboración propia. Enlace.

En la respuesta temporal (Fig. 27- Fig. 30), el sistema converge en todos los sectores del dominio, alcanzando el régimen estacionario en tiempos inferiores a 2 s. No obstante, el transitorio depende de la condición inicial: configuraciones cercanas a la referencia presentan trayectorias más directas, mientras que condiciones alejadas generan respuestas más largas y con mayores desviaciones iniciales.

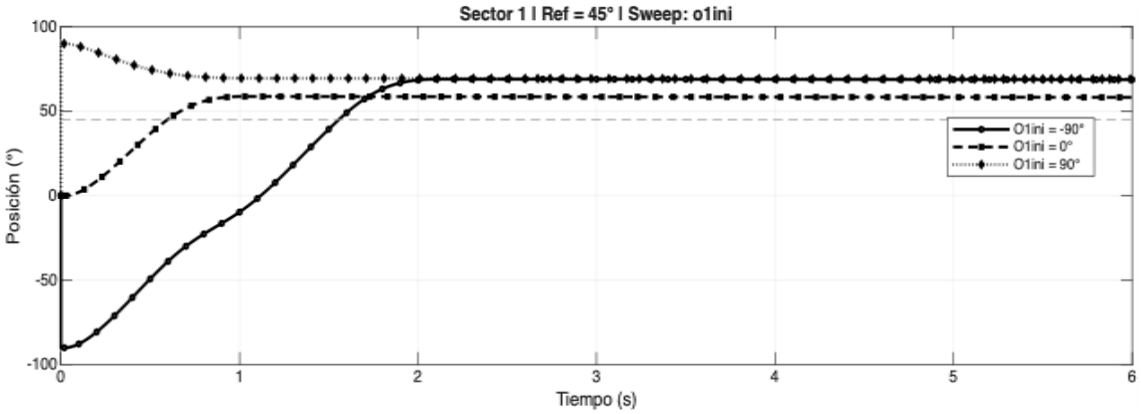

Fig. 27. Respuesta temporal del sistema ante variaciones del ángulo inicial de operación en plataforma plana, Sector 1. Fuente: Elaboración propia. Enlace.

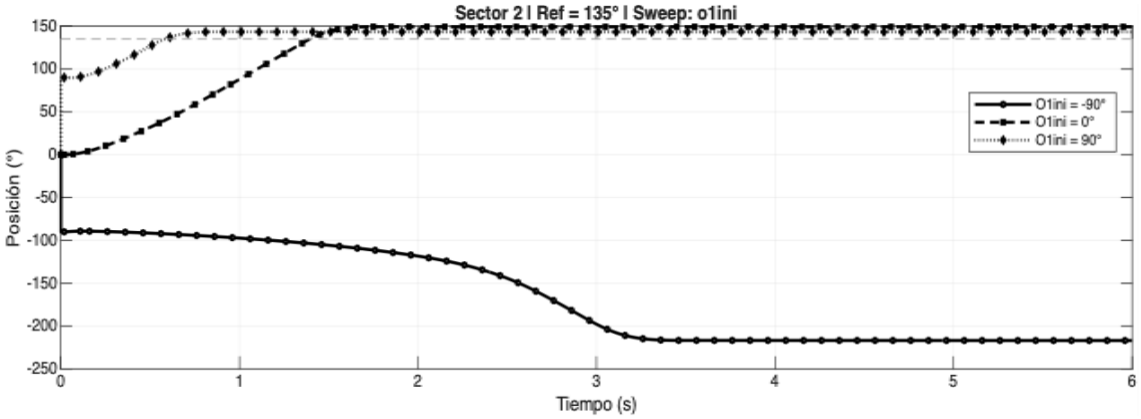

Fig. 28. Respuesta temporal del sistema ante variaciones del ángulo inicial de operación en plataforma plana, Sector 2. Fuente: Elaboración propia. Enlace.

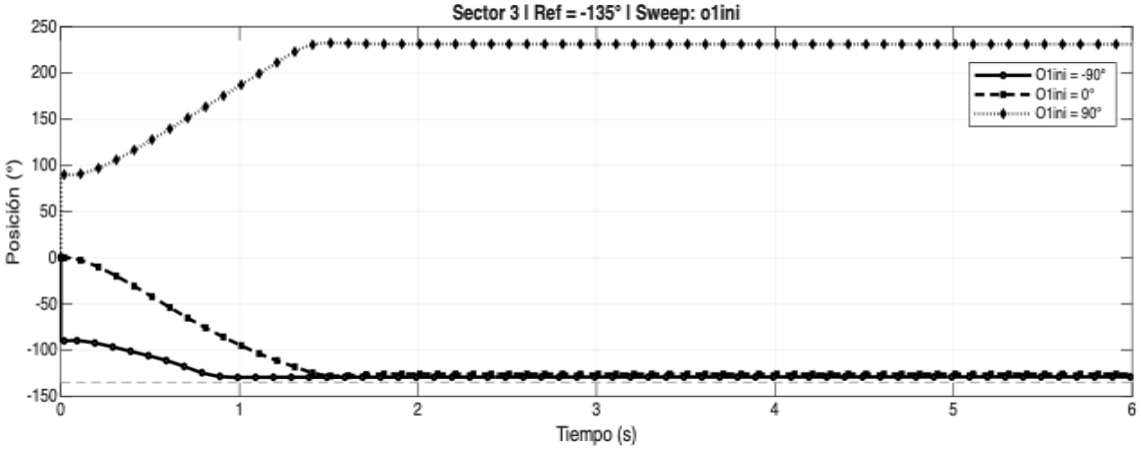

Fig. 29. Respuesta temporal del sistema ante variaciones del ángulo inicial de operación en plataforma plana, Sector 3.. Fuente: Elaboración propia. Enlace.

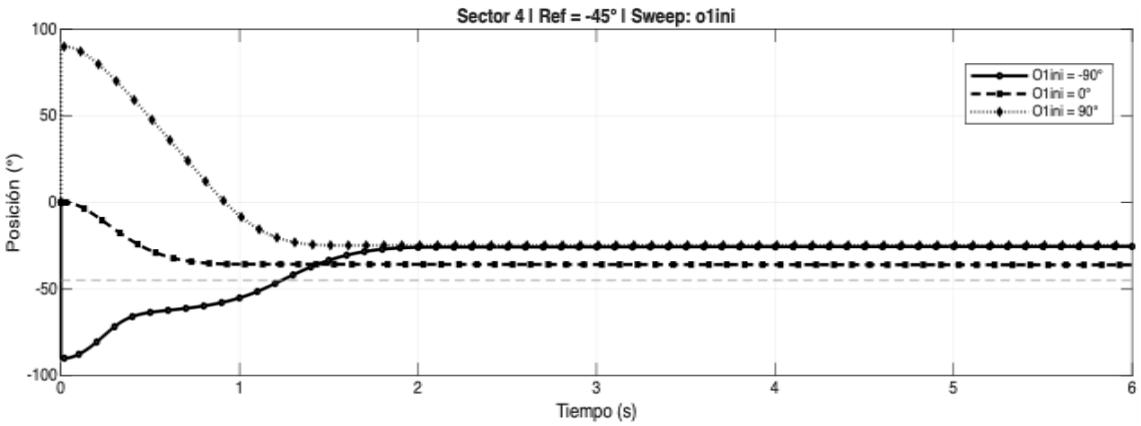

Fig. 30. Respuesta temporal del sistema ante variaciones del ángulo inicial de operación en plataforma plana, Sector 4. Fuente: Elaboración propia. Enlace.

La Fig. 31 muestra la evaluación del RMSE en el dominio angular ante variaciones del retardo en la señal. Las curvas se mantienen prácticamente superpuestas en todo el dominio, con valores globales de RMSE entre 36.09° y 36.92°, lo que indica un impacto mínimo del retardo sobre el error. La forma del RMSE se conserva, con un mínimo en la región central (≈10°) y un incremento hacia los extremos, donde se alcanzan valores superiores a 160°.

La Fig. 32 presenta la respuesta temporal del sistema. En todos los casos, el sistema converge al valor de referencia en tiempos cercanos a 1 s, sin diferencias apreciables entre los distintos retardos. El transitorio y el valor estacionario permanecen prácticamente inalterados. En consecuencia, el retardo de señal introduce una variación leve y uniforme en el desempeño, sin afectar de forma significativa ni la distribución del error en el dominio angular ni la dinámica de la respuesta temporal.

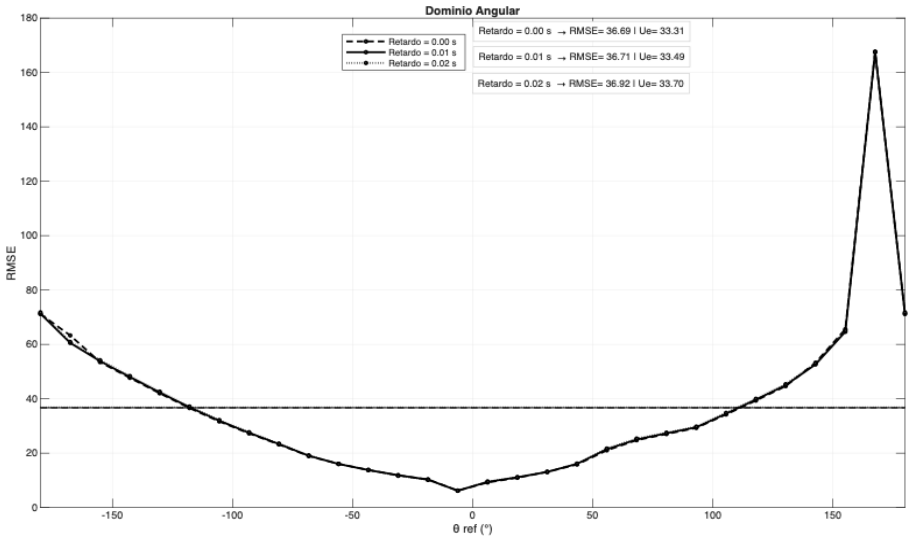

Fig. 31. Evaluación del RMSE en el dominio angular bajo variación retardo de señal. Fuente: Elaboración propia. Enlace.

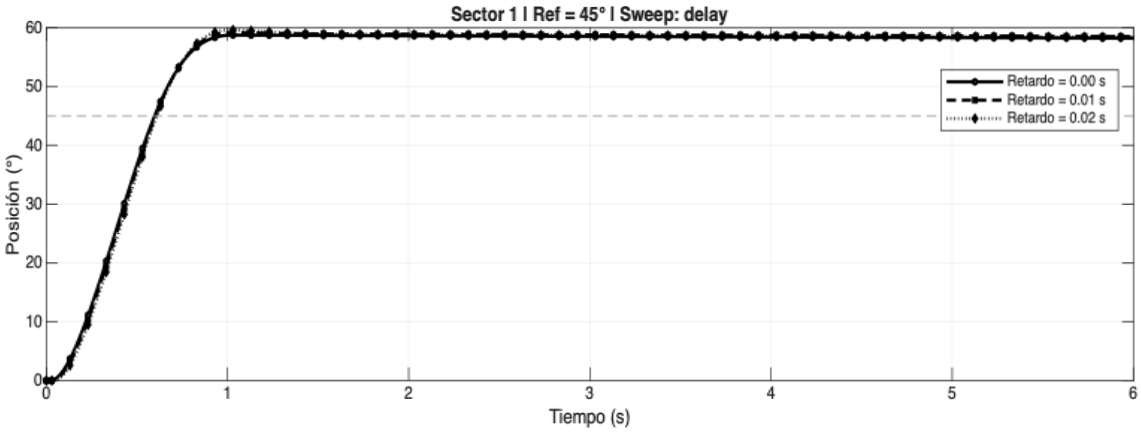

Fig. 32. Respuesta temporal del sistema ante variaciones de retardo en el lazo de control. Fuente: Elaboración propia. Enlace.

La Fig. 33 muestra la evaluación del RMSE en el dominio angular ante variaciones de la velocidad angular inicial do1ini. El error mantiene la forma global, con un mínimo en la región central (≈8°–12°), pero presenta diferencias entre configuraciones. El RMSE global varía entre 34.35° (do1ini = −3.14 rad/s) y 37.21° (do1ini = 3.14 rad/s), evidenciando una dependencia moderada respecto al signo y magnitud de la velocidad inicial. En los extremos del dominio, el error supera los 160°, con diferencias más marcadas entre las curvas.

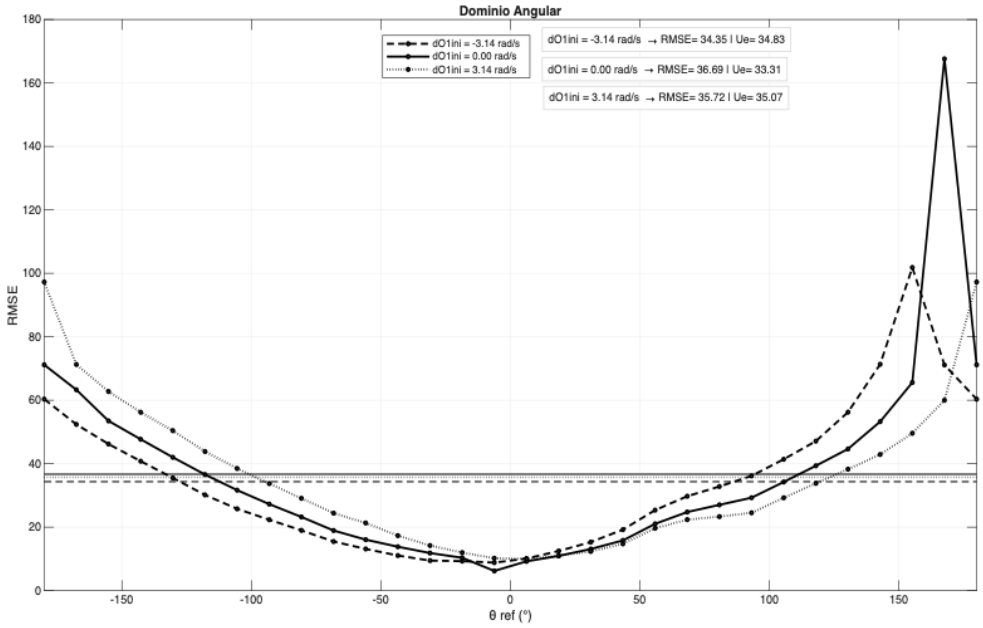

Fig. 33. Evaluación del RMSE en el dominio angular bajo variación de la velocidad angular inicial do1ini, plataforma plana. Fuente: Elaboración propia. Enlace

La respuesta temporal evidencia convergencia del sistema en todos los casos, alcanzando el valor de referencia en tiempos cercanos a 1 s. No obstante, el comportamiento transitorio depende de la velocidad angular inicial: valores positivos aceleran la aproximación inicial hacia la referencia, mientras que valores negativos generan trayectorias más largas y con mayor desviación inicial antes de la convergencia (Fig. 34).

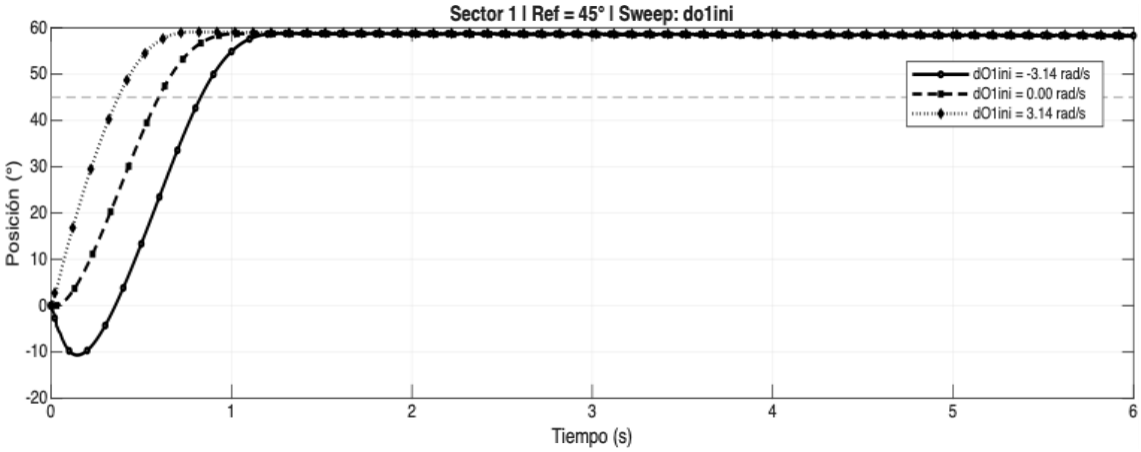

Fig. 34. Respuesta temporal del sistema ante variaciones de la velocidad angular inicialen plataforma plana. Fuente: Elaboración propia. Enlace

1.2.3 Evaluación del controlador RL en plataforma inclinada

La Fig. 35 muestra la evaluación del RMSE en el dominio angular bajo inclinación (pitch = roll = −10°) ante variaciones del ángulo inicial o1ini. El error mantiene la forma general con un mínimo en la región central (≈15°–20°), pero con un incremento global respecto al caso plano. El RMSE varía entre 36.25° (o1ini = 0°) y 42.59° (o1ini = −90°), alcanzando valores superiores a 140° en regiones específicas del dominio, lo que evidencia una degradación del desempeño bajo carga gravitacional.

Se observa además una mayor dispersión entre las curvas, indicando una dependencia más marcada del error respecto al estado inicial. En particular, ciertas configuraciones generan incrementos localizados del RMSE, reflejando trayectorias más exigentes en presencia de inclinación.

La respuesta temporal muestra convergencia en todos los casos, alcanzando el régimen estacionario en tiempos cercanos a 2 s. No obstante, el transitorio es más pronunciado que en plataforma plana, con mayores desviaciones iniciales y trayectorias menos directas hacia la referencia, especialmente en condiciones iniciales alejadas (Fig. 36).

En consecuencia, la inclinación introduce una degradación del desempeño global y una mayor sensibilidad a las condiciones iniciales, afectando tanto la distribución del error en el dominio angular como el comportamiento transitorio, aunque sin comprometer la convergencia del sistema.

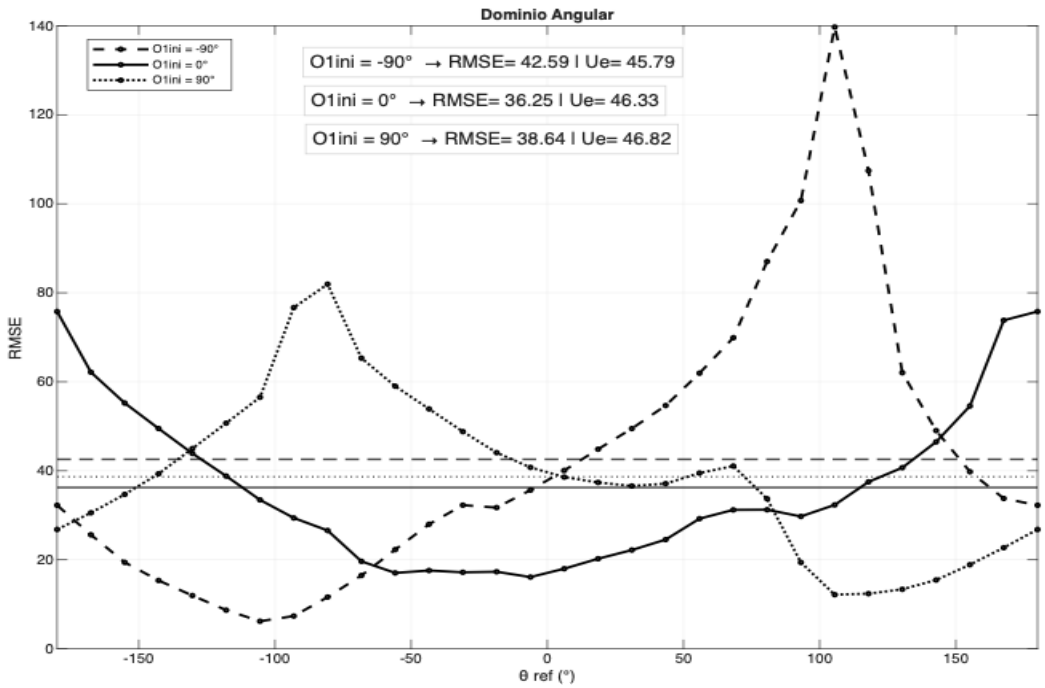

Fig. 35. Evaluación del RMSE en el dominio angular bajo variación retardo de señal en plataforma inclinada, pitch=roll= -10°. Fuente: Elaboración propia. Enlace.

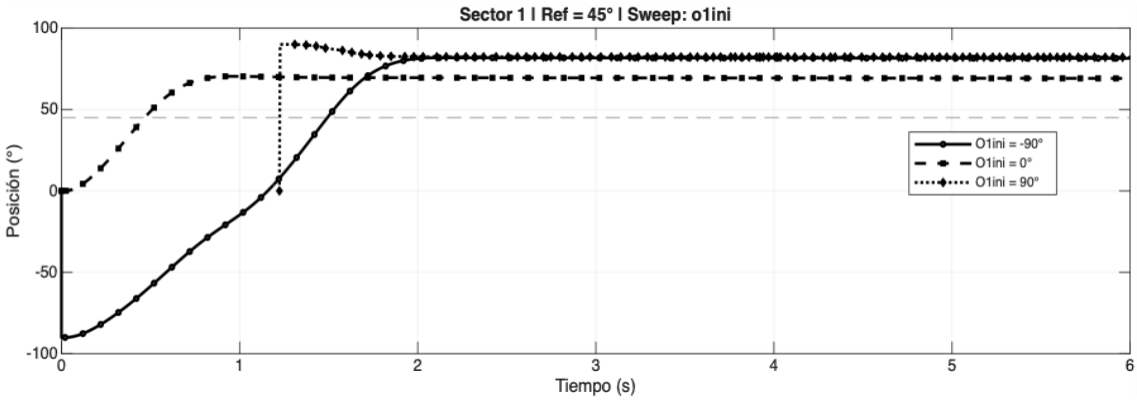

Fig. 36. Respuesta temporal del sistema ante variaciones del ángulo inicial de operación en plataforma inclinada pitch=roll= -10. Fuente: Elaboración propia. Enlace.

La Fig. 37 muestra la evaluación del RMSE en el dominio angular bajo inclinación (pitch = roll = −10°) ante variaciones del retardo de señal. Las curvas se mantienen prácticamente superpuestas en todo el dominio, con valores globales de RMSE entre 36.25° y 36.60°, lo que indica un impacto mínimo del retardo sobre el desempeño. La forma del error se conserva, con un mínimo en la región central (≈15°–20°) y un incremento hacia los extremos, donde se alcanzan valores cercanos a 80°.

La respuesta temporal evidencia convergencia en todos los casos, alcanzando el valor de referencia en tiempos cercanos a 1 s. No se observan diferencias apreciables en el transitorio ni en el valor estacionario entre los distintos retardos, manteniéndose trayectorias prácticamente idénticas (Fig. 38).

En consecuencia, el retardo de señal no introduce degradaciones significativas en el desempeño del controlador bajo inclinación, manteniendo tanto la distribución del error como la dinámica de la respuesta.

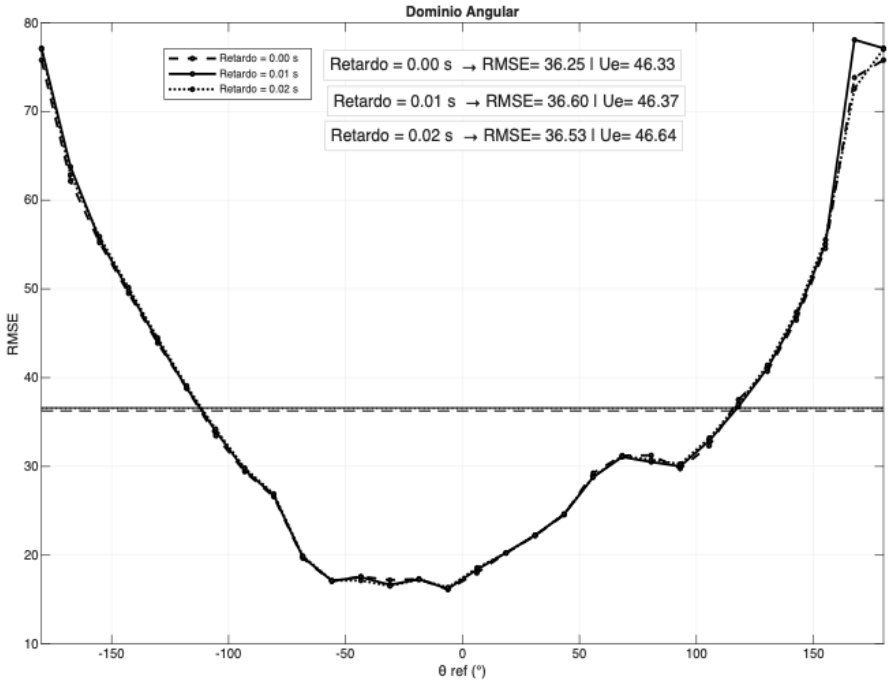

Fig. 37. Evaluación del RMSE en el dominio angular bajo variación retardo de señal en plataforma inclinada, pitch=roll= -10°. Fuente: Elaboración propia. Enlace.

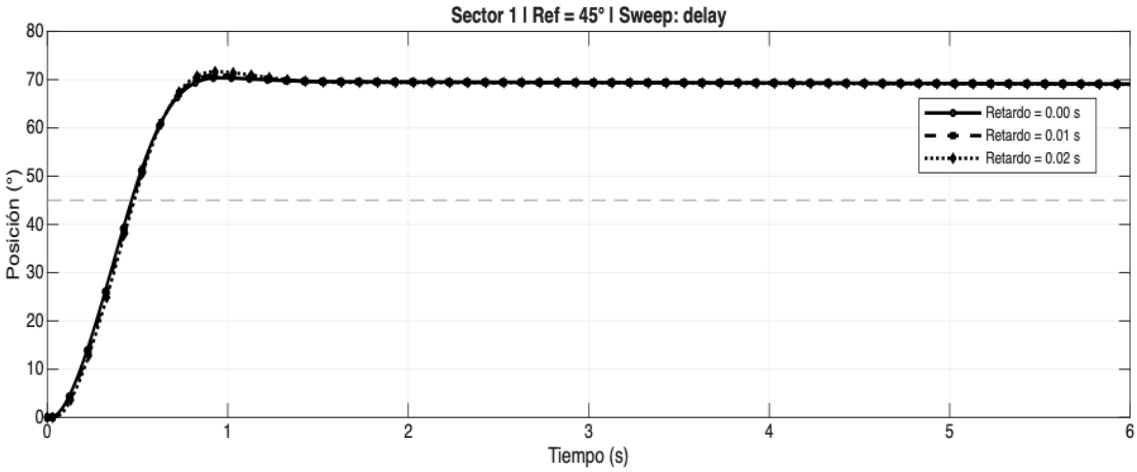

Fig. 38. Respuesta temporal del sistema ante retardo en el lazo de control en plataforma inclinada pitch=roll= -10. Fuente: Elaboración propia. Enlace.

El análisis en el dominio angular (Fig. 39) muestra que la variación de la velocidad inicial introduce cambios tanto en la forma como en el nivel de la curva de error. En particular, el caso más favorable alcanza un RMSE de 35.18 con menor esfuerzo de control (Ue = 44.79), mientras que los otros escenarios incrementan el error hasta 36.25° y 37.41° respectivamente. Además, no solo se observa un desplazamiento de la curva, sino también una ligera deformación, especialmente en los extremos del dominio ($\pm 180\circ$), donde el RMSE crece de forma más pronunciada. Esto indica que la velocidad inicial no solo afecta la magnitud del error, sino también la capacidad del agente para generalizar en todo el espacio angular.

En la respuesta temporal (Fig. 40), estas diferencias se reflejan principalmente en la fase transitoria. El caso más desfavorable presenta un mayor retardo inicial y un sobreimpulso más marcado antes de estabilizarse. En el escenario intermedio, la respuesta es más equilibrada, con menor sobreimpulso y una convergencia más suave. Por otro lado, el caso más favorable muestra una respuesta más rápida en el arranque, aunque con pequeñas oscilaciones iniciales. En todos los escenarios, la referencia de $45°$ se alcanza en menos de 1 s y el sistema permanece estable sin error estacionario significativo, confirmando que las diferencias en RMSE observadas en la Fig. 39 provienen principalmente de la dinámica transitoria mostrada en la Fig. 40.

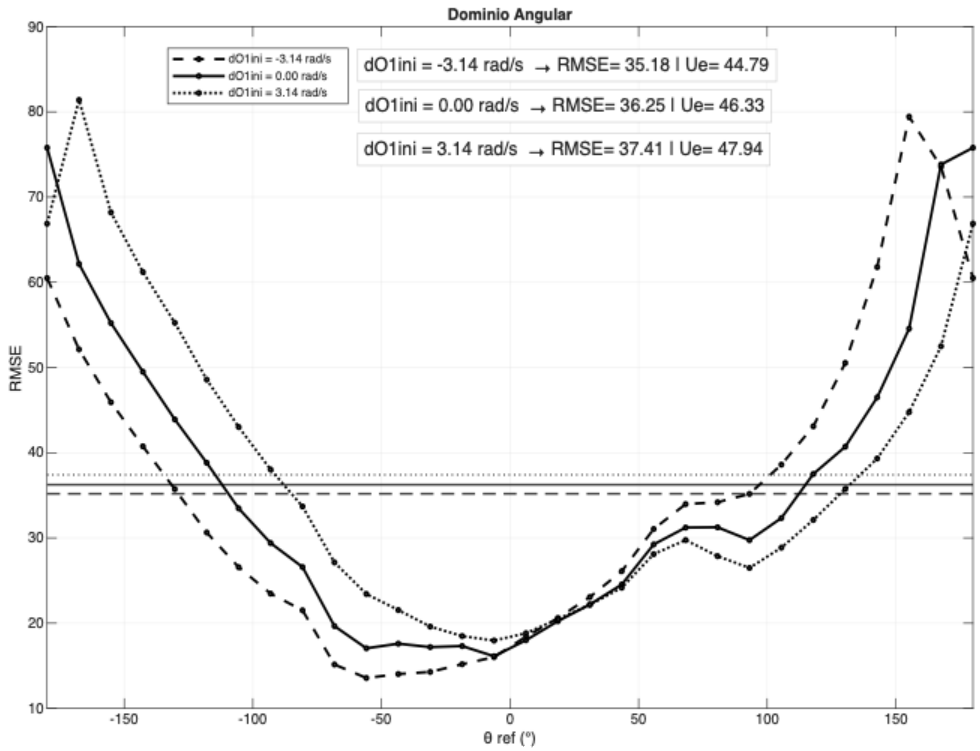

Fig. 39. Evaluación del RMSE en el dominio angular bajo variación de la velocidad angular inicial do1ini, plataforma inclinada pitch=roll=-10°. Fuente: Elaboración propia. Enlace.

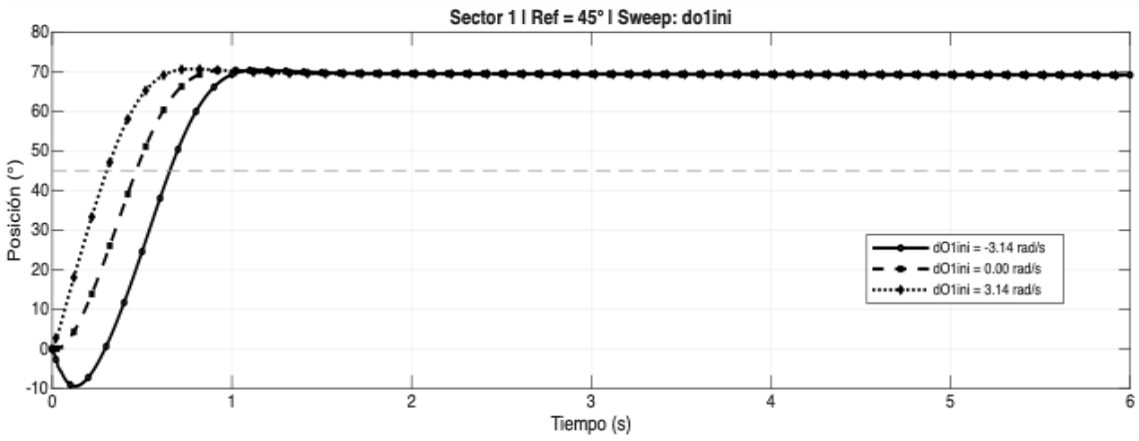

Fig. 40. Respuesta temporal del sistema ante variaciones de la velocidad angular inicialen plataforma inclinada pitch=roll=-10°. Fuente: Elaboración propia. Enlace.

1.2.4 Comparación PID vs controlador RL Fase 4B

El análisis comparativo en el dominio angular para plataforma plana (Fig. 41) muestra que ambos controladores presentan un comportamiento muy similar en la mayor parte del rango, con curvas prácticamente solapadas en la zona central. El controlador PID alcanza un RMSE global ligeramente inferior (31.35°) frente al controlador RL (36.70°), lo que indica un mejor desempeño promedio en condiciones nominales. Sin embargo, en los extremos del dominio angular ($\pm 150°$ a $\pm 180°$), el controlador RL evidencia una degradación más pronunciada, con picos de error significativamente mayores, lo que sugiere una menor capacidad de generalización en regiones alejadas del punto de operación.

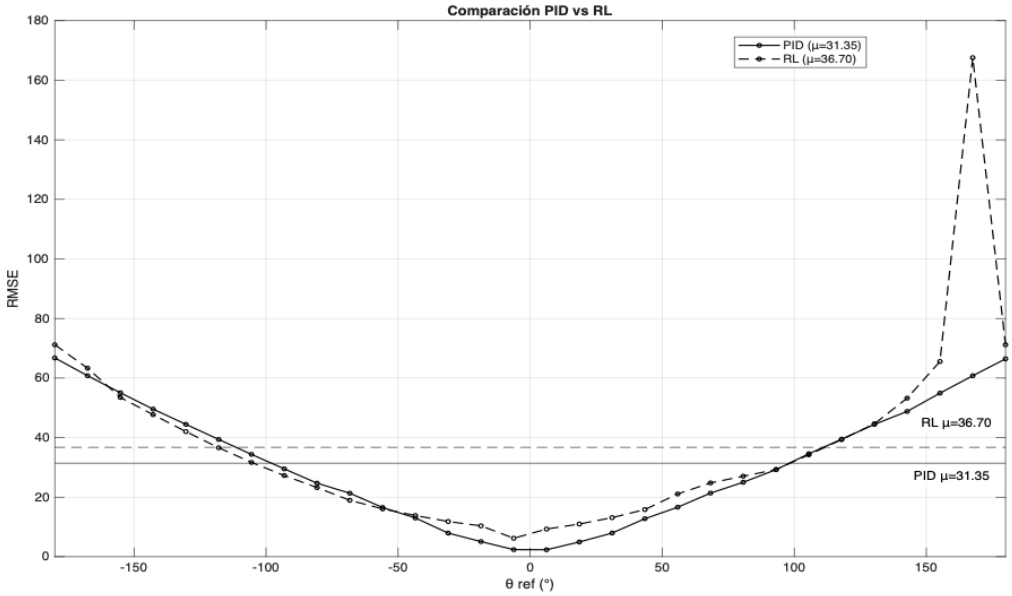

Fig. 41. Evaluación del RMSE en el dominio angular del PID vs Controlador RL Fase4B, plataforma plana. Fuente: Elaboración propia. Enlace.

En condiciones de plataforma inclinada (Fig. 42), la situación se invierte parcialmente. El controlador RL mejora su desempeño relativo, alcanzando un RMSE global de 36.25° frente a 40.55° del PID, lo que evidencia una mayor robustez frente a perturbaciones externas. En la región central del dominio, el RL mantiene menores niveles de error, mientras que el PID presenta una degradación más notable en todo el rango. No obstante, en los extremos del dominio angular ambos controladores vuelven a mostrar incrementos significativos del RMSE, aunque el RL mantiene una ligera ventaja en la mayoría de los casos.

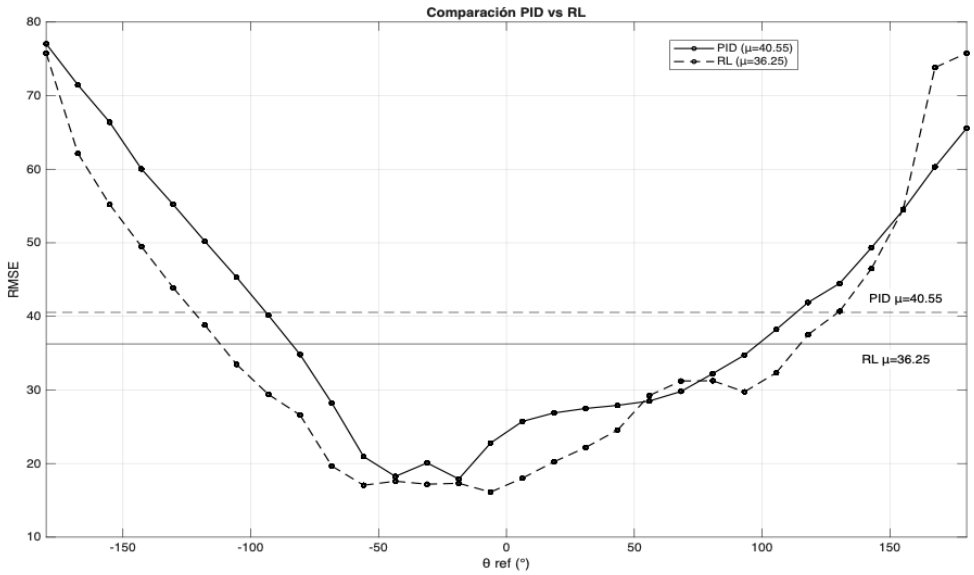

Fig. 42. Evaluación del RMSE en el dominio angular del PID vs Controlador RL Fase4B, plataforma inclinada, pitch= roll= -10°. Fuente: Elaboración propia. Enlace.

Estos resultados ponen de manifiesto que el PID resulta más eficiente en escenarios nominales, mientras que el controlador basado en aprendizaje por refuerzo muestra una mayor capacidad de adaptación ante condiciones perturbadas, evidenciando una mejor robustez aunque aún con limitaciones en los extremos del dominio angular.

1.2.5 Conclusión Fase 4B

La Fase 4B demuestra que el controlador RL mantiene un seguimiento estable en todo el dominio angular, incluso bajo perturbaciones, con convergencia consistente y sin error estacionario. El RMSE global se sitúa en torno a 36.25° en plataforma inclinada y 36.69° en plana (véase anexo 2.12 Fase 4B, Enlace) , con un esfuerzo de control acotado.

En comparación con la Fase 4A, donde se alcanzaban valores inferiores (≈28.67° inclinada y ≈29.73° plana, (véase anexo 2.12 Fase 4A, Enlace), se evidencia una degradación del RMSE. Esta pérdida de precisión está directamente asociada al

incremento de la complejidad del entorno durante el entrenamiento, debido a la introducción de perturbaciones estructurales. Dicho efecto no puede compensarse simplemente mediante un aumento del número de episodios, ya que responde a un compromiso inherente entre precisión y robustez.

No obstante, el agente de la Fase 4B presenta una mayor capacidad de generalización y robustez frente a perturbaciones, superando al PID en condiciones inclinadas. De este modo, esta fase consolida un controlador más adaptable, priorizando el desempeño bajo incertidumbre sobre la optimización en condiciones ideales.

Véase tabla de resultados en el Anexo 2.12, Enlace.

1.3 Resultados Fase 4C Lázaro Ascencion

En esta fase se entrena el agente RL incorporando todas las perturbaciones de forma simultánea y en modo aleatorio, incluyendo variaciones en inclinación (pitch y roll), condiciones iniciales (posición y velocidad angular) y retardo en la señal. Este enfoque expone al agente a un entorno altamente variable durante el aprendizaje, forzando una política más robusta y generalizable.

Posteriormente, se evalúa el desempeño del controlador en escenarios de plataforma plana e inclinada, analizando el error en el dominio angular y la respuesta temporal ante distintas perturbaciones. Este análisis permite caracterizar la capacidad del agente para mantener estabilidad y desempeño bajo condiciones dinámicas complejas.

1.3.1 Entrenamiento del agente RL

El entrenamiento del agente en esta fase se realiza en un entorno altamente variable, donde todas las perturbaciones se introducen de forma simultánea y aleatoria. A diferencia de fases anteriores basadas en Curriculum Learning, en este caso no se sigue una progresión estructurada, sino que el agente es expuesto desde el inicio a un dominio completo de operación.

Durante el proceso, el entorno incorpora variaciones aleatorias en la inclinación (pitch y roll), las condiciones iniciales de posición (o1ini) y velocidad angular (do1ini), así como en el retardo de la señal. Este enfoque incrementa la complejidad del aprendizaje, obligando al agente a desarrollar una política robusta capaz de generalizar ante múltiples configuraciones dinámicas.

La evolución del agente a lo largo del entrenamiento se muestra en la Fig. 43, donde se observa la transición entre distintos checkpoints hasta la selección final del modelo utilizado en la evaluación. A pesar de la mayor variabilidad del entorno, el agente alcanza una política estable, evidenciando su capacidad de adaptación frente a perturbaciones combinadas.

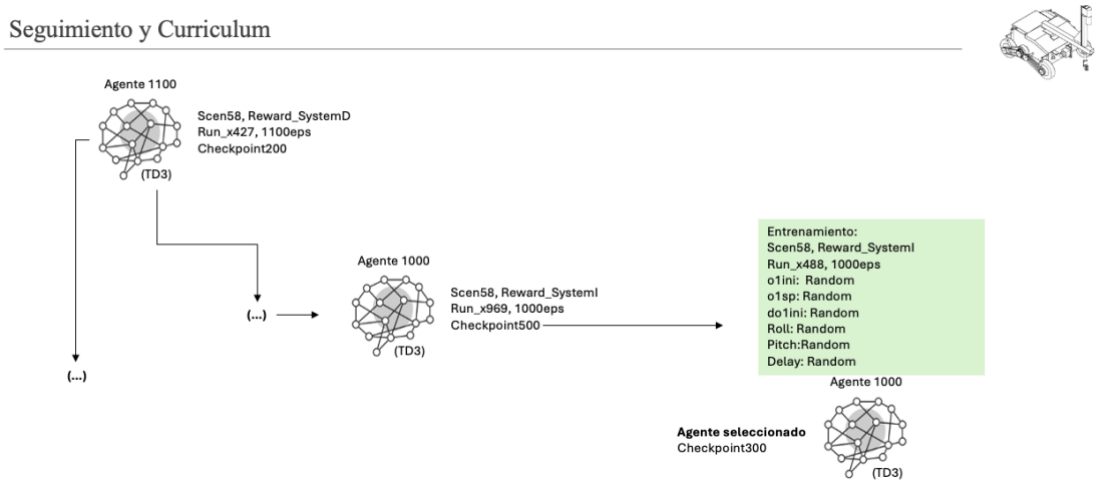

Fig. 43. Estrategia de entrenamiento progresivo mediante Curriculum Learning y evolución de agentes, Fase4C. Fuente: Elaboración propia. Enlace.

La evolución de la recompensa por episodio durante el entrenamiento se presenta en la Fig. 44. A diferencia de fases anteriores, se observa un comportamiento altamente no monótono, con caídas puntuales significativas asociadas a la exploración en un entorno con perturbaciones completamente aleatorias. Estas fluctuaciones reflejan la mayor complejidad del problema de aprendizaje, donde el agente debe adaptarse a múltiples configuraciones dinámicas simultáneamente. No obstante, la tendencia general muestra una estabilización progresiva de la recompensa media, indicando la convergencia hacia una política robusta.

Los parámetros de entrenamiento y configuración del agente se resumen en la Tabla 5. Se emplea el algoritmo TD3 con exploración gaussiana y reducción progresiva de la varianza, junto con técnicas de target policy smoothing y actualización suave de redes (soft update). La inclusión de un buffer de experiencia de gran tamaño y un tamaño de batch elevado contribuyen a estabilizar el aprendizaje en un entorno altamente estocástico.

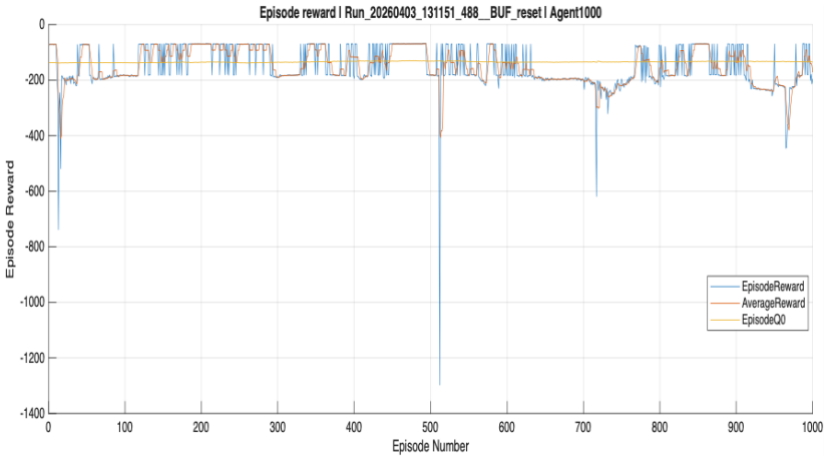

Fig. 44. Curva de aprendizaje recompensa vs episodio del agente RL, fase 4C. Fuente: Elaboración propia. Enlace.

Tabla 5. Métricas e hiperparámetros del agente RL, fase4C durante el entrenamiento. Fuente: propia

Training Stats		
Métrica	Símbolo	Valor
Total de episodios	N_{ep}	1000
Recompensa total último episodio	R_{ep}	-195.983
Recompensa Media	$\bar{R}$	-172.063
Pasos último episodio	-	600
Número total de pasos	N_{steps}	600000
Promedio pasos/eps	-	600
Valor Q estimado	Q_0	-135.065

Advanced Agent Options		
Métrica	Símbolo	Valor
Tiempo muestreo	T_s	0.01
Factor descuento	γ	0.99
Tamaño del Batchize	B	64
Tamaño del Exp. Buffer		50000
Modo del Buffer	-	Reset
Taza aprendizaje actor	α_a	1.0000e-04
Optimizador del actor	-	adam
Taza aprendizaje critico	α_c	0.001
Optimizador del critico	-	adam
Coeficiente actualización suave	τ	0.005

Exploration Gaussian Model		
Métrica	Símbolo	Valor
Std.Dev	σ	0.15
Mean	μ	0
Lower Lim	-	-0.5
Upper Lim	-	0.5
Std.Dev decay	λ_σ	3.3582e-06
Std.Dev min	σ_{min}	0.02

Target Policy Smoothing		
Métrica	Símbolo	Valor
Std.Dev	σ	0.1
Mean	μ	0
Lower Lim	-	-0.5
Upper Lim	-	0.5
Std.Dev decay	λ_σ	2.6824e-06
Std.Dev min	σ_{min}	0.02

La evolución del desempeño del agente durante el entrenamiento se analiza a partir del RMSE global evaluado en distintos checkpoints. Como se muestra en la Fig. 45, el comportamiento presenta una alta variabilidad, sin una tendencia monótona clara, debido a la naturaleza estocástica del entorno con perturbaciones completamente aleatorias. Se observan fases de mejora y degradación, reflejando la dificultad del agente para adaptarse simultáneamente a múltiples condiciones dinámicas.

El mejor desempeño se alcanza en el entorno de los 300 episodios, donde se obtiene el mínimo RMSE global (≈35.61°), destacando como el punto óptimo dentro del proceso de entrenamiento. Con base en estas evaluaciones, se realiza la selección del agente considerando múltiples métricas de desempeño, tal como se resume en la Tabla 6. El agente correspondiente al checkpoint 300 (Agent300) presenta el menor RMSE global y un comportamiento competitivo en el resto de las métricas, posicionándose como la mejor solución global dentro del conjunto evaluado.

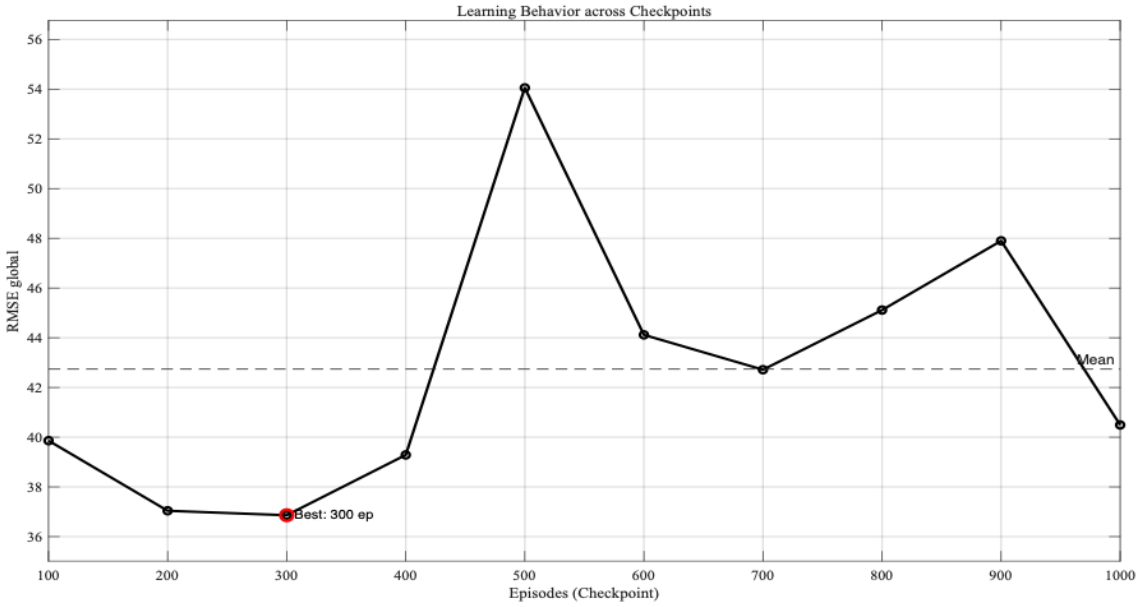

Fig. 45. Evolución del RMSE global a lo largo de los checkpoints de entrenamiento. Fuente: Elaboración propia. Enlace.

Tabla 6. Tabla de evaluación y selección del agente basada en métricas de desempeño. Fuente: Elaboración propia

Position	Agente	$RMSE_{global}$	$RMSE_{max}$	$\sigma_{angular}$	$Ratio_{ext}$	AUC
1	Agent300.mat	36.8605	72.4756	19.4134	1.9662	35.3029
2	Agent200.mat	37.0402	69.7293	17.2820	1.8825	35.5885
3	Agent400.mat	39.2867	75.4535	17.4646	1.9206	38.0429
4	Agent100.mat	39.8603	79.8937	19.1098	2.0043	38.4253
5	Agent1000.mat	40.4916	82.4769	21.9402	2.0369	38.9010
6	Agent700.mat	42.7140	73.2960	17.2925	1.7160	41.6420
7	Agent600.mat	44.1162	77.5349	19.8403	1.7575	42.5048
8	Agent800.mat	45.1127	77.8606	18.2310	1.7259	44.1669
9	Agent900.mat	47.8977	179.8421	50.2923	3.7547	40.9533
10	Agent500.mat	54.0507	107.8342	36.0303	1.9951	51.6330

Para validar la consistencia del desempeño, la Fig. 46 muestra la comparación del RMSE en el dominio angular para los tres mejores checkpoints seleccionados. Se observa que los agentes presentan un comportamiento similar, con un mínimo en la región central del dominio y un incremento progresivo del error hacia los extremos.

No obstante, el agente correspondiente al checkpoint 300 mantiene de forma consistente los menores niveles de error en la mayor parte del dominio, así como una distribución más uniforme, lo que confirma su selección como la mejor solución global. Asimismo, se aprecia una mayor dispersión entre las curvas en regiones extremas del dominio angular, evidenciando que, a pesar del

entrenamiento con perturbaciones aleatorias, persisten limitaciones en la generalización bajo condiciones más exigentes.

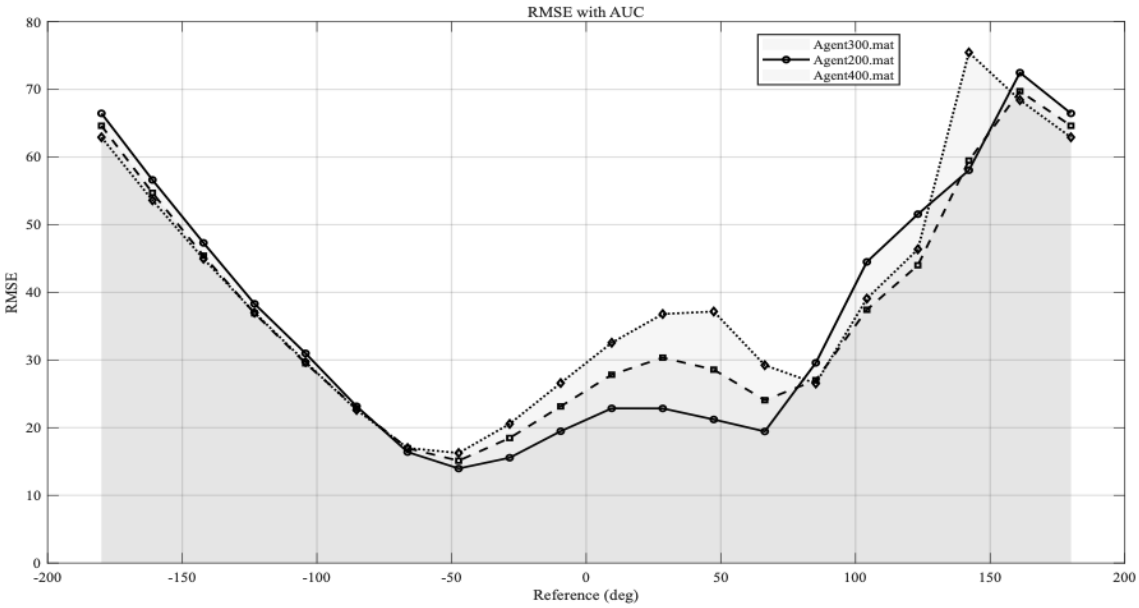

Fig. 46. Comparación del RMSE angular de los mejores 3 checkpoints del agente RL. Fuente: Elaboración propia. Enlace.

1.3.2 Evaluación del controlador RL en Plataforma Plana

La Fig. 47 muestra la evaluación del RMSE en el dominio angular ante variaciones del ángulo inicial o1ini. El comportamiento mantiene la forma característica, con un mínimo en la región central del dominio y un incremento progresivo del error hacia los extremos.

A nivel global, el mejor desempeño se obtiene para o1ini = −90° (RMSE ≈32.60°), seguido de o1ini = 90° (≈34.14°) y o1ini = 0° (≈35.09°). Estos resultados evidencian una asimetría en la respuesta del agente, donde ciertas condiciones iniciales resultan más favorables. En los extremos del dominio angular se observan incrementos significativos del error, con picos localizados que reflejan trayectorias más exigentes. No obstante, el agente mantiene un comportamiento estable en todo el rango, evidenciando una adecuada capacidad de generalización en condiciones nominales.

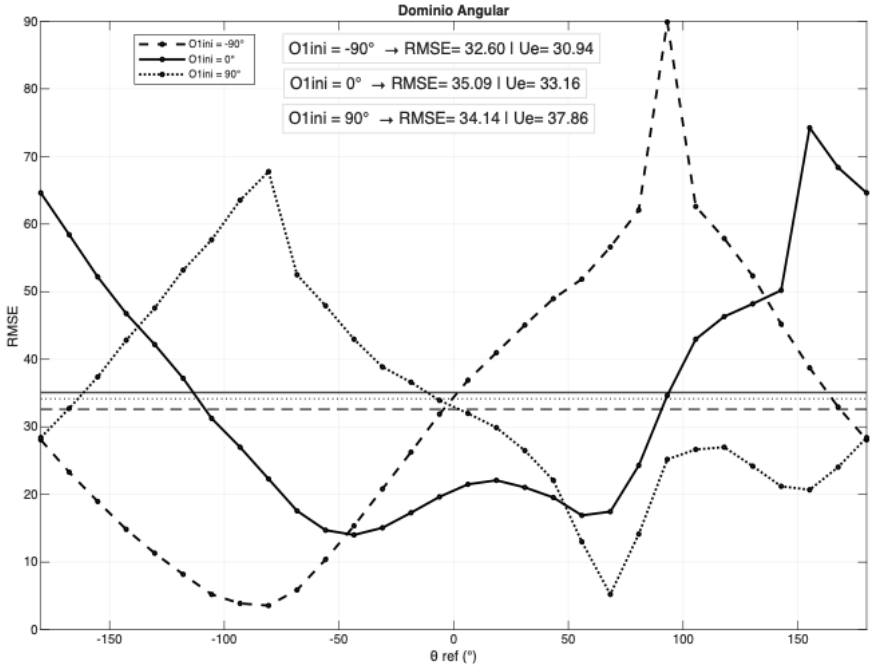

Fig. 47. Evaluación del RMSE en el dominio angular bajo variación del ángulo inicial o1ini, plataforma plana. Fuente: Elaboración propia. Enlace.

Las Fig. 48–51 muestran la respuesta temporal del sistema ante variaciones del ángulo inicial o1ini en los distintos sectores de operación. En general, el sistema converge hacia la referencia en todos los casos, evidenciando estabilidad global del controlador. Sin embargo, el comportamiento transitorio presenta una dependencia clara del estado inicial. Para condiciones cercanas a la referencia, la convergencia es rápida y con bajo sobreimpulso, mientras que para valores extremos (±90°) se observa un incremento del tiempo de establecimiento y mayores desviaciones iniciales.

En algunos sectores, particularmente cuando la referencia se encuentra alejada de la condición inicial, aparecen trayectorias más exigentes e incluso casos límite donde el sistema requiere recorrer grandes rangos angulares, afectando el desempeño transitorio. En conjunto, los resultados confirman que el agente mantiene la estabilidad, pero con una respuesta asimétrica y dependiente de las condiciones iniciales, coherente con el comportamiento observado en el análisis del RMSE (véase Anexo 2.12, Resultados Fase 4C, Evaluación Plataforma plana , Enlace)

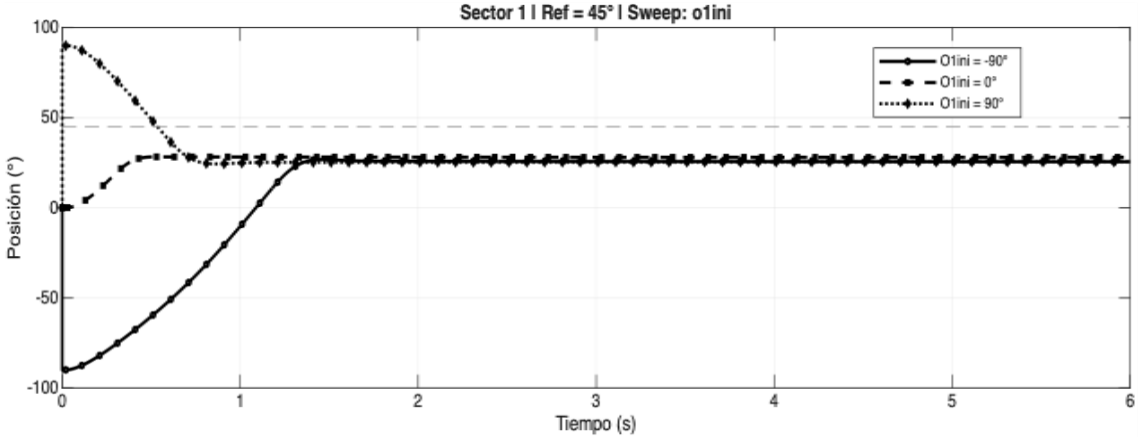

Fig. 48. Respuesta temporal del sistema ante variaciones del ángulo inicial de operación en plataforma plana, Sector 1. Fuente: Elaboración propia. Enlace.

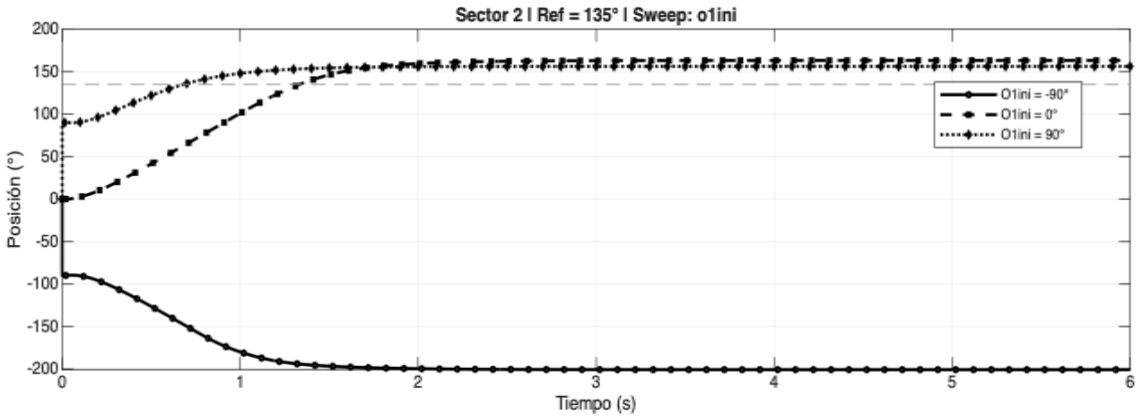

Fig. 49. Respuesta temporal del sistema ante variaciones del ángulo inicial de operación en plataforma plana, Sector 2. Fuente: Elaboración propia. Enlace.

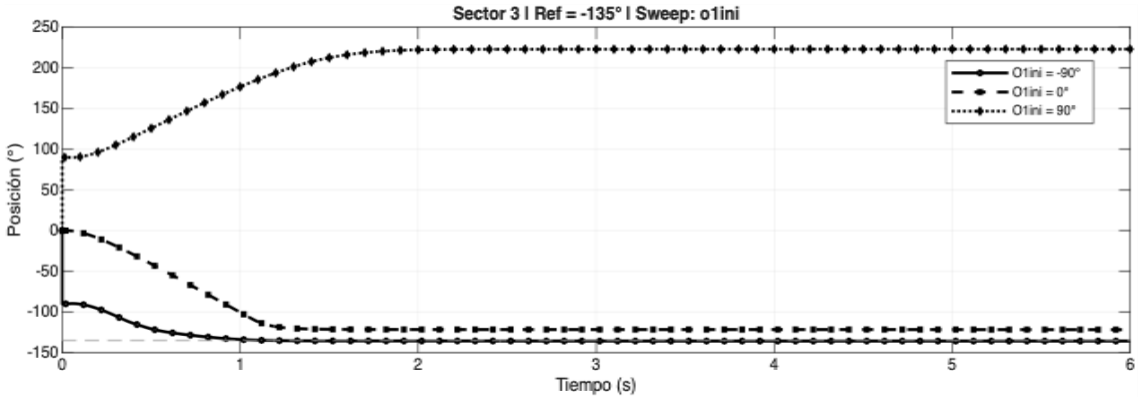

Fig. 50. Respuesta temporal del sistema ante variaciones del ángulo inicial de operación en plataforma plana, Sector 3. Fuente: Elaboración propia. Enlace.

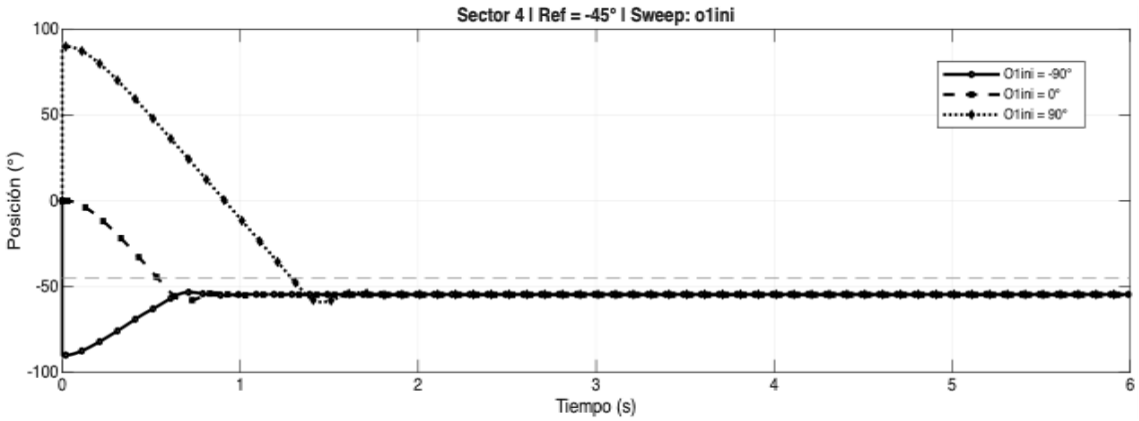

Fig. 51. Respuesta temporal del sistema ante variaciones del ángulo inicial de operación en plataforma plana, Sector 4. Fuente: Elaboración propia. Enlace.

La Fig. 52 muestra la variación del RMSE en el dominio angular ante diferentes valores de retardo en el lazo de control. Los resultados evidencian que el retardo introduce una degradación leve del desempeño, con un incremento marginal del RMSE (≈35.09° → ≈35.52°), sin alterar la forma general de la curva.

En la respuesta temporal (Fig. 53), el sistema mantiene una dinámica prácticamente invariante, con convergencia rápida y sin cambios apreciables en el sobreimpulso ni en el tiempo de establecimiento. En resumen, el retardo considerado (hasta 20 ms) resulta poco significativo para el desempeño global del controlador, confirmando su robustez frente a este tipo de perturbación, en línea con lo observado en la evaluación global.

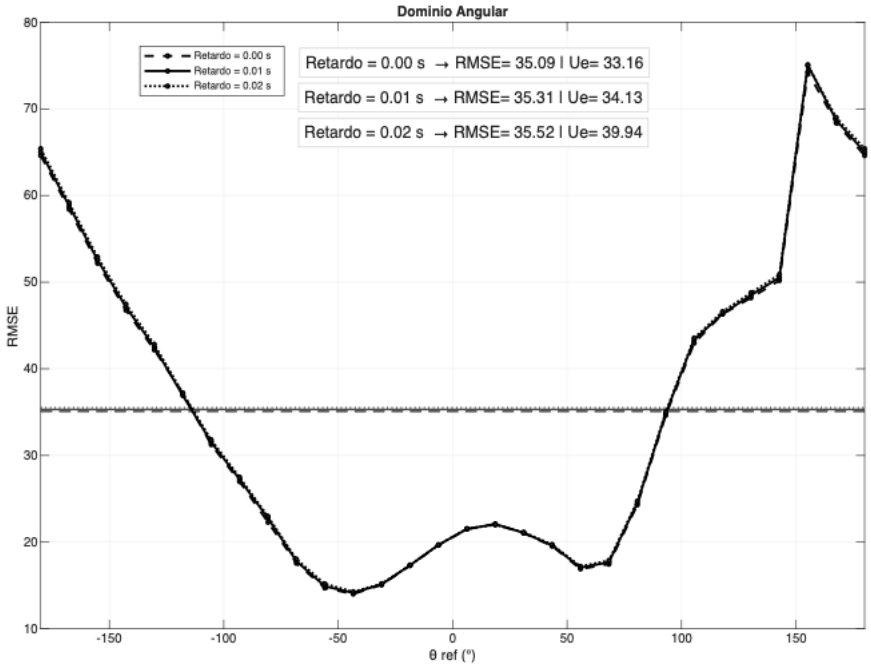

Fig. 52. Evaluación del RMSE en el dominio angular bajo variación retardo de señal. Fuente: Elaboración propia. Enlace.

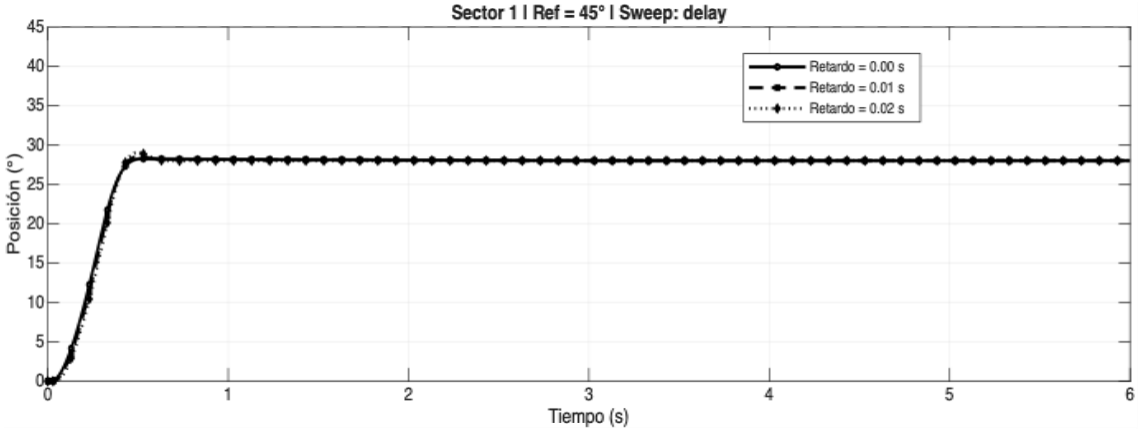

Fig. 53. Respuesta temporal del sistema ante variaciones de retardo en el lazo de control. Fuente: Elaboración propia. Enlace.

La Fig. 54 muestra la variación del RMSE ante cambios en la velocidad angular inicial. Se observa un impacto leve pero asimétrico, donde el mejor desempeño se obtiene para valores negativos (≈34.49°), mientras que velocidades positivas incrementan el error (≈36.57°). La forma global de la curva se mantiene, aunque con un aumento del error en los extremos del dominio angular, indicando una mayor sensibilidad del sistema en condiciones más exigentes.

En la respuesta temporal (Fig. 55), el sistema converge en todos los casos, pero el transitorio se ve afectado por la velocidad inicial. Valores mayores generan mayores desviaciones iniciales y ligeros incrementos en el esfuerzo de control, sin afectar el error en régimen estacionario. La velocidad angular inicial introduce una degradación moderada y dependiente del signo, manteniendo la estabilidad del sistema pero evidenciando asimetrías en la dinámica, coherentes con el comportamiento global observado.

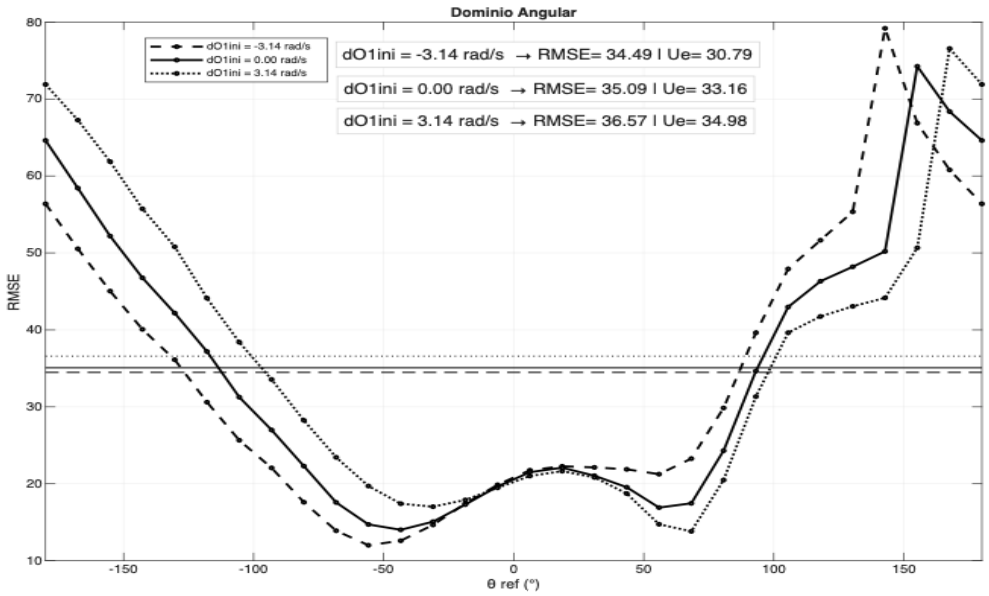

Fig. 54. Evaluación del RMSE en el dominio angular bajo variación de la velocidad angular inicial do1ini, plataforma plana. Fuente: Elaboración propia. Enlace.

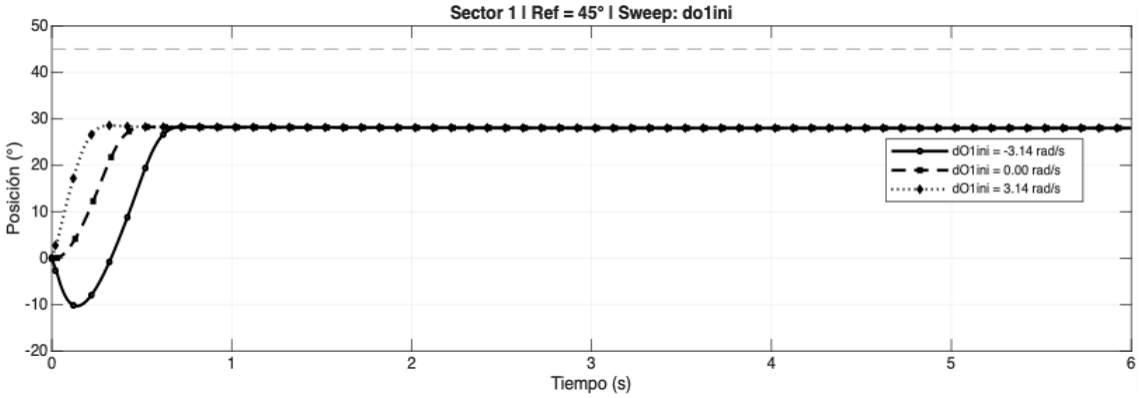

Fig. 55. Respuesta temporal del sistema ante variaciones de la velocidad angular inicialen plataforma plana. Fuente: Elaboración propia. Enlace.

1.3.3 Evaluación del controlador RL en plataforma inclinada

La Fig. 56 presenta la evaluación del RMSE en el dominio angular bajo condiciones de inclinación (pitch–roll = −10°). A diferencia de la plataforma plana, se observa una degradación general del desempeño, con incrementos significativos del error, especialmente en los extremos del dominio angular.

El comportamiento mantiene la tendencia global, pero con una mayor dispersión y pérdida de simetría, evidenciando una mayor sensibilidad del sistema ante las condiciones iniciales. En particular, el caso o1ini = 0° presenta el mayor error (≈57.25°), mientras que o1ini = 90° (≈34.89°) muestra el mejor desempeño relativo, invirtiendo la tendencia observada en plataforma plana.

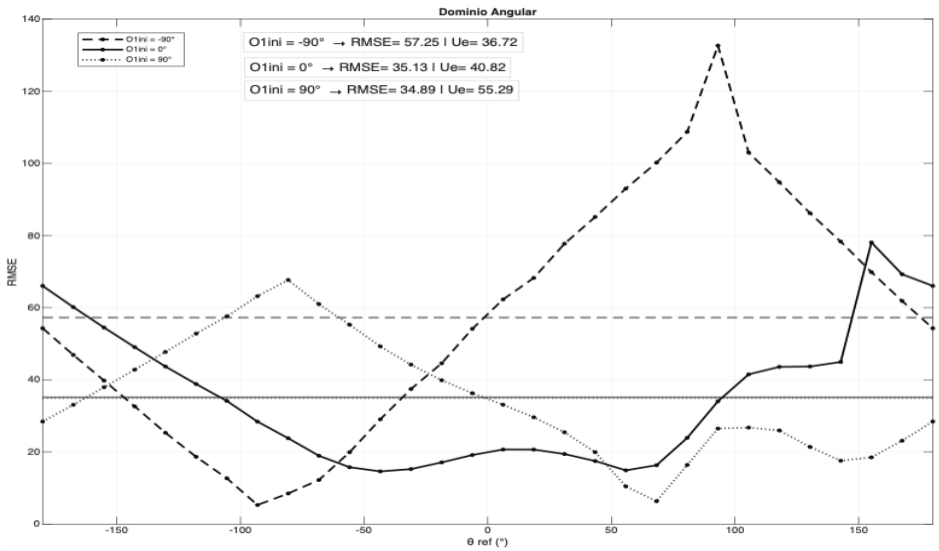

Fig. 56. Evaluación del RMSE en el dominio angular bajo variación retardo de señal en plataforma inclinada, pitch=roll= -10°. Fuente: Elaboración propia. Enlace.

En la respuesta temporal (Fig. 57), el sistema continúa convergiendo hacia la referencia en todos los casos, pero con un transitorio más lento y mayores desviaciones iniciales, especialmente para condiciones desfavorables. La inclinación introduce una perturbación persistente que el controlador compensa, aunque a costa de un mayor esfuerzo y degradación del rendimiento. Los resultados muestran que la inclinación afecta de forma notable al desempeño del agente, reduciendo su capacidad de generalización y acentuando la dependencia de las condiciones iniciales.

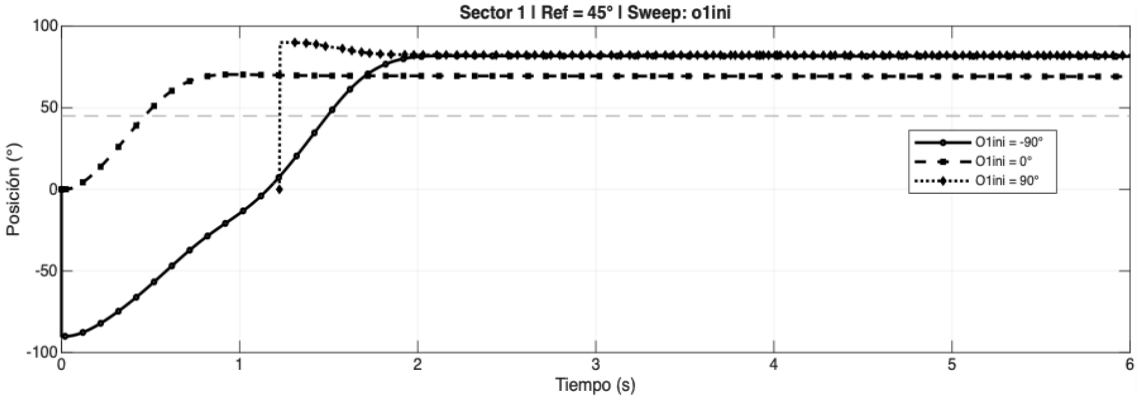

Fig. 57. Respuesta temporal del sistema ante variaciones del ángulo inicial de operación en plataforma inclinada pitch=roll= -10. Fuente: Elaboración propia. Enlace.

La Fig. 58 muestra la variación del RMSE en el dominio angular bajo la presencia de retardo en una plataforma inclinada (pitch–roll = −10°). De forma similar al caso en plataforma plana, el retardo introduce una degradación leve del desempeño, con un incremento marginal del RMSE (≈35.13° → ≈35.56°), manteniendo prácticamente inalterada la forma de la curva.

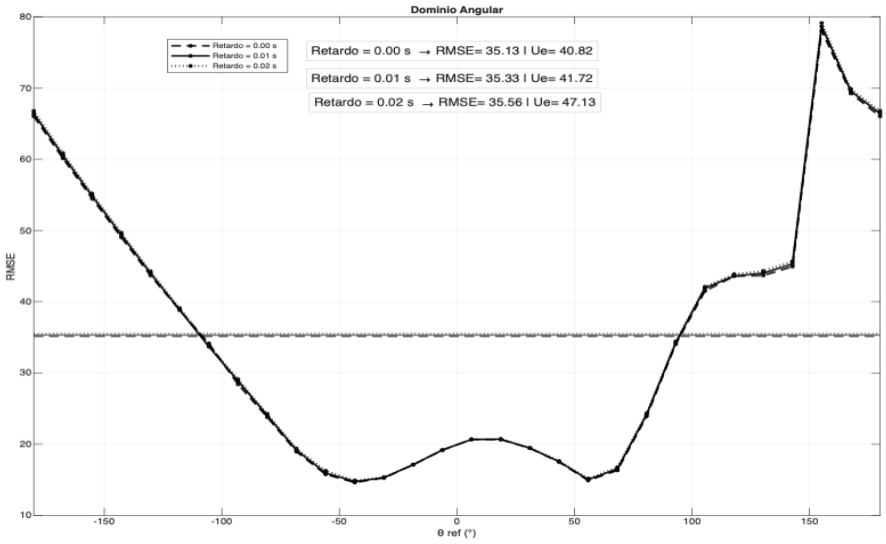

Fig. 58. Evaluación del RMSE en el dominio angular bajo variación retardo de señal en plataforma inclinada, pitch=roll= -10°. Fuente: Elaboración propia. Enlace.

En la respuesta temporal (Fig. 59), el sistema presenta una dinámica robusta frente al retardo, conservando la velocidad de convergencia y sin cambios significativos en el sobreimpulso o en el tiempo de establecimiento. El retardo analizado no constituye un factor limitante relevante, incluso bajo condiciones de inclinación, manteniéndose un comportamiento estable y consistente del controlador.

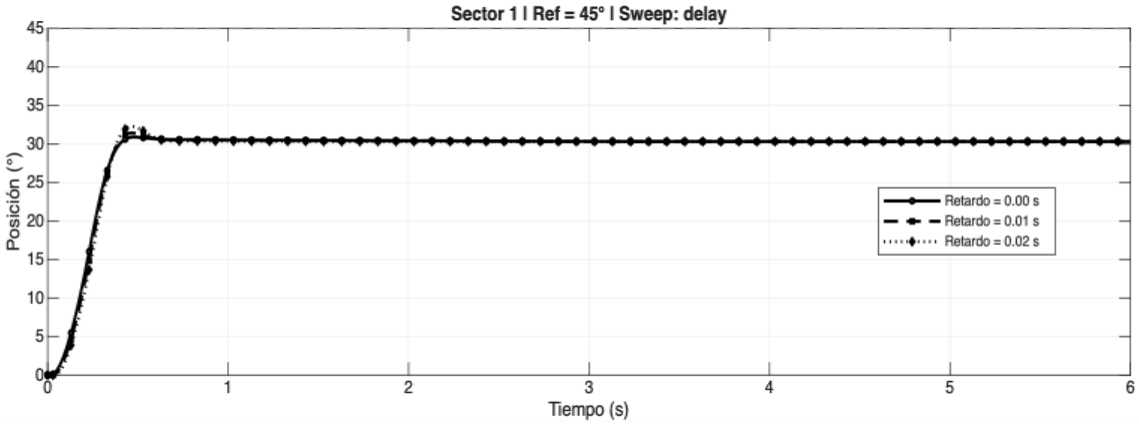

Fig. 59. Respuesta temporal del sistema ante retardo en el lazo de control en plataforma inclinada pitch=roll= -10. Fuente: Elaboración propia. Enlace.

La Fig. 60 muestra la influencia de la velocidad angular inicial sobre el RMSE en el dominio angular bajo condiciones de inclinación. Se mantiene un comportamiento similar al observado en plataforma plana, aunque con mayor dispersión y sensibilidad en los extremos, reflejando el efecto combinado de ambas perturbaciones. El mejor desempeño se obtiene para valores negativos de velocidad inicial (≈32.94°), mientras que velocidades positivas incrementan el error (≈36.94°), evidenciando nuevamente una respuesta asimétrica del sistema.

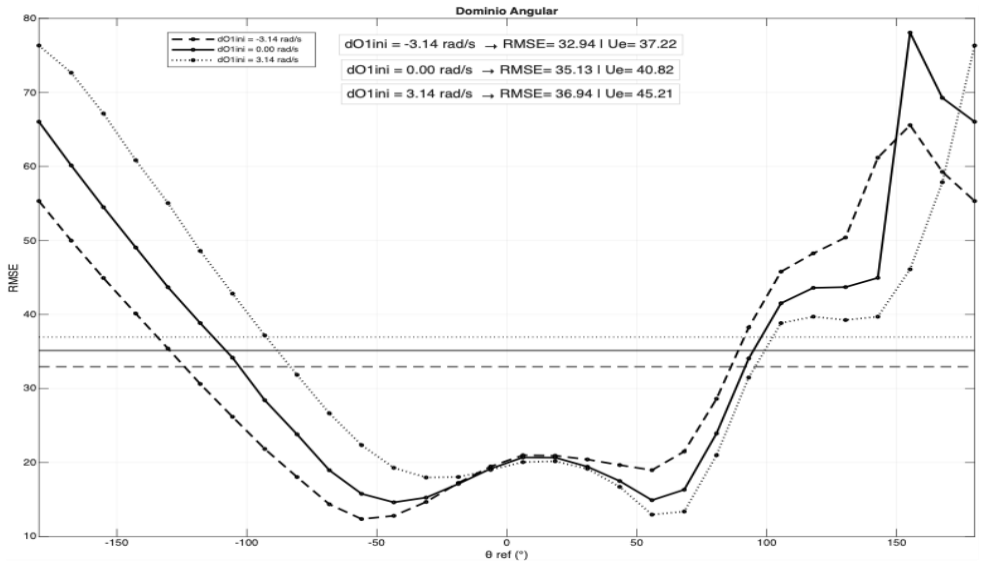

Fig. 60. Evaluación del RMSE en el dominio angular bajo variación de la velocidad angular inicial do1ini, plataforma inclinada pitch=roll=-10°. Fuente: Elaboración propia. Enlace.

En la respuesta temporal (Fig. 61), el sistema converge en todos los casos, pero el transitorio muestra diferencias más marcadas que en la plataforma plana. En particular, velocidades iniciales elevadas generan mayores desviaciones iniciales y trayectorias más exigentes, aunque sin comprometer la estabilidad final. La inclinación amplifica el efecto de la velocidad inicial, haciendo más evidente la dependencia del desempeño respecto al estado dinámico inicial del sistema.

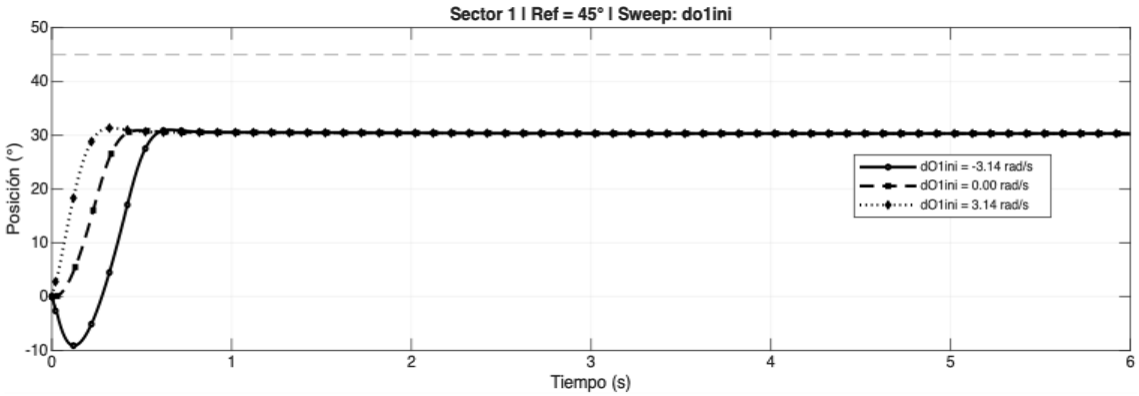

Fig. 61. Respuesta temporal del sistema ante variaciones de la velocidad angular inicialen plataforma inclinada pitch=roll=-10°. Fuente: Elaboración propia. Enlace.

1.3.4 Comparación PID vs controlador RL Fase 4C

Las Fig. 62 y Fig. 63 presentan la comparación del RMSE en el dominio angular entre el controlador PID y el agente RL entrenado en la Fase 4C, tanto en plataforma plana como inclinada.

En plataforma plana, ambos controladores muestran un comportamiento similar en gran parte del dominio. El PID alcanza un menor error medio (μ≈31.39°) frente al RL (μ≈35.13°), especialmente en la región central, donde presenta valores mínimos más bajos. No obstante, el agente RL mantiene una respuesta más homogénea en ciertas zonas, evitando caídas bruscas pero con un error global ligeramente superior.

En plataforma inclinada, la diferencia se acentúa. El PID incrementa significativamente su error (μ≈40.55°), mientras que el agente RL mantiene prácticamente constante su desempeño (μ≈35.13°). Esto indica una mayor robustez del controlador basado en aprendizaje por refuerzo frente a perturbaciones estructurales, como la inclinación de la plataforma. Además, el RL presenta una mejor adaptación en regiones alejadas de la referencia, donde el PID muestra un crecimiento más pronunciado del error. Sin embargo, el RL también exhibe picos localizados en condiciones específicas, reflejando limitaciones en la generalización completa del espacio de estados.

En términos comparativos, el PID resulta competitivo en condiciones nominales, pero el controlador RL ofrece mayor consistencia y robustez ante perturbaciones,

lo que lo posiciona como una alternativa más adecuada en entornos variables o no modelados.

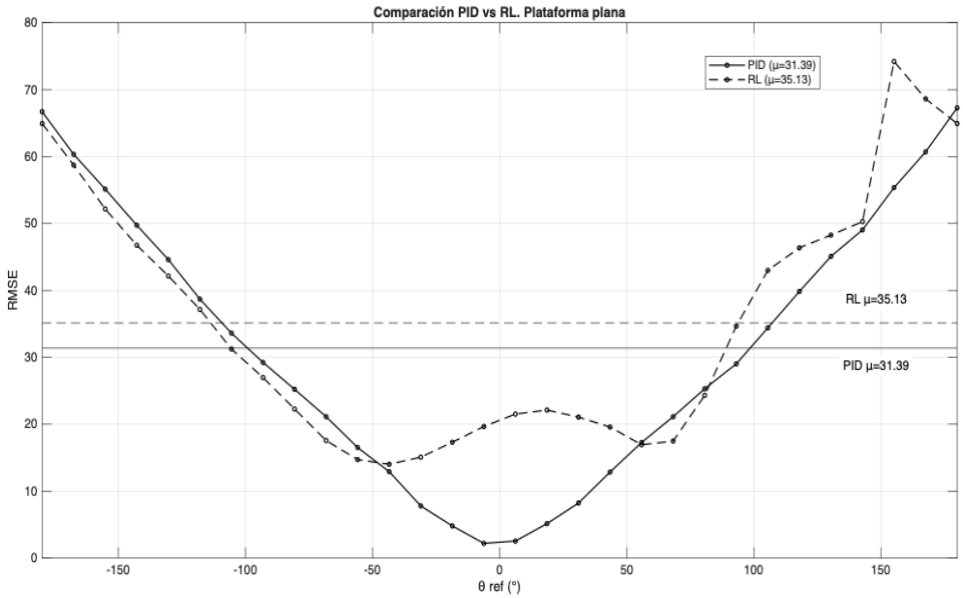

Fig. 62. Evaluación del RMSE en el dominio angular del PID vs Controlador RL Fase4C, plataforma plana. Fuente: Elaboración propia. Enlace.

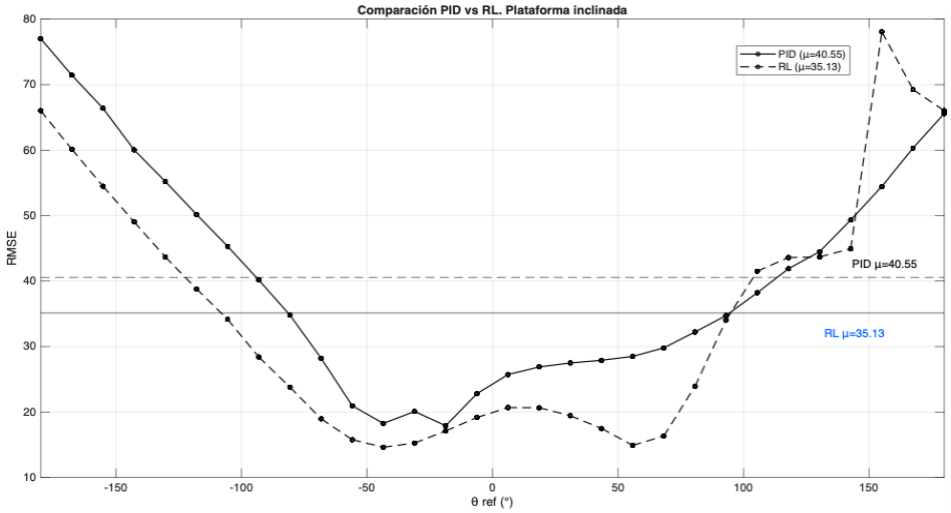

Fig. 63. Evaluación del RMSE en el dominio angular del PID vs Controlador RL Fase4C, plataforma inclinada, pitch= roll= -10°. Fuente: Elaboración propia. Enlace.

1.3.5 Conclusión Fase 4C

El agente RL entrenado bajo perturbaciones aleatorias mantiene un desempeño estable en todos los escenarios analizados, con un RMSE en plataforma plana comprendido entre 32.60° y 36.57°, y en plataforma inclinada entre 32.94° y

57.25°, dependiendo de las condiciones iniciales (véase Anexo 2.12, Tabla de resultados Fase 4C, Enlace).

El retardo presenta un impacto mínimo, con variaciones inferiores a 0.5° en RMSE, mientras que las condiciones iniciales (o1ini) siguen siendo el factor dominante, alcanzando el peor caso en inclinación (57.25°). Por su parte, la velocidad angular inicial introduce variaciones moderadas, manteniendo el error en un rango acotado (≈33°–37°). En general, el agente demuestra estabilidad global y capacidad de adaptación simultánea a múltiples perturbaciones, manteniendo un comportamiento consistente incluso en condiciones no favorables.

1.4 Conclusión Fase 4

La evolución del agente RL a lo largo de las fases 4A, 4B y 4C muestra una transición desde un comportamiento más preciso pero específico hacia uno más robusto y generalista. En la Fase 4A, el agente alcanza los menores valores de RMSE en condiciones nominales (≈29°–30° en plataforma plana), pero con menor capacidad de adaptación ante perturbaciones, véase Tabla 7.

Tabla 7. Métricas de seguimiento (RMSE) y esfuerzo de control (U_energy) del agente RL en Fase 4A. Fuente: Elaboración propia. Enlace.

	Seguimiento		Esfuerzo	
	Plataforma plana [RMSE]	**Plataforma Inclinada [RMSE]**	**Plataforma plana [U_energy]**	**Plataforma Inclinada [U_energy]**
Retardo=0ms	29.73	28.67	31.42	41.11
Retardo=0.01ms	29.78	29.02	31.79	41.72
Reatardo=0.02ms	29.53	29.08	32.28	42.55
o1ini=-90°	33.52	33.01	35.51	46.05
o1ini= 0°	29.73	28.67	31.42	41.11
o1ini=90°	30.94	31.46	30.70	50.02
do1ini = -0.5rad/s	29.78	28.99	31.25	40.02
do1ini = 0rad/s	29.73	28.67	31.42	41.11
do1ini = 0.5rad/s	29.12	29.67	30.88	4312

En la Fase 4B, el uso de curriculum learning incrementa el error medio (≈36°–37°), pero mejora la estabilidad frente a variaciones, aunque todavía presenta sensibilidad a condiciones iniciales (hasta ≈42.59° en inclinada), véase Tabla 8.

Tabla 8. Métricas de seguimiento (RMSE) y esfuerzo de control (U_energy) del agente RL en Fase 4B. Fuente: Elaboración propia. Enlace.

	Seguimiento		Esfuerzo	
	Plataforma plana [RMSE]	**Plataforma Inclinada [RMSE]**	**Plataforma plana [U_energy]**	**Plataforma Inclinada [U_energy]**
Retardo=0ms	36.69	36.25	33.31	46.33
Retardo=0.01ms	36.71	36.60	33.49	46.37
Reatardo=0.02ms	36.92	36.53	33.70	46.64
o1ini=-90°	41.64	42.59	37.89	45.79
o1ini= 0°	36.69	36.25	33.31	46.33
o1ini=90°	35.19	38.64	30.30	46.82
do1ini = -0.5rad/s	34.35	35.18	34.83	44.79
do1ini = 0rad/s	36.69	36.25	33.31	46.33
do1ini = 0.5rad/s	35.72	37.41	35.07	47.94

Finalmente, en la Fase 4C, el entrenamiento con perturbaciones aleatorias estabiliza el comportamiento del agente, manteniendo el RMSE en un rango más consistente (≈32°–36° en plana y ≈33°–36° en la mayoría de casos inclinados), reduciendo la sensibilidad a perturbaciones dinámicas y mejorando el desempeño en escenarios no vistos, aunque con penalización en casos extremos (hasta ≈57.25°), véase Tabla 9.

Tabla 9. Métricas de seguimiento (RMSE) y esfuerzo de control (U_energy) del agente RL en Fase 4C. Fuente: Elaboración propia. Enlace

	Seguimiento		Esfuerzo	
	Plataforma plana [RMSE]	**Plataforma Inclinada [RMSE]**	**Plataforma plana [U_energy]**	**Plataforma Inclinada [U_energy]**
Retardo=0ms	35.09	35.13	33.16	40.82
Retardo=0.01ms	35.31	35.33	34.13	41.72
Reatardo=0.02ms	35.52	35.56	39.94	47.13
o1ini=-90°	32.60	57.25	30.94	36.72
o1ini= 0°	35.09	35.13	33.16	40.82
o1ini=90°	34.14	34.89	37.86	55.29
do1ini = -0.5rad/s	34.49	32.94	30.79	37.22
do1ini = 0rad/s	35.09	35.13	33.16	40.82
do1ini = 0.5rad/s	36.57	36.94	34.98	45.21

Esta progresión evidencia que el agente evoluciona desde un controlador ajustado a condiciones específicas hacia un sistema más robusto, consistente y competitivo en entornos inciertos, siendo la Fase 4C la que mejor equilibra desempeño y capacidad de generalización.

Referencias Bibliográficas

Achiam, J. (Jan de 2026). *https://spinningup.openai.com/en/latest/algorithms/td3.html*. Obtenido de SpinningUp OpenAI: https://spinningup.openai.com/en/latest/algorithms/td3.html

Dankwa, S., & Wenfeng, Z. (2019). Twin-Delayed DDPG: A Deep Reinforcement Learning Technique to Model a Continuous Movement of an Intelligent Robot Agent. *ICVISP 2019, Proceedings of the 3rd International Conference on Vision, Image and Signal Processing*.

Fujimoto, S., Van Hoof, H., & Meger, D. (2018). *Addressing Function Approximation Error in Actor-Critic Methods.* Stockholm, Sweden: PMLR (Proceedings of Machine Learning Research).

Gamal, Z., Mahran, Y., & El-Badawy, A. (2024). *Control of a Twin Rotor using Twin Delayed Deep Deterministic Policy Gradient (TD3).* Egypt: 28th International Conference on System Theory, Control and Computing (ICSTCC).

García, J. M., Medina, I. J., Martinez, J. L., García-Cerezo, A., Linares, A., & Porras, C. (2017). *Lázaro: Robot Móvil dotado de Brazo para Contacto con el Suelo.*

García, J. M., Medina, I., Cerezo, A. G., & Linares, A. (2015). Improving The Static Stability Of A Mobile Manipulator Using Its End Effector In Contact With The Ground. 3228-3234.

García, J., Bohórquez, A., & Valero, A. (2020). Suspension Effect in Tip-Over Stability and Steerability of Robots Moving on Sloping Terrains. *IEEE LATIN AMERICA TRANSACTIONS*, 1381-1389.

Hazem, Z. B., Saidi, F., Guler, N., & Altaif, A. H. (2025). A Hybrid Reinforcement Learning Framework Combining TD3 and PID Control for Robust Trajectory Tracking of a 5-DOF Robotic Arm. *automation*.

Khoi, P. B., Giang, N. T., & Tan, H. V. (2021). Control and Simulation of a 6-DOF Biped Robot based on Twin Delayed Deep Deterministic Policy Gradient Algorithm. *Indian journal of Science and Technology*.

Kim, M., Han, D.-K., Park, J.-H., & Kim, J.-S. (2020). Motion Planning of Robot Manipulators for a Smoother Path Using a Twin Delayed Deep Deterministic Policy Gradient with Hindsight Experience Replay. *Applied Science*, 10,575.

Li, H. (2024). *Machine Learning Methods.* Quanzhou, China: Springer.

Lunze, J. (2014). *Regelungstechnik 1 . Systemtheoretische Grundlangen, Analyse und Entwurfe einschleifiger Regelung.* Berlin: Springer Vieweg.

M., G. J., L., M. J., A., M., & A., G.-C. (2017). Caster-legaidedmaneuverfornegotiatingsurfacediscontinuities withawheeledskid-steermobilerobot. *RoboticsandAutonomousSystems*, 25-37.

M., H. (2019). *Grundlagen der Robotik.* Berlin: VDE Verlag.

Mahran, Y., Gamal, Z., & El-Badawy, A. (2024). *Reinforcement Learning Position Control of a Quadrotor Using Soft Actor-Critic (SAC).* Egypt: publication in the IEEE 6th Novel Intelligent and Leading Emerging Sciences Conference (NILES).

Martínez, J. L., Mandow, A., & García-Cerezo, A. (2017). Slide-Down Prevention for Wheeled Mobile Robots on Slopes. *ACM*.

MatlabWorks. (Januar de 2026). *Reinforcement Learning Toolbox*. Obtenido de MATLAB Hilfe-Center: https://de.mathworks.com/help/reinforcement-learning/index.html?utm_source=chatgpt.com

Mosali, N. A., Shamsudin, S. S., & Omar Alfandi, R. O.-F. (2022). Twin Delayed Deep Deterministic Policy Gradient-Based Target Tracking for Unmanned Aerial Vehicle With Achievement Rewarding and Multistage Training. *IEEE Access*.

OpenAI. (26 de 01 de 2026). *Spinning Up in Deep Reinforcement Learning: DDPG*. Obtenido de OpenAI: https://spinningup.openai.com/en/latest/algorithms/ddpg.html#the-q-learning-side-of-ddpg

Plaat, A. (2022). *Deep Reinforcement Learnig.* Netherlands: Springer.

Sutton, R. S., & Barto, A. G. (2018). *Reinforcement Learning.* London, England: The MIT Press.

Wittpahl, V. (2019). *Künstliche Intelligenz, technologie, Anwendung, Gesellschaft.* Berlin: Springer Verlag.

2 Anexos

https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia

2.1 Modo en el Entrenamiento

Modos en el Entrenamiento: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/InformacionGeneral/MetodosEntrenamiento.pdf*

2.2 Evaluación en las fases

Evaluación en las fases: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/InformacionGeneral/MetodologiaEvaluacion.pdf*

2.3 Proceso de Decision de Markov (MDP)

Proceso de Decision de Markov (MDP): [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/InformacionGeneral/El%20Proceso%20de%20Decisión%20de%20Markov%20(MDP).pdf*

2.4 Vector de observaciones

Bus Vector de Observaciones: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/ArquitecturaAgente/Observacion/BusVectorObservacion.pdf*

Observables: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/ArquitecturaAgente/Observacion/Observation.pdf*

2.5 Anexo Bufferlength

Bufferlength: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/InformacionGeneral/EvaluacionImpactoBufferlength.pdf*

2.6 Warm-Start Steps

Warm-start Steps: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/InformacionGeneral/EvaluacionImpactoWarmStartSteps.pdf*

2.7 Anexo policy Exploration Gaussian

Exploracion Gaussiana: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/InformacionGeneral/EvaluacionImpactoPolicyExplorationGaussian.pdf*

2.8 Anexo Learning Rate Actor Critic

Taza de Aprendizaje: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/InformacionGeneral/EvaluacionImpactoLearningRate.pdf*

2.9 Anexo Mini Batchsize

Minie Batchsize: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/InformacionGeneral/EvaluacionImpactoBatchsize.pdf*

2.10 TD3 Redes Neuronales

Redes Neuronales TD3: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/ArquitecturaAgente/05_Redes/RedesActorCritico.pdf*

2.11 Función de Recompensa

Función de Recompensa: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/tree/main/ArquitecturaAgente/03_FuncionRecompensas*

Función de Recompensa Sistema A: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/ArquitecturaAgente/03_FuncionRecompensas/Reward_System_A.pdf*

Función de Recompensa Sistema D: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/ArquitecturaAgente/03_FuncionRecompensas/Reward_System_D.pdf*

Función de Recompensa Sistema F: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/ArquitecturaAgente/03_FuncionRecompensas/Reward_System_F.pdf*

2.12 Anexo Resultados

Fase 1:

Fase 1 plataforma plana: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase1/03_results/Evaluación%20PID–%20Plataforma%20plana%20%20.pdf*

Fase 1 plataforma inclinada: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase1/03_results/Evaluación%20PID–%20Plataforma%20Inclinada.pdf*

Fase1 tabla de resultados: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase1/03_results/TablaResultadosFase1.pdf*

Fase 2:

Fase 2 Entrenamiento: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase2/03_results/EvaluacionEntrenamiento.pdf*

Fase 2 plataforma plana: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase2/03_results/EvaluacionAgenteRL_F2–%20Plataforma%20plana%20%20.pdf*

Fase 2 plataforma inclinada: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase2/03_results/EvaluacionAgenteRL_F2–%20Plataforma%20Inclinada.pdf*

Fase 2 Tabla de resultados: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase2/03_results/TablaResultadosFase2.pdf*

Fase 2 Comparación PID vs RL: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase4/03_results/FaseC/ComparacionPID_vs_RL_F4C_Agente300/ComparacionPIDvsRL300.png*

Fase 3:

Fase 3 Entrenamiento: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase3/03_results/EvaluacionEntrenamiento.pdf*

Fase 3 plataforma plana: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase3/03_results/Evaluación%20AgenteRL_F3–%20Plataforma%20plana%20%20.pdf*

Fase 3 plataforma inclinada: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase3/03_results/Evaluación%20AgenteRL_F3–%20Plataforma%20Inclinada.pdf*

Fase 3 Tabla de resultados: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase2/03_results/TablaResultadosFase2.pdf*

Fase 3 Comparación PID vs RL: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase3/03_results/ComparacionPID_vs_RL_F3.pdf*

Fase 4A:

Fase 4A Entrenamiento: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase4/03_results/FaseA/EvaluacionEntrenamientoFaseA_Agente600.pdf*

Fase 4A plataforma plana: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase4/03_results/Evaluación%20AgenteRL_F4A_Agente600–%20Plataformaplana.pdf*

Fase 4A plataforma inclinada: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase4/03_results/FaseA/Evaluación%20AgenteRL_F4A_Agente600–Plataformainclinada.pdf*

Fase 4A Tabla de resultados: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase4/03_results/TablaResultadosFase4A.pdf*

Fase 4A Comparación PID vs RL: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase4/03_results/FaseA/ComparacionPID_vs_RL_F4A_Agente600.pdf*

Fase 4B:

Fase 4B Entrenamiento: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase4/03_results/FaseB/EvaluacionEntrenamientoFaseB_Agente1900.pdf*

Fase 4B plataforma plana: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase4/03_results/FaseB/Evaluación%20AgenteRL_F4B_Agente1900–Plataformaplana.pdf*

Fase 4B plataforma inclinada: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase4/03_results/FaseB/Evaluación%20AgenteRL_F4B_Agente1900–Plataformainclinada.pdf*

Fase 4B Tabla de resultados: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase4/03_results/FaseB/TablaResultadosFase4B.pdf*

Fase 4B Comparación PID vs RL: [Enlace] *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase4/03_results/FaseB/ComparacionPID_vs_RL_F4B_Agente1900.pdf*

Fase 4C:

Fase 4C Entrenamiento: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase4/03_results/FaseC/EvaluacionEntrenamientoFaseC_Agente300.pdf*

Fase 4C plataforma plana: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase4/03_results/FaseC/Evaluación%20AgenteRL_F4C_Agente300–Plataformaplana.pdf*

Fase 4C plataforma inclinada: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase4/03_results/FaseC/Evaluación%20AgenteRL_F4C_Agente300–Plataformainclinada.pdf*

Fase 4C Tabla de resultados: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase4/03_results/FaseC/TablaResultadosFase4C.pdf*

Fase 4C Comparación PID vs RL: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase4/03_results/FaseC/ComparacionPID_vs_RL_F4C_Agente300.pdf*

Fase 5:

Fase 5 plataforma plana: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase5/03_results/Evaluación%20AgenteRL_F5_Politica_Plataformaplana.pdf*

Fase 5 plataforma inclinada: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase5/03_results/Evaluación%20AgenteRL_F5_Politica_Plataformainclinada.pdf*

Fase 5 Tabla de Resultados: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase5/03_results/TablaResultadosFase5.pdf*

Fase 5 Comparación PID vs política neuronal: [Enlace], *https://github.com/RichardSarabia/SimuladorBrazoLazaro_RLAgent_TFM_RicardoSarabia/blob/main/Fase5/03_results/ComparacionPID_vs_Politica_F5.pdf*