Control Monoarticular aplicado en manipuladores móviles utilizando aprendizaje por refuerzo

Universidad Internacional de Valencia

Titulación:

Máster Inteligencia Artificial
Curso académico

2025-2026

Alumno/a:

Sarabia Palacio
Ricardo Enrique

D.N.I: LFTG8GWZ6

Director/a de TFM:
García Caicedo
Jesús Marcey

Convocatoria:

Regular

De:
Planeta Formación y Universidades

Universidad Internacional de Valencia

Índice

1 El Proceso de Decisión de Markov (MDP) 4
1.1 Elementos de MDP 4
1.2 Estados y observaciones 4
1.3 Espacios de Acción 5
1.4 La Política 6
1.4.1 Política determinista μ 7
1.4.2 Política estocástica π 7
1.5 Trayectorias 8
1.6 Recompensa Ra 10
1.7 Factor de descuento γ 11
1.8 Trazas τ 11
1.8.1 Distribución de trazas 12
1.9 Funciones de Valor 13
1.10 Valor del estado $V\pi s$ 13
1.11 Valor de acción $Q\pi s, a$ 14
1.12 Función de ventaja $A\pi s, a$ 14

Índice de ilustraciones

Fig. 1. Tipos de Transicion en MDP: trans. estocastica (izquierda), transc. determinista (centro y derecha). Fuente: (Plaat, 2022). 9

1 El Proceso de Decisión de Markov (MDP)

Los problemas de decisión secuencial se representan con Procesos de Decisión de Markov (MDP), donde el sistema evoluciona según el estado actual y la acción, ignorando estados anteriores. Esta propiedad de Markov simplifica el razonamiento sobre la dinámica futura, ya que toda la información relevante está en el estado presente (Plaat, 2022). A continuación se bordan elementos del proceso MDP.

1.1 Elementos de MDP

Según (Plaat, 2022) el Proceso de Decisión de Markov para aprendizaje por refuerzo se define como una 5-tupla $\mathcal{M} = (S, A, T, R, \gamma)$:

donde:

- S es el conjunto finito de estados posibles del entorno, y s_0 denota el estado inicial.

- A es el conjunto finito de acciones disponibles; en el caso general, cada estado s puede disponer de un subconjunto permitido $A_s \subseteq A$.

- $\mathrm{T}(s, a, s') = \Pr(\, s_{t+1} = s' \mid s_t = s,\ a_t = a\,)$ representa la dinámica del entorno, es decir, la probabilidad de transitar del estado s al estado s' al ejecutar la acción a.

- $\mathrm{R}(s, a, s')$ es la recompensa obtenida al pasar del estado s al estado s' tras aplicar la acción a.

- $\gamma \in [0,1]$ es el factor de descuento, que determina el peso relativo de las recompensas futuras frente a las inmediatas en el proceso de aprendizaje.

Este formalismo proporciona la estructura matemática sobre la cual se puede describir con claridad la interacción entre el agente y el entorno, así como la función objetivo que guía su comportamiento óptimo (Plaat, 2022).

1.2 Estados y observaciones

En el marco de los MDP, el concepto de estado puede adoptar distintas formas según el grado de información disponible y la naturaleza del entorno. Un estado completamente observable contiene toda la información necesaria para predecir la evolución futura del sistema, cumpliendo estrictamente la propiedad de Markov. En contraste, un estado parcialmente observable solo ofrece una fracción de la información relevante, como ocurre en muchos sistemas robóticos donde

las lecturas sensoriales no permiten reconstruir todas las variables internas; en estos casos, pueden emplearse estimadores o representaciones extendidas para aproximar el estado real (Plaat, 2022).

Finalmente, en ciertos problemas se utiliza un estado reducido o abstraído, formado únicamente por las variables mínimas necesarias para la toma de decisiones, lo que simplifica el aprendizaje y reduce la dimensionalidad sin perder capacidad de control. Estas distinciones permiten adaptar el formalismo MDP a diferentes escenarios, desde simulaciones totalmente deterministas hasta entornos físicos con incertidumbre y ruido sensorial.

En un entorno determinista, una acción aplicada en un estado específico conduce siempre al mismo estado siguiente, sin incertidumbre. En un entorno estocástico, en cambio, la misma acción puede producir distintos estados futuros con probabilidades asociadas, reflejando la presencia de ruido, imprecisiones o fenómenos no modelados (Plaat, 2022).

En el caso concreto de ese trabajo, la simulación del Robot Lázaro en MATLAB/Simulink se construye a partir de ecuaciones dinámicas que incluyen fricción viscosa, fricción estática, torque gravitatorio dependiente de la inclinación y retardo de señal en el lazo de control. Todos estos fenómenos —aunque implementados de forma determinista— reproducen comportamientos típicos de un sistema físico real: pérdida de movimiento por fricción, cambios en el esfuerzo del actuador según el ángulo del robot, o degradación del control por latencia.

Así, aunque el entorno de simulación no introduce aleatoriedad explícita, sí representa una dinámica compleja y altamente sensible a sus condiciones, lo que aproxima su funcionamiento al de un sistema real. Esta característica resulta especialmente relevante para el aprendizaje por refuerzo, ya que permite entrenar al agente en un escenario que refleja con fidelidad los efectos no lineales y las limitaciones físicas que se presentarían en la operación del robot.

1.3 Espacios de Acción

La acción representa la decisión que el agente ejecuta cuando se encuentra en un estado determinado. La acción seleccionada depende de la política de comportamiento $\pi(a|s)$, y una vez enviada al entorno, provoca un cambio irreversible en su dinámica: el entorno transita a un nuevo estado y devuelve una recompensa. Esta irreversibilidad refleja el funcionamiento real de muchos sistemas físicos, donde no existe un mecanismo para “deshacer” una acción una vez aplicada (Plaat, 2022).

El conjunto de acciones disponibles puede variar según el estado. En algunos entornos, las acciones son discretas, como seleccionar un movimiento entre un conjunto finito. En otros casos —especialmente en robótica— las acciones son continuas, ya que los actuadores requieren señales de control expresadas como valores reales (por ejemplo, torques o velocidades articulares).

Esta distinción tiene consecuencias importantes para los métodos de aprendizaje por refuerzo profundo, ya que ciertos algoritmos están diseñados exclusivamente para espacios discretos, mientras que otros pueden operar únicamente en espacios continuos. Por ejemplo, problemas de control robótico suelen requerir políticas que produzcan acciones continuas, lo cual motiva el uso de algoritmos específicos capaces de manejar este tipo de espacios (Plaat, 2022).

1.4 La Política

la política π constituye el elemento central del aprendizaje por refuerzo, ya que define cómo debe actuar un agente ante un estado del entorno. Formalmente, la política es una función que asigna a cada estado $s \in S$ una distribución de probabilidad sobre el espacio de acciones A (Plaat, 2022):

$$\pi: S \rightarrow p(A) \tag{1}$$

Donde $p(A)$puede representar una distribución discreta o continua (Plaat, 2022). De esta distribución se obtiene la probabilidad de seleccionar una acción particular dado un estado:

$$\pi(a \mid s) \tag{2}$$

En tareas con espacios de acción finitos, una política puede representarse explícitamente como una tabla de probabilidades. Sin embargo, en control continuo —como en el movimiento de la articulación θ_1 del robot Lázaro— el conjunto de acciones es un intervalo real, y por tanto la política debe ser modelada mediante una función paramétrica capaz de generar acciones en un dominio continuo.

Un caso particular de política es la política determinista, que asigna una única acción a cada estado:

$$\pi(s): S \rightarrow A. \tag{3}$$

Este tipo de políticas es especialmente relevante en algoritmos actor–critic continuos como TD3, empleado en este trabajo. En este enfoque, la política $\pi(s)$ genera directamente la acción continua aplicada al sistema, sin necesidad de muestrear una distribución estocástica. Así, para cada estado observado —que incluye el error angular, la posición actual del brazo, la inclinación del robot y otras variables relevantes— la política produce una acción$a = \pi(s)$ que corresponde al torque (escalado) aplicado al actuador.

El objetivo del aprendizaje es ajustar los parámetros de la política para maximizar el retorno esperado, de modo que las acciones seleccionadas conduzcan a un seguimiento preciso de la referencia, con suavidad adecuada y dentro de los límites físicos del actuador.

1.4.1 Política determinista μ

La política determinista denotada por μ asigna una única acción a cada estado:

$$a_t = \mu(s_t) \tag{4}$$

En entornos con espacios de acción continuos con política determinista, se emplean políticas Gaussianas diagonales ejecutándose:

1. Un muestreo para determinar la acción

   a) Con su componente vectorial para la acción:

$$\mu_\theta(s) \tag{5}$$

   b) Y su componente de matriz de covarianza diagonal

$$\sigma_\theta(s) \text{ , también común, } \log \sigma_\theta(s) \tag{6}$$

$$\mathrm{a} = \mu_\theta(s) + \sigma_\theta(s) \odot z, \qquad z \sim \mathcal{N}(0, I) \tag{7}$$

donde $\odot$ denota el producto elemento a elemento

2. El cálculo Log-Likelihood para el entrenamiento de la política mediante el gradiente:

$$\log \pi_\theta(\, a \mid s\,) = -\frac{1}{2}\left(\sum_{i=1}^{k}\left[\frac{(a_i - \mu_i)^2}{\sigma_i^2} + 2\log\sigma_i\right] + k\log 2\,\pi\right). \tag{8}$$

En algoritmos de control continuo como TD3, utilizados en este trabajo, la política resulta determinista durante la inferencia, generando directamente la acción aplicada al sistema. No obstante, durante el entrenamiento se introduce ruido externo (ruido Gaussiano) para fomentar la exploración.

1.4.2 Política estocástica π

La política estocástica esta denotada por π y define una distribución de probabilidad sobre las acciones:

$$a_t \sim \pi(\cdot \mid s_t\,) \tag{9}$$

En el caso de políticas estocásticas, el uso y entrenamiento de la política requieren dos operaciones centrales:

1. (Uso) muestrear una acción de la distribución definida por la política

$$a_t \sim \pi(\cdot \mid s_t)$$

2. El cálculo Log-Likelihood para el entrenamiento de la política mediante el gradiente.

$$\log \pi_\theta(a_t \mid s_t) \tag{10}$$

En entornos con espacios de acción discretos, es común utilizar políticas categóricas, también llamadas *categorical policies*. Este tipo de política funciona de manera análoga a un clasificador: la red neuronal recibe la observación del entorno y produce un vector de logits, uno por cada acción posible. Dichos logits se transforman en probabilidades mediante una función softmax, generando así la distribución:

$$\pi_\theta(a \mid s) = P_\theta(a \mid s) \tag{11}$$

1. Muestreo de acciones:

Dado el vector de probabilidades sobre las acciones, una acción puede seleccionarse muestreando directamente de la distribución categórica:

$$a_t \sim \pi_\theta(\cdot \mid s_t) \tag{12}$$

Las principales librerías de Deep Learning (como PyTorch o TensorFlow) incluyen funciones nativas para muestrear de una distribución categórica.

2. Entrenamiento de política:

Para entrenar políticas estocásticas mediante métodos basados en gradientes, se necesita calcular la log-probabilidad de la acción ejecutada. Si $P_\theta(s)$ es el vector de probabilidades devuelto por la política, entonces:

$$\log \pi_\theta(a \mid s) = \log[P_\theta(s)]_a \tag{13}$$

1.5 Trayectorias

El proceso de transición entre estados puede representarse mediante tres tipos de dinámicas (véase Fig. 1), en donde el agente desciende por el árbol de estados al seleccionar acciones (proceso de exploración) (Plaat, 2022). A Continuación se describen estos tres tipos de transiciones:

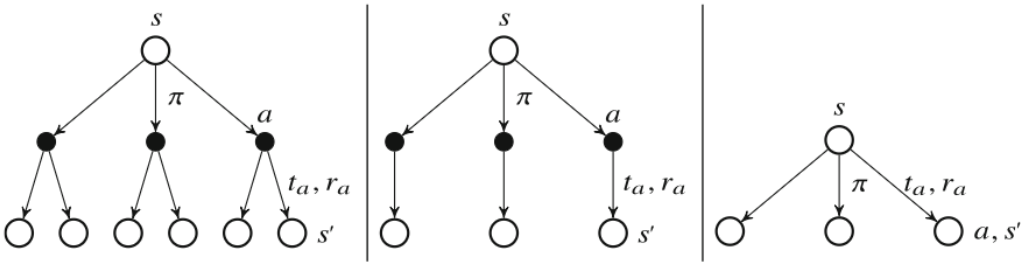

Fig. 1. Tipos de Transicion en MDP: trans. estocastica (izquierda), transc. determinista (centro y derecha). Fuente: (Plaat, 2022).

1. Transiciones estocásticas - Fig. 1, izquierda.

Una misma acción puede conducir a múltiples estados futuros posibles, cada uno con una probabilidad asociada. Este tipo de transición modela entornos donde existen elementos no controlados por el agente, como ruido, variaciones mecánicas o perturbaciones externas.

2. Transiciones deterministas con múltiples acciones - Fig. 1, centro

Cada acción disponible desde un estado produce siempre el mismo estado siguiente, pero el agente dispone de varias acciones entre las que elegir sin incertidumbre sobre su efecto. Este caso aparece en simulaciones donde la dinámica está completamente definida por ecuaciones exactas.

3. Transición determinista simplificada - Fig. 1, derecha

El entorno posee una única rama posible por acción y no existe divergencia en los estados futuros. El grafo puede entonces representarse sin nodos intermedios, ya que cada acción define una relación directa $s \rightarrow s'$

Una trayectoria τ es la secuencia de estados y acciones que se generan durante la interacción del agente con el entorno:

$$\tau = (s_0, a_0, s_1, a_1, \dots) \tag{14}$$

El primer estado s_0 suele muestrearse de una distribución inicial, denotada por ρ_0:

$$s_0 \sim \rho_0(\cdot) \tag{15}$$

La evolución del entorno está determinada por sus leyes dinámicas, que especifican cómo se transita del estado $s_t$al estado s_{t+1} tras ejecutar la acción a_t. Estas transiciones pueden ser:

Deterministas:

$$s_{t+1} = \mathrm{f}(s_t, a_t) \tag{16}$$

Estocásticas:

$$s_{t+1} = \mathrm{P}(\cdot \mid s_t, a_t) \tag{17}$$

Las acciones que conforman la trayectoria provienen del agente y se seleccionan de acuerdo con su política. Una trayectoria completa representa por tanto un "episodio" de interacción, y constituye la unidad básica de información sobre la que se entrenan y evalúan los algoritmos de aprendizaje por refuerzo.

1.6 Recompensa Ra

La recompensa es el elemento central del aprendizaje por refuerzo, ya que cuantifica la calidad inmediata de una transición del sistema. Cada vez que el agente pasa del estado s al estado s' mediante la acción a, el entorno devuelve un valor numérico que indica si el resultado obtenido es deseable o no. Aunque la recompensa está asociada a una sola transición, el objetivo del agente no es maximizar recompensas aisladas, sino el retorno acumulado, es decir, la suma de recompensas obtenidas a lo largo de toda una secuencia de decisiones.

La expectativa de este retorno futuro, ponderado por un factor de descuento, define la función de valor $V^{\pi}(s)$, que representa la calidad esperada de encontrarse en un estado determinado cuando se sigue una política π. La función de valor constituye un concepto fundamental, ya que guía la mejora progresiva del comportamiento del agente al ofrecer una medida de utilidad a largo plazo más allá de las recompensas inmediatas. En conjunto, la recompensa, el retorno y la función de valor establecen la base matemática que permite evaluar la eficacia de las decisiones del agente dentro del formalismo del MDP (Plaat, 2022).

En el caso específico del robot Lázaro, la función de recompensa se construye a partir de las señales que gobiernan directamente el comportamiento de la articulación: el error angular y la señal de control aplicada al actuador. El error angular, definido como la diferencia entre la referencia θ_{1sp} y la posición real θ_1, constituye el término principal de la recompensa y permite penalizar desviaciones respecto a la trayectoria deseada.

Adicionalmente, la recompensa incorpora la señal de control generada por el agente, la cual atraviesa el bloque de conversión Torque → Voltaje (T→V) del modelo dinámico. Este término introduce una penalización sobre esfuerzos de control excesivos, favoreciendo acciones más suaves y evitando torques abruptos que puedan comprometer la estabilidad del sistema.

En conjunto, la recompensa combina información sobre el desempeño del seguimiento y sobre el esfuerzo requerido para lograrlo, orientando el aprendizaje del

agente hacia políticas de control que mantienen un equilibrio entre precisión y eficiencia energética dentro del lazo de control de la articulación.

1.7 Factor de descuento γ

El factor de descuento γ forma parte fundamental de la formulación de un Proceso de Decisión de Markov (MDP). Su papel consiste en determinar la importancia relativa entre recompensas inmediatas y recompensas futuras. Tal como explica (Plaat, 2022) es útil distinguir entre dos tipos de tareas:

1. tareas continuas o de larga duración, y
2. tareas episódicas, en las que la interacción termina tras un número finito de pasos.

En tareas continuas, resulta razonable atenuar el efecto de recompensas muy lejanas en el tiempo, ya que su valor es menos relevante para la toma de decisiones en el presente. Para ello se introduce un factor γ < 1 que reduce progresivamente el peso de recompensas futuras:

$$R_t = r_t + \gamma r_{t+1} + \gamma^2 r_{t+2} + \dots \tag{18}$$

De esta forma, γ actúa como un mecanismo de estabilidad y de priorización temporal.

En contraste, en tareas episódicas —como muchos juegos o problemas donde la interacción termina cuando se alcanza un estado objetivo— el descuento puede resultar innecesario, ya que no existe riesgo de acumulación indefinida de recompensas. En estos casos, establecer γ = 1 no altera la optimización de la política, pues el horizonte está naturalmente acotado (Plaat, 2022).

En el contexto de este trabajo, el control de la articulación θ_1 del robot Lázaro se formula como una tarea episódica de duración fija durante cada simulación. Por ello, un valor de γ próximo a 1 resulta adecuado, ya que preserva toda la información de las recompensas obtenidas y favorece que el agente optimice el desempeño a lo largo de todo el episodio.

1.8 Trazas τ

Cuando un agente interactúa con un proceso de decisión de Markov, genera de manera natural una secuencia ordenada de estados, acciones y recompensas. Esta secuencia recibe el nombre de traza y constituye uno de los elementos fundamentales en el aprendizaje por refuerzo (Plaat, 2022).

En cada paso temporal t, el agente observa un estado s_t, selecciona una acción a_t, y el entorno devuelve un nuevo estado s_{t+1} junto con una recompensa r_t. La repetición de este proceso produce una traza de longitud n:

$$\tau_t^n = \{s_t, a_t, r_t, s_{t+1}, \dots, a_{t+n}, r_{t+n}, s_{t+n+1}\} \tag{19}$$

En muchos entornos, especialmente aquellos que finalizan de forma natural tras una secuencia finita de interacciones, se considera una traza completa de episodio, es decir:

$$\tau_t = \tau_t^\infty \tag{20}$$

que se extiende hasta que el entorno alcanza un estado terminal. Una traza completa también recibe los nombres de episodio, trayectoria o rollout.

1.8.1 Distribución de trazas

Debido a que tanto las políticas como las dinámicas del entorno pueden ser estocásticas, iniciar un episodio desde el mismo estado inicial no garantiza obtener siempre la misma traza. En su lugar, se obtiene una distribución de posibles trazas, denotada por $\mathrm{p}(\tau_0)$.

La probabilidad de una traza completa puede expresarse como el producto de todas las probabilidades de transición y selección de acciones a lo largo del tiempo:

$$p(\tau_0) = p_0(s_0) \prod_{t=0}^{\infty} \pi(\, a_t \mid s_t \,)\; T_{a_t}(s_t, s_{t+1}) \tag{21}$$

Esta formulación refleja que la probabilidad de una trayectoria completa depende simultáneamente:

- de la política del agente,
- de las dinámicas del entorno,
- del estado inicial.

En TD3, las trazas generadas durante el entrenamiento son estocásticas debido al ruido gaussiano que se añade a las acciones para promover la exploración. Sin embargo, durante la fase de inferencia la política es completamente determinista y no incorpora ningún componente aleatorio. Por tanto, si el entorno es determinista, las trazas producidas por el agente serán idénticas en cada ejecución; únicamente variarán si el propio entorno introduce aleatoriedad externa.

$$a_t = \pi(s_t) + \epsilon_t, \qquad \epsilon_t \sim \mathcal{N}(0, \sigma^2) \tag{22}$$

Eso convierte automáticamente las trazas en:

$$\tau = \{s_0, a_0, r_0, s_1, a_1, \dots\} \tag{23}$$

en variables aleatorias por lo tanto trazas probabilísticas.

1.9 Funciones de Valor

1.10 Valor del estado $V^{\pi}(s)$

En entornos donde tanto la política como las dinámicas del MDP pueden ser estocásticas, una misma acción tomada desde un mismo estado inicial no necesariamente conduce siempre a la misma trayectoria. Por esta razón, el análisis del desempeño de una política no debe basarse en el retorno obtenido en una única traza, sino en el retorno esperado al seguir dicha política (Plaat, 2022).

La función de valor del estado, $V^{\pi}(s)$, cuantifica precisamente este concepto. Se define como la recompensa acumulada esperada que recibirá un agente al iniciar en el estado s y seguir la política π a lo largo del tiempo. Formalmente:

$$V^{\pi}(s) = \mathbb{E}_{\tau_t \sim p(\tau_t)}\left[\sum_{i=0}^{\infty} \gamma^i \, r_{t+i} \mid s_t = s\right] \tag{24}$$

Es decir, $V^{\pi}(s)$ representa el retorno promedio que se obtendría al iniciar desde s y continuar aplicando la política π, teniendo en cuenta que las diferentes trazas posibles pueden ocurrir con distintas probabilidades.

Si una política dada produce dos posibles trazas desde el mismo estado s:

- una con retorno total 20, con probabilidad 0.6,
- otra con retorno total 10, con probabilidad 0.4,

entonces el valor del estado es:

$$V^{\pi}(s) = 0.6 \cdot 20 + 0.4 \cdot 10 = 16$$

Esto refleja que el valor del estado es el retorno esperado, no el retorno de un único episodio.

Cada política π tiene asociada una única función de valor $V^{\pi}(s)$ y esta asigna a cada estado un número real:

$$\mathrm{V}: \mathrm{S} \rightarrow \mathbb{R}$$

En espacios de estados discretos, esta función puede representarse como una tabla donde cada fila contiene el valor asociado a un estado específico. En tareas

de control continuo, esta función suele aproximarse mediante redes neuronales u otros métodos paramétricos (Plaat, 2022).

Por convención, el valor de un estado terminal es cero:

$$s = \text{terminal} \Rightarrow V(s) = 0$$

1.11 Valor de acción $Q^{\pi}(s, a)$

Además de la función de valor del estado, es útil definir la función de valor estado–acción, denotada como $Q^{\pi}(s, a)$. Mientras que$V^{\pi}(s)$ mide el retorno esperado al iniciar en el estado s y seguir la política π, la función $Q^{\pi}(s, a)$cuantifica el retorno esperado cuando el agente toma primero una acción concreta a en el estado s, y posteriormente continúa siguiendo la política π.

$$Q^{\pi}(s, a) = \mathbb{E}_{\tau_{\mathbb{t}} \sim \mathbb{p}(\tau_{\mathbb{t}})}\left[\sum_{i=0}^{\infty} \gamma^{i}\ r_{t+i} \middle| s_t = s, a_t = a\right] \tag{25}$$

Es decir, $Q^{\pi}(s, a)$ mide la calidad de ejecutar la acción a en el estado s, teniendo en cuenta la evolución posterior inducida por la política. De hecho, la letra “Q” suele asociarse coloquialmente a *“quality”,* ya que esta función estima cuán buena es una acción en un estado dado.

Cada política π tiene asociada una única función de valor estado–acción. Su dominio es el producto cartesiano del conjunto de estados y el conjunto de acciones:

$$\mathrm{Q}: \mathrm{S} \times A \rightarrow \mathbb{R} \tag{26}$$

Por tanto, esta función asigna un valor real a cada par (s, a), representando su retorno esperado bajo la política.

1.12 Función de ventaja $A^{\pi}(s, a)$

La función de ventaja $A^{\pi}(s, a)$ cuantifica cuánto mejor o peor resulta tomar una acción específica a en un estado s, en comparación con seguir la política actual π. Mientras que la función de valor de acción $Q^{\pi}(s, a)$ evalúa el retorno esperado al ejecutar una acción concreta en un estado dado, la ventaja mide ese retorno relativo a lo que la política normalmente produciría en el mismo estado (Plaat, 2022).

Formalmente, la ventaja se define como:

$$A^{\pi}(s, a) = Q^{\pi}(s, a) - V^{\pi}(s) \tag{27}$$

donde:

$Q^{\pi}(s,a)$ es el retorno esperado al tomar la acción a y continuar con la política π;

$V^{\pi}(s)$ es el retorno esperado al seguir la política directamente desde ese estado.

En donde:

- Si $A^{\pi}(s,a) > 0$: la acción es mejor que la acción promedio prevista por la política.
- Si $A^{\pi}(s,a)$= 0: la acción tiene una calidad equivalente a la expectativa de la política.
- Si $A^{\pi}(s,a) < 0$:la acción es peor que el comportamiento habitual de la política.

De esta forma, la ventaja no mide el rendimiento absoluto de una acción, sino su valor incremental respecto a la política vigente.

2 Literaturverzeichnis

Plaat, A. (2022). *Deep Reinforcement Learnig.* Netherlands: Springer.

Sutton, R. S., & Barto, A. G. (2018). *Reinforcement Learning.* London, England: The MIT Press.

Wittpahl, V. (2019). *Künstliche Intelligenz, technologie, Anwendung, Gesellschaft.* Berlin: Springer Verlag.